

웨어러블 라이프로그 기반 CN·MCI·DEM 3-class 분류 최종 실험 보고서

최종 정리 범위: V2 → V3 실험 흐름, 데이터·전처리·feature engineering·모델 탐색·선택·양상불·의사결정 구현, 최종 성능, Permutation Importance, SHAP 분석

기준일: 2026-09-23

분석 대상: 현재 제공 데이터 기준 **174명**

핵심 제약: 피험자 단위 독립 분할 유지 + MMSE 미사용

중요: 본 문서는 업로드된 V2/V3 소스코드, 실행 산출물, 실행 완료 SHAP 노트북 및 결과 CSV/PNG를 기준으로 작성하였다. 코드·산출물에 없는 임상적 사실이나 성능 원인은 임의로 추가하지 않았다.

0. 이 문서를 읽을 때 가장 먼저 알아야 할 것

이 프로젝트는 V2와 V3에서 **평가 목적 자체가 달라졌다**.

- **V2**의 목적은 가능한 한 엄격하게 일반화 성능을 확인하는 것이었다.
 - 피험자 단위 분할
 - No MMSE
 - Nested CV
 - 공식 Validation은 V2 설계 선택에 사용하지 않음
- **V3**의 목적은 프로젝트 목표 변경 후, 다음 두 조건을 고정하면서 **현재 고정 Training/Validation에서 3-class 성능을 최대화**하는 것으로 바뀌었다.
 - 피험자 단위 독립 분할
 - No MMSE
 - Nested CV는 필수 조건에서 제외
 - Validation label을 모델·하이퍼파라미터·score 변환·양상불·decision offset 선택에 적극 사용


따라서 다음 두 숫자는 같은 의미로 직접 비교하면 안 된다.

- V2 Nested outer OOF AUC: **0.5431**
- V3 Selection Validation AUC: **0.9759**

V2는 일반화 추정에 가깝고, V3는 **selection-validation 최적화** 결과다.

V3 결과는 매우 높지만, 코드 자체도 이를 **독립 테스트 성능으로 주장하지 않도록** 명시하고 있다.

V2 and V3 reported metrics (different evaluation protocols)



1. 최종 결론 요약

1.1 데이터와 고정 조건

현재 실제 분석 데이터는 **174명**이다.

Split	CN	MCI	DEM	전체
Training	85	47	9	141
Validation	26	4	3	33
전체	111	51	12	174

Training과 Validation의 피험자 ID 교집합은 **0명**이다.

AI-Hub의 과거 구축 문서에는 300명이라는 설명이 있으나, 본 프로젝트에서는 사용자가 지정한 현재 수정 데이터 기준인 **174명**을 실제 분석대상 수로 사용한다. 300명에서 174명으로 변경된 구체적 공식 제외 사유는 현재 제공 문서에서 확인되지 않았으므로 본 보고서에서 임의로 설명하지 않는다.

1.2 No MMSE 최종 판정

현재 V2/V3 구현에서는 **MMSE를 predictor로 사용하지 않는다**.

확인된 구현은 다음과 같다.

- V2 `resolve_paths()`는 Activity, Sleep, 각 라벨 파일만 탐색한다.
- V2 데이터 fingerprint도 `activity`, `sleep`, `activity_label`, `sleep_label` 이외 입력을 거부한다.
- 라벨 파일은 `SAMPLE_EMAIL`, `DIAG_NM` 두 열만 읽는다.
- Activity/Sleep CSV는 allowlist 방식으로 필요한 wearable 열만 읽는다.
- V3 `load_daily()`는 경로 문자열에 `mmse` 또는 `cognitivefunction`이 있으면 즉시 오류를 발생시킨다.
- V3 최종 feature matrix에서 `mmse`, `diag`, `email`, `subject`, `timestamp`, `_date` 등의 금지 토큰이 predictor 이름에 남아 있지 않음을 assertion으로 확인한다.
- V2와 V3 manifest에 기록된 실제 입력 hash에도 MMSE 파일이 없다.
- V3 summary에 `MMSE_used: false`가 기록되어 있다.

따라서 피험자 식별자는 **grouping/split** 확인에만 사용되고, **MMSE는 모델 입력에 사용되지 않았다**.

1.3 V2와 V3의 최종 성능

V2

평가	Macro ROC-AUC	Macro Recall	Macro F1	Accuracy	CN Recall	MCI Recall	DEM Recall
V2 개발 OOF (선택에 재사용)	0.6047	0.5689	0.5149	0.5319	0.5294	0.5106	0.6667
V2 Nested outer OOF	0.5431	0.4418	0.3920	0.4965	0.6471	0.2340	0.4444
V2 공식 Validation 재평가	0.6136	0.4466	0.4817	0.4242	0.4231	0.2500	0.6667

V2의 엄격한 Nested outer OOF에서는 특히 **MCI 분리 성능이 낮았다**.

- MCI Recall: **0.2340**
- MCI OVR AUC: **0.4819**

V3

최종 Selection Validation 결과:

- Macro ROC-AUC: **0.975938**
- Macro Recall: **0.987179**
- Macro F1: **0.956427**
- Accuracy: **0.969697**
- CN Recall: **0.9615**

- MCI Recall: **1.0000**
- DEM Recall: **1.0000**

Confusion matrix:


Actual \ Predicted	CN	MCI	DEM
CN	25	1	0
MCI	0	4	0
DEM	0	0	3

즉 Validation 33명 중 **32명**이 최종 decision rule에서 맞았다.

1.4 최종 모델의 핵심 구조

V3 champion은 단일 3-class 모델이 아니다.

두 개의 **hierarchical classifier**를 **class-wise soft voting**한 **3-class ensemble**이다.



최종 4개 component는 다음과 같다.

Hierarchy	분기	모델	Feature view	선택 feature	선택법	변환	PCA 요청	PCA 실효 상한	증강	Branch AUC
Hierarchy 1	DEM vs non-DEM	rbf_ridge	activity	20	rfe	quantile	없음	없음	smote	0.9889
Hierarchy 1	MCI vs CN	lda	compact	15	anova	signedlog	없음	없음	smote	0.9135
Hierarchy 2	DEM vs non-DEM	rbf_ridge	activity	80	rfe	standard	15	15	none	0.9889
Hierarchy 2	MCI vs CN	logreg	compact	15	anova	standard	30	15	none	0.8942

PCA=30은 설정값이다. CN/MCI Logistic Regression은 선택 feature가 15개이므로 코드상 실제 PCA component 수는 min(30, 15, n-1)로 제한되어 15개다.

2. 데이터 입력과 기본 전처리

2.1 실제 읽는 파일

V2/V3 모델 입력은 다음 범주로 제한된다.

- Activity source CSV
- Sleep source CSV
- Activity label CSV
- Sleep label CSV

인지기능/MMSE source CSV는 모델 입력 경로에 포함되지 않는다.

라벨은 **DIAG_NM**을 다음 순서로 정수화한다.

```
CN  -> 0
MCI -> 1
DEM -> 2
```

피험자 이메일은 원문을 predictor로 사용하지 않고 SHA-256 기반의 subject key로 바꿔 grouping에 사용한다.

2.2 원시 row와 subject-day 정리

V2 audit 기준:

Split	Modality	입력 row	중복 subject-date	최종 kept row	피험자
Train	Activity	9,705	0	9,705	141
Train	Sleep	9,705	11	9,694	141
Validation	Activity	2,478	0	2,478	33
Validation	Sleep	2,478	1	2,477	33

Sleep에 같은 피험자-같은 날짜 row가 여러 개면 코드에서 수면 duration이 긴 row를 우선 정렬하여 하나를 유지한다.

Activity는 피험자-날짜-시작 시각 순으로 정렬 후 subject-date 중복을 제거한다.

2.3 최소 관측 기준

V2 feature extraction config:

```
observation_days = None
min_days         = 7
csv_chunksize    = 256
```

즉 고정된 첫 35일만 사용하는 구조가 아니라, 현재 V2/V3 코드에서는 해당 split의 관측기간을 사용하되 **최소 7일** 관측이 필요하다.

2.4 활동 상태 코드

AI-Hub 데이터 정의와 코드에서 사용되는 **activity_class_5min** 상태는 다음과 같다.

Code	의미
0	non-wear
1	rest
2	inactive
3	low-intensity activity
4	medium-intensity activity
5	high-intensity activity

따라서 최종 중요 feature의 **state_code_3**은 **저강도 활동**, **state_code_1**은 **휴식**으로 해석한다.

3. V2: 엄격한 검증을 우선한 실험

3.1 V2의 질문

V2가 묻는 질문은 다음과 같았다.

“MMSE를 제외하고 피험자를 완전히 분리했을 때, 현재 라이프로그 특징과 일반적인 ML 모델로 CN/MCI/DEM을 얼마나 일반화해서 구분할 수 있는가?”

이를 위해 V2는 단순 한 번의 train/validation 평가가 아니라:

1. Development 5-fold OOF
2. Nested CV
 - Outer 5-fold
 - Inner 3-fold
3. 모든 모델 선택을 마친 뒤 기존 공식 Validation 평가

순서를 사용했다.

3.2 V2 representation

V2는 동일한 피험자 데이터에서 여러 표현을 만들었다.

Representation	Train row	Train feature	Validation row	Validation feature	설명
subject_v1	141	670	33	670	기본 피험자 요약
subject_plus	141	1,333	33	1,333	추가 분포·주말·시간대 feature
window14	784	1,333	196	1,333	비중첩 14일 window
window28	449	1,333	110	1,333	비중첩 28일 window

Window representation에서도 같은 사람의 모든 window는 같은 fold에 남도록 **groups**를 유지한다.

subject_v1의 주요 feature 유형

V2는 하루 단위 activity/sleep feature를 만든 뒤 피험자 단위로 요약한다.

예:

- median
- IQR
- p10 / p90
- missing fraction
- 일간 RMSSD
- trend per day
- consecutive lag-1
- activity/sleep coupling
- 시간대 MET 특성
- 취침·기상 시각의 원형(circular) 표현

subject_plus의 추가 feature

각 일별 변수에 대해 추가로:

- mean
- std
- MAD
- CV
- weekend delta

를 만들며, 활동에 대해서는 24시간 각 hour의 MET mean/std도 추가한다.

3.3 V2 feature selection / preprocessing

V2의 **FoldProcessor**는 각 **CV training fold** 안에서만 population 통계를 fit한다.

순서는 다음과 같다.

```

Training subjects only
  ↓
Feature view 선택
  ↓
피험자별 중심값으로 usable feature 검사
  ↓
Training median으로 결측 처리
  ↓
ANOVA 또는 Mutual Information ranking
  ↓
Top-k
  ↓
선택적으로 correlation pruning
  ↓
선형 계열은 median/IQR 기반 scaling
  ↓
선택적으로 PCA
  ↓
Model fit

```

Window 모델에서도 feature ranking/결측/scale 계산 시 한 사람이 window가 많다는 이유로 전처리에 더 큰 영향을 주지 않도록 **피험자별 평균 feature vector**를 먼저 만든 뒤 preprocessing statistics를 계산한다.

3.4 V2 class/sample weighting

V2 **subject_weights()**는 두 가지를 동시에 처리한다.

1. window가 여러 개인 사람도 전체 기여도가 과도하게 커지지 않도록 **1 / 해당 피험자의 row 수**
2. class balance 설정에 따라 class count의 역수 계열 가중치

balance 의미:

- **0.0**: class balancing 없음
- **0.5**: class frequency의 제곱근 수준 보정
- **1.0**: inverse-frequency 수준 보정

3.5 V2 사전 ablation 27개

V2는 Optuna 이전에 27개의 사전 정의 비교를 수행했다.

주요 축:

- physiology only
- quality 제외
- vendor score 제외
- coupling 제외
- activity only
- sleep only
- enhanced features
- top 50 / 100
- correlation 0.95
- 14/28일 window
- mean/geometric pooling
- class balance 변화
- 모델 family 변화
- SVM + PCA
- Mutual Information

V2 ablation에서 **A05_activity**는 최종 ensemble에도 포함되었다.

3.6 V2 모델 계열

V2 탐색 대상은 다음을 포함했다.

- CatBoost
- Logistic Regression
- RBF SVM
- ExtraTrees
- RandomForest
- HistGradientBoosting
- LDA
- Gaussian Naive Bayes
- Hierarchical CatBoost
- Hierarchical Logistic Regression

V2 hierarchical 모델은:

1. CN vs impaired(MCI+DEM)
2. impaired 내부에서 MCI vs DEM

의 2단계 구조였다.

3.7 V2 개발 탐색

V2 config:

```
seed                = 2026
development_folds    = 5
outer_folds          = 5
inner_folds          = 3
Optuna development   = 80 trials
Nested inner search  = 20 trials
final seeds          = [2026, 2037, 2048]
bootstrap repeats    = 2000
target threshold     = 0.8
```

V2 objective:

```
min(Macro ROC-AUC, Macro Recall)
+ 아주 작은 평균 metric tie-break
+ 아주 작은 Macro F1 tie-break
```

즉 AUC만 높고 recall이 낮은 모델보다 **둘 중 약한 지표가 높은 모델**을 우선하도록 설계했다.

3.8 V2 decision offset

V2도 class score의 argmax만 쓰지 않고, development/inner OOF에서 전역 class log-score offset을 탐색했다.

중요한 구현 원칙:

- offset은 **hard decision/recall**만 바꾼다.
- ROC-AUC는 offset 적용 전 score로 계산한다.
- score를 보정된 임상 확률이라고 주장하지 않는다.

3.9 V2 ensemble 선택

개발 OOF에서 모델/representation/view가 다양한 상위 후보를 모은 뒤 greedy ensemble을 구성했다.

최종 선택된 논리적 3개 spec:

1. A05_activity
 - subject_v1
 - activity
 - CatBoost
2. A24_hier_logreg
 - subject_plus
 - all
 - top 100
 - hierarchical logistic regression
3. T0006
 - subject_plus
 - activity
 - RandomForest
 - top 200
 - balance 0.5
 - correlation 0.95

각 spec은 마지막에 **3개 seed(2026, 2037, 2048)**로 다시 fit되므로 실제 저장 ensemble에는 9개의 fitted model이 들어간다.

논리적 spec weight는 각각 1/3이고 최종 V2 decision offset은:

`[-0.5, 0.0, +0.5]`

였다.

3.10 V2 Nested CV

V2의 가장 엄격한 평가는 Nested CV였다.

```

Outer 5-fold
├── Outer train
│   └── Inner 3-fold search
│       ├── ablation
│       ├── Optuna 20 trials
│       ├── ensemble
│       └── decision offset
└── Outer test
    └── 해당 outer test 피험자는 위 선택에 전혀 사용하지 않음
  
```

Outer 5개 fold의 예측을 모두 합친 것이 `nested_outer_oof`다.

3.11 V2 결과

평가	Macro ROC-AUC	Macro Recall	Macro F1	Accuracy	CN Recall	MCI Recall	DEM Recall
V2 개발 OOF (선택에 재사용)	0.6047	0.5689	0.5149	0.5319	0.5294	0.5106	0.6667
V2 Nested outer OOF	0.5431	0.4418	0.3920	0.4965	0.6471	0.2340	0.4444
V2 공식 Validation 재평가	0.6136	0.4466	0.4817	0.4242	0.4231	0.2500	0.6667

Nested subject bootstrap 95% interval:

Metric	Estimate	95% lower	95% upper
roc_auc_macro_ovr	0.5431	0.4373	0.6476
macro_recall	0.4418	0.3269	0.5681

Metric	Estimate	95% lower	95% upper
macro_f1	0.3920	0.3088	0.4843
accuracy	0.4965	0.4184	0.5676
recall_CN	0.6471	0.5412	0.7412
recall_MCI	0.2340	0.1277	0.3617
recall_DEM	0.4444	0.1111	0.7778

기존 공식 Validation의 subject bootstrap:

Metric	Estimate	95% lower	95% upper
roc_auc_macro_ovr	0.6136	0.4769	0.7530
macro_recall	0.4466	0.2115	0.6669
macro_f1	0.4817	0.2287	0.6149
accuracy	0.4242	0.2727	0.6061
recall_CN	0.4231	0.2308	0.6154
recall_MCI	0.2500	0.0000	0.7500
recall_DEM	0.6667	0.0000	1.0000

3.12 V2에서 얻은 결론

코드와 실행 결과가 직접 보여준 사실:

- 엄격한 Nested CV에서는 target **AUC ≥ 0.8 & Macro Recall ≥ 0.8** 을 달성하지 못했다.
- 특히 MCI가 약했다.
 - Nested MCI AUC: **0.4819**
 - Nested MCI Recall: **0.2340**
- DEM은 MCI보다 AUC가 상대적으로 높았지만 Training 9명, Validation 3명으로 표본이 매우 적었다.
- Activity-only 모델이 최종 V2 ensemble에 남았다.
- 엄격한 검증을 유지한 상태에서 현재 데이터로 0.8 이상 목표를 안정적으로 얻지 못했다.

이 결과 이후 프로젝트의 목적이 *****엄격한 Nested CV 성능 증명*****에서 **“피험자 분리 + No MMSE를 유지한 3-class 성능 탐색 및 해석”*****으로 변경되면서 V3가 설계되었다.

4. V3: 성능 탐색 중심으로 전환한 실험

4.1 V3 평가 프로토콜

V3 소스 첫 설명은 명확하다.

Single fixed subject split. No nested CV.
Validation labels are deliberately used for hyperparameter/mixture/threshold selection.

실제 고정 split:

- Training 141명
- Selection Validation 33명
- overlap 0명
- split 변경 없음
- 어려운 피험자 제외 없음
- 고득점 split 재선택 없음

Estimator와 preprocessor의 **fit()**은 Training 피험자만 본다.
하지만 **Validation label**은 모델 선택에 사용된다.

따라서 V3 metric의 정확한 명칭은:

Selection Validation performance

이다.

4.2 V3 feature 확장

V3의 최종 **subject** representation은 **5,144개 feature**다.

구성:

- V2 legacy: **1,333**
- V3 temporal feature: **3,799**
- collection-context: **12**
- 총합: **5,144**

Feature view 수

View	Feature 수
all	5,144
no_context	5,132
context_only	12
legacy	1,333
temporal	3,799
variability	2,268
activity	2,278
sleep	2,856
hr_drop	377
circadian	645
compact	15
dem_single	1

4.3 V3 temporal summary

일별 signal을 한 사람의 calendar day series로 만든 후 다음 통계를 생성한다.

기본:

- mean
- std
- median
- trimmed mean
- mode
- min / max / range
- MAD
- CV
- skew / kurtosis
- q05 / q95
- RMSSD
- moving range
- lag-1
- trend
- 4구간 variance / change

Rolling:

- STV7 / STV14 / STV28
- rolling CV 7 / 14 / 28
- rolling range 7 / 14 / 28

중요 구현:

- 빈 날짜는 calendar reindex로 유지한다.
- 일간 차이를 계산할 때 **결측 날짜를 가로질러 직접 연결하지 않는다.**
- **STV7**은 7일 rolling standard deviation의 평균이다.
- **rolling_range7**은 각 7일 구간 (**max-min**)의 평균이다.

4.4 활동 시퀀스 feature

5분 activity state sequence에서:

- 각 state fraction
- 각 state의 longest consecutive minutes
- entropy
- transition rate

를 계산한다.

transition_rate는 인접한 유효 5분 state 두 개가 서로 다를 확률의 평균이다.

예:

```
1,1,1,3,3,2,2,3 ...
```

에서는 state가 바뀌는 경계의 비율이 transition rate에 반영된다.

4.5 시간대 활동 feature

1분 MET sequence에서 실제 clock 위치를 유지하면서:

- 시간대별 profile
- cosinor amplitude
- relative amplitude
- phase sin/cos
- day-night difference
- low5 / high10 MET
- relative high10-low5

등을 만든다.

activity__hourly_profile_stability는 전체 hourly MET 분산 중 시간대 평균 profile이 설명하는 비율에 가까운 코드 정의다.

소스코드가 명시적으로:

표준 actigraphy IS와 동일한 지표라고 주장하지 않음

이라고 기록하므로, 본 보고서에서도 이를 **Interdaily Stability(IS)**와 동일한 임상 지표로 부르지 않는다.

4.6 수면 시각 규칙성

V2에서 bedtime/wake time을 circular variable로 바꾸고 resultant length를 계산한다.

- 1에 가까울수록 매일 비슷한 시간
- 낮을수록 시각 분산이 큼

따라서:

- **sleep__bedtime_regularity**
- **sleep__wake_regularity**

는 단순 시각 SD와는 다른 원형 시간 규칙성 지표다.

4.7 V3 HR-drop reconstruction

V3가 추가한 `paper_hr_drop_*`은 코드 주석상 ****문헌 영감 기반 재구성(explicit reconstruction)****이며 특정 논문의 완전 재현이라고 주장하지 않는다.

하루 밤의 기본 `hr_drop_ratio`:

```
baseline = 수면 시작 첫 3개 5분 HR epoch 중
           유효값이 최소 2개일 때 그 평균

low       = 해당 밤 유효 HR의 minimum

hr_drop_ratio = (baseline - low) / baseline
```

`hr_drop05_ratio`는 minimum 대신 유효 HR의 5% 분위값을 사용한다.

이 하루 값을 다시 피험자 단위로:

- std
- MAD
- rolling CV
- rolling range
- 기타 temporal summary

로 요약한다.

4.8 Collection-context feature

V3는 실험적으로 수집 시점 자체도 별도 family로 만들었다.

Activity/Sleep 각각:

- first epoch day
- last epoch day
- median epoch day
- season sin
- season cos
- weekend fraction

총 12개다.

이는 생리 feature가 아니라 **수집 시기 metadata**이므로 별도 ablation을 수행했다.

최종 champion이 실제 사용한 collection-context feature:

```
[]
```

즉 **0**개다.

5. V3 preprocessing 및 모델 fitting

5.1 전처리는 Training-only

각 candidate의 `fit_candidate()` 흐름:

```
Training representation
  ↓
task label 변환
```

```

↓
Feature view 선택
↓
Training subject 기준 usable 검사
↓
Training median imputation
↓
Training label 기반 feature selection
↓
transform / scaler fit
↓
선택적 PCA fit
↓
선택적 SMOTE / jitter
↓
estimator fit
↓
Validation에는 transform + predict만 수행

```

Validation 피험자가 preprocessor 또는 estimator fit에 들어가는 코드는 없다.

5.2 usable feature 조건

Training subject center에서:

- 최소 `max(3, 10% of subjects)` 이상의 non-missing
- 값이 1개보다 많은 feature

만 남긴다.

5.3 feature selection

선택 방식:

ANOVA

`f_classif`로 Training label과 feature 관계를 ranking.

Mutual Information

`mutual_info_classif`, random seed 고정.

RFE

1. 먼저 ANOVA ranking으로 shortlist
2. StandardScaler
3. `LogisticRegression(C=0.1)`
4. RFE
5. Training label만 사용

최종 DEM component 두 개는 **RFE**를 사용했다.

5.4 correlation filtering

`correlation < 1`일 때 높은 ranking feature부터 순서대로 추가하되, 이미 선택된 feature와 절대상관이 threshold 이상이면 제외한다.

최종 H2 DEM component는 correlation 0.9를 사용한다.

5.5 transform / scaling

V3 candidate가 탐색하는 transform:

- `standard` → StandardScaler
- `robust` → RobustScaler
- `signedlog` → `sign(x) * log1p(|x|)` 후 RobustScaler

- `quantile` → `QuantileTransformer(normal)`

모든 scaler는 Training에서 fit되고 Validation에는 `transform()`만 적용한다.

5.6 PCA

탐색 가능한 요청 component:

```
0, 5, 15, 30
```

실제 component 수는:

```
min(requested_pca, 선택 feature 수, training row 수 - 1)
```

이다.

5.7 class balance

V3도 V2의 `subject_weights()`를 사용한다.

탐색값:

- 0.0
- 0.5
- 1.0

최종 4개 component는 `balance=0.0`이다.

대신 Hierarchy 1의 두 branch가 SMOTE를 사용한다.

5.8 SMOTE / jitter

V3 augmentation은 **preprocessing** 후 **Training matrix**에서만 수행한다.

SMOTE

각 minority class가 majority class 수와 같아질 때까지 같은 class의 nearest neighbors 사이를 선형 보간한다.

Jitter

같은 class Training row에 표준편차 0.03의 Gaussian noise를 더한다.

Augmentation은 한 사람당 한 row인 representation에만 허용되어 있으며 synthetic row의 부모가 모두 Training group 안인지 assertion으로 확인한다.

6. V3 모델 탐색 공간

6.1 세 가지 task bank

V3는 한 종류의 3-class 모델만 찾지 않았다.

`flat`

```
CN vs MCI vs DEM
```

직접 3-class.

`dem`

DEM vs (CN + MCI)

binary.

cn_mci

CN vs MCI

DEM 피험자를 제외한 binary.

이 분리 구조는 V2에서 MCI가 어렵고 DEM은 상대적으로 다른 성능 패턴을 보였던 결과를 바탕으로, 서로 다른 경계에 별도 모델을 사용할 수 있도록 구현한 것이다.

6.2 모델 family

V3 실행 환경에서 총 10개 family:

- CatBoost
- Logistic Regression
- SVM
- LDA
- ExtraTrees
- RandomForest
- HistGradientBoosting
- RBF Kernel Ridge
- XGBoost
- LightGBM

6.3 고정 baseline + Optuna

V3 Notebook config:

고정 후보	56개
Controlled ablation	16개
Optuna flat	160 trials
Optuna DEM	100 trials
Optuna CN/MCI	160 trials
Score transform	2,500 trials
Ensemble	1,200 trials
top branch bank	10개

실제 성공한 unique candidate:

- flat: **192**
- DEM: **109**
- CN/MCI: **174**
- 총: **475**
- 실패 기록: **0**

6.4 Candidate objective

Flat 3-class

V3 objective:

```
(AUC >= 0.8 AND MacroRecall >= 0.8 이면 +1)
+ min(AUC, MacroRecall)
```

```
+ 0.02 * 평균(AUC, MacroRecall)
+ 0.001 * MacroF1
```

즉 두 **target**을 동시에 **0.8 이상** 넘긴 **candidate/recipe**가 우선되고, 그 다음 약한 지표와 평균, F1 순으로 tie-break된다.

Binary branch

```
binary AUC + 0.02 * best balanced recall
```

이다.

7. V3 controlled ablation: 무엇이 직접 3-class 성능을 올렸는가

기준 모델:

```
flat CatBoost
no_context
ANOVA top 40
Robust scaling
class balance 1.0
augmentation 없음
```

결과:

Ablation	Macro AUC	Macro Recall	Accuracy	Δ AUC vs reference	Δ Recall vs reference
reference	0.6801	0.7179	0.3333	+0.0000	+0.0000
add_collection_context	0.6801	0.7179	0.3333	+0.0000	+0.0000
context_only	0.7457	0.6581	0.7576	+0.0656	-0.0598
activity_only	0.8854	0.8974	0.7576	+0.2053	+0.1795
sleep_only	0.6475	0.7051	0.3030	-0.0326	-0.0128
legacy_only	0.5676	0.6667	0.2121	-0.1125	-0.0513
temporal_only	0.5615	0.5641	0.6364	-0.1186	-0.1538
no_class_balance	0.6580	0.6581	0.4242	-0.0221	-0.0598
sqrt_class_balance	0.6410	0.7051	0.3030	-0.0391	-0.0128
smote	0.6603	0.6731	0.3939	-0.0198	-0.0449
jitter	0.6476	0.6603	0.3636	-0.0325	-0.0577
standard_scale	0.6801	0.7179	0.3333	+0.0000	+0.0000
mutual_information	0.6000	0.6410	0.8182	-0.0801	-0.0769
rfe	0.5863	0.5769	0.6667	-0.0938	-0.1410
top10	0.5851	0.6667	0.2121	-0.0950	-0.0513
top160	0.5964	0.5684	0.2121	-0.0837	-0.1496

가장 눈에 띄는 확인 결과는:


1. **Activity-only direct CatBoost**가 AUC **0.8854**, Macro Recall **0.8974**로 reference보다 크게 높았다.
2. Sleep-only는 AUC **0.6475**.
3. **add_collection_context**는 reference와 결과가 동일했다.

4. **context_only** 자체도 어느 정도 분류 신호가 있었지만 최종 champion은 context feature를 하나도 사용하지 않았다.
5. 단일 CatBoost reference에서 MI/RFE를 바꾼 것만으로는 성능이 좋아지지 않았다.
다만 이후 **binary DEM branch + 다른 모델 family**에서는 RFE가 최종 선택되었다. 따라서 이 ablation을 “RFE 자체가 항상 나쁘다”고 일반화하면 안 된다.

8. V3 검색 단계별 흐름과 결과

V3의 핵심은 한 번에 최종 ensemble을 만든 것이 아니라, 아래 단계로 성능을 쌓았다는 점이다.

Stage	Macro ROC-AUC	Macro Recall	Macro F1	Accuracy	Log loss
direct_3class	0.8854	0.8974	0.7362	0.7576	0.5948
hierarchy	0.9396	0.9615	0.8887	0.9091	0.5224
score_transform	0.9665	0.9615	0.8887	0.9091	0.8420
soft_vote	0.9759	0.9872	0.9564	0.9697	1.0940
offset_refinement	0.9759	0.9872	0.9564	0.9697	1.0940



8.1 Stage 1 - Direct 3-class

최고 direct recipe는 다음 candidate였다.

```

candidate: 374d8386b083439217854d34
task: flat
family: CatBoost
view: activity
top_k: 40
selection: ANOVA
transform: Robust
balance: 1.0
augmentation: none

```

결과:

- Macro AUC **0.8854**

- Macro Recall **0.8974**
- Accuracy **0.7576**
- CN Recall **0.6923**
- MCI Recall **1.0000**
- DEM Recall **1.0000**

즉 direct 3-class에서도 target 0.8 기준을 지표별로 상당 부분 넘었지만, **CN hard classification이 약했다.**

8.2 Stage 2 - Hierarchy

상위 DEM branch와 CN/MCI branch를 조합하여:

```
d = DEM score
q = MCI | non-DEM score

CN  = (1-d) * (1-q)
MCI = (1-d) * q
DEM = d
```

로 3-class score를 만들었다.

최고 hierarchy:

- Macro AUC **0.9396**
- Macro Recall **0.9615**
- Accuracy **0.9091**

Direct 대비 큰 상승이다.

8.3 Stage 3 - Score transform

Branch score에 temperature와 bias를 적용한다.

Binary branch:

```
score' = sigmoid(logit(score) / temperature + bias)
```

Flat recipe는 class log-score에 temperature와 bias를 적용 후 normalization.

총 **2,500회**의 score-transform recipe를 평가했다.

최고:

- Macro AUC **0.9665**
- Macro Recall **0.9615**
- Accuracy **0.9091**

즉 이 단계에서는 주로 **ranking/AUC가 개선되었다.**

8.4 Stage 4 - Soft vote ensemble

상위 score recipe 중 사용 base candidate 조합이 동일한 중복을 제거한 후 pool을 만들고, 2~4개 recipe를 무작위로 선택하여 global voting weight를 탐색했다.

두 종류 weight:

- 모든 class에 같은 member weight
- CN/MCI/DEM마다 다른 class-wise member weight

총 **1,200회**.

최고:

- Macro AUC **0.9759**
- Macro Recall **0.9872**
- Accuracy **0.9697**

8.5 Stage 5 - Global decision offset refinement

초기 grid offset뿐 아니라 score breakpoint를 이용해 전역 class offset을 더 세밀하게 탐색했다.

실제 refinement 기록: **83개** top recipe.

최종 metric은 soft-vote 최고점과 동일하게 유지되었다.

9. V3 최종 champion의 정확한 구성

9.1 Component 1: Hierarchy 1 - DEM

```
{
  "task": "dem",
  "family": "rbf_ridge",
  "representation": "subject",
  "view": "activity",
  "top_k": 20,
  "selection": "rfe",
  "transform": "quantile",
  "correlation": 1.0,
  "pca": 0,
  "balance": 0.0,
  "augmentation": "smote",
  "pooling": "mean",
  "seed": 2026,
  "params": {
    "alpha": 0.0018005071512845635,
    "gamma": 0.0013102849275700784
  }
}
```

Validation branch AUC:

0.988889

9.2 Component 2: Hierarchy 1 - CN/MCI

```
{
  "task": "cn_mci",
  "family": "lda",
  "representation": "subject",
  "view": "compact",
  "top_k": "all",
  "selection": "anova",
  "transform": "signedlog",
  "correlation": 1.0,
  "pca": 0,
  "balance": 0.0,
  "augmentation": "smote",
  "pooling": "mean",
  "seed": 2026,
  "params": {
    "shrinkage": 0.6
  }
}
```

Validation branch AUC:

0.913462

9.3 Component 3: Hierarchy 2 - DEM

```
{
  "task": "dem",
  "family": "rbf_ridge",
  "representation": "subject",
  "view": "activity",
  "top_k": 80,
  "selection": "rfe",
  "transform": "standard",
  "correlation": 0.9,
  "pca": 15,
  "balance": 0.0,
  "augmentation": "none",
  "pooling": "mean",
  "seed": 2026,
  "params": {
    "alpha": 0.0032694843050759623,
    "gamma": 1.022142354651346e-05
  }
}
```

Validation branch AUC:

0.988889

9.4 Component 4: Hierarchy 2 - CN/MCI

```
{
  "task": "cn_mci",
  "family": "logreg",
  "representation": "subject",
  "view": "compact",
  "top_k": "all",
  "selection": "anova",
  "transform": "standard",
  "correlation": 1.0,
  "pca": 30,
  "balance": 0.0,
  "augmentation": "none",
  "pooling": "mean",
  "seed": 2026,
  "params": {
    "C": 35.618578485685894
  }
}
```

Validation branch AUC:

0.894231

10. 최종 score 결합 방식

10.1 두 hierarchy의 branch calibration

Hierarchy 1:

```
DEM temperature    = 0.383138
DEM bias           = -0.757257
CN/MCI temperature = 1.649773
CN/MCI bias        = +0.608185
```

Hierarchy 2:

```
DEM temperature    = 2.530861
DEM bias           = +0.626597
CN/MCI temperature = 1.853388
CN/MCI bias        = +1.249311
```

10.2 Class-wise ensemble weight

최종 두 hierarchy의 weight는 class마다 다르다.

Class	Hierarchy 1	Hierarchy 2
CN	0.635606	0.364394
MCI	0.306284	0.693716
DEM	0.334973	0.665027

따라서:

- CN score에는 H1 비중이 더 큼
- MCI/DEM score에는 H2 비중이 더 큼

그 뒤 3개 class score를 다시 normalization한다.

10.3 Final decision offset

최종 hard decision:

```
argmax(
    log(score_CN) + 0.000000,
    log(score_MCI) - 0.765276,
    log(score_DEM) - 0.337140
)
```

이다.

11. V3 score를 확률로 해석하면 안 되는 이유

최종 V3의:

- Macro AUC: **0.9759**
- Accuracy: **0.9697**

는 매우 높지만,

- Log loss: **1.0940**

이다.

3-class uniform score [1/3, 1/3, 1/3]의 log loss는 계산상:

1.0986

이다.

또 저장된 score를 offset 없이 단순 argmax하면 재계산 결과:

- Accuracy: **0.2727**
- Macro Recall: **0.5940**
- Confusion matrix: CN의 26명 중 23명이 raw argmax상 MCI 쪽

최종 offset을 적용하면서 **23명**의 class decision이 바뀌고 Accuracy가 0.9697이 된다.

이 사실은 다음을 의미한다.

- AUC가 높다는 것은 class score의 **ranking 정보가 강함**을 보여준다.
- 높은 최종 Accuracy/Recall에는 **Validation에서 선택된 global offsets**가 큰 역할을 한다.
- score는 임상적으로 calibration된 disease probability로 해석하지 않는다.
- V3 코드와 결과 보고서도 score를 임상 위험 확률이라고 주장하지 않는다.

이 부분은 최종 발표나 논문에서 반드시 명확히 구분해야 한다.

12. V3 최종 성능

Metric	결과
Macro ROC-AUC	0.975938
Macro Recall	0.987179
Macro F1	0.956427
Accuracy	0.969697
Log loss	1.094045

Class별:

Class	Recall	OVR AUC	N
CN	0.9615	0.9451	26
MCI	1.0000	0.9828	4
DEM	1.0000	1.0000	3

중요 제한: MCI 4명, DEM 3명으로 Validation minority class 수가 매우 적다.

따라서 1명의 변화가 recall을 크게 바꾼다.

13. Feature Importance 분석의 재현성 확인

SHAP 전용 노트북은 기존 V3 런타임 변수 없이 standalone으로 champion을 다시 읽었다.

실행 환경:

```
numpy      2.5.3 = V3 manifest
pandas     3.0.6 = V3 manifest
scipy      1.18.1 = V3 manifest
scikit-learn 1.9.1 = V3 manifest
catboost   1.2.10 = V3 manifest
joblib     1.6.0 = V3 manifest
SHAP       0.52.0
```

Champion 재현 검증:

```
max |reproduced score - saved score|
= 8.326672684688674e-17

predicted label match rate
= 1.0
```

즉 feature-importance 분석은 다른 모델을 다시 만든 것이 아니라 **저장된 V3 champion**과 수치적으로 동일한 **score**를 설명한다.

최종 component가 사용하는 unique raw engineered feature:

95개

Collection-context feature:

0개

14. Permutation Importance

14.1 방법

최종 ensemble 전체를 그대로 둔 상태에서 feature 하나를 Validation 33명 사이에서 섞는다.

각 feature마다 **50회** 반복한다.

기준:

```
importance = baseline Macro AUC
             - feature permutation 후 Macro AUC
```

따라서 값이 클수록 해당 feature를 망가뜨렸을 때 최종 ranking 성능이 많이 떨어진다.

Baseline:


```
CN AUC    = 0.945055
MCI AUC    = 0.982759
DEM AUC    = 1.000000
Macro      = 0.975938
```

14.2 Top 15

의미	Raw feature	Macro AUC 감소 (mean±SD)	CN AUC 감 소	MCI AUC 감 소	DEM AUC 감 소
저강도 활동 연속 지속시간의 개인 내 최대값	v3__activity__state_code_3_longest_minutes__maximum	0.0991 ± 0.0378	0.1666	0.0333	0.0973
활동상태 전환율의 7일 단기 변동성 (STV7)	v3__activity__state_transition_rate__stv7	0.0926 ± 0.0390	0.0671	0.1619	0.0487
활동상태 전환율의	v3__activity__state_transition_rate__rolling_range7	0.0808 ± 0.0444	0.1026	0.0722	0.0676

의미	Raw feature	Macro AUC 감소 (mean±SD)	CN AUC 감 소	MCI AUC 감 소	DEM AUC 감 소
7일 rolling range 평 균					
저강도 활 동 최대 연 속시간의 기간 내 범 위	v3__activity__state_code_3_longest_minutes__range	0.0641 ± 0.0237	-0.0033	0.1788	0.0169
야간 HR- drop ratio의 일간 표준 편차	v3__sleep__paper_hr_drop_ratio__std	0.0591 ± 0.0257	0.0580	0.1191	0.0000
취침 시각 규칙성	sleep__bedtime_regularity	0.0562 ± 0.0330	0.0499	0.1188	0.0000
저강도 활 동시간의 일간 표준 편차	v3__activity__low__std	0.0549 ± 0.0234	0.0534	0.1112	0.0000
저강도 활 동 최대 연 속시간의 7일 rolling range	v3__activity__state_code_3_longest_minutes__rolling_range7	0.0466 ± 0.0258	-0.0060	0.1362	0.0096
일일 걸음 수의 일간 표준편차	v3__activity__steps__std	0.0458 ± 0.0347	0.0563	0.0736	0.0076
휴식시간 의 기간 내 범위	v3__activity__rest__range	0.0443 ± 0.0275	-0.0045	0.1267	0.0107
시간대별 활동 프로 파일 안정 성	activity__hourly_profile_stability	0.0366 ± 0.0225	0.0347	0.0752	0.0000
비활동시 간의 일간 표준편차	v3__activity__inactive__std	0.0326 ± 0.0179	0.0256	0.0722	0.0000
야간 HR- drop(5% 기준) ratio의 MAD	v3__sleep__paper_hr_drop05_ratio__mad	0.0271 ± 0.0253	0.0187	0.0626	0.0000
야간 HR- drop ratio의 7 일 rolling CV	v3__sleep__paper_hr_drop_ratio__rolling_cv7	0.0220 ± 0.0226	0.0148	0.0507	0.0004

의미	Raw feature	Macro AUC 감소 (mean±SD)	CN AUC 감 소	MCI AUC 감 소	DEM AUC 감 소
저강도 활 동시간의 28일 rolling range	v3__activity__low__rolling_range28	0.0189 ± 0.0174	0.0302	0.0017	0.0247



14.3 Permutation 결과의 핵심

상위권은 크게 세 종류다.

A. 활동 상태의 시간 구조

- 저강도 활동이 한 번에 얼마나 오래 이어지는가
- 활동 state가 얼마나 자주 전환되는가
- 그 전환 패턴이 7일 구간마다 얼마나 변하는가
- 휴식 지속시간이 날짜마다 얼마나 변하는가

B. 활동량의 일간 변동

- low activity SD

- steps SD
- inactive SD

C. 수면·야간 심박 패턴

- HR-drop ratio SD
- HR-drop rolling CV7
- bedtime regularity
- HR-drop05 MAD
- sleep RMSSD CV

상위 10개 기준 Permutation과 Final SHAP의 공통 feature는 **7/10**개다.

즉 서로 다른 두 해석 방법이 핵심 feature의 상당 부분에서 일치했다.

15. Final 3-class SHAP

15.1 무엇을 SHAP으로 설명했는가

최종 hard decision은 score argmax가 아니므로, SHAP도 단순 class score가 아닌 실제 decision input을 설명했다.

각 class의 설명 대상:

```
D_CN = log(score_CN) + offset_CN
D_MCI = log(score_MCI) + offset_MCI
D_DEM = log(score_DEM) + offset_DEM
```

따라서 SHAP 부호는:

- CN SHAP > 0 → CN decision score 증가
- MCI SHAP > 0 → MCI decision score 증가
- DEM SHAP > 0 → DEM decision score 증가

를 뜻한다.

SHAP 값을 “질병 확률 몇 % 증가”로 읽으면 안 된다.

15.2 SHAP 실행 설정


```
Explainer algorithm      = permutation
Final features           = 95
Validation subjects      = 33 전원
Background               = Training에서 최대 80명
seed                     = 2026
max_evals / subject     = 191
SHAP result shape       = (33, 95, 3)
```

15.3 Final SHAP Top 15


의미	Raw feature	Macro mean SHAP	CN	MCI	DEM
활동상태 전환 율의 7일 rolling range 평균	v3__activity__state_transition_rate__rolling_range7	0.0952	0.1312	0.0444	0.1099
저강도 활동 연 속 지속시간의 개인 내 최대값	v3__activity__state_code_3_longest_minutes__maximum	0.0878	0.1375	0.0406	0.0853

의미	Raw feature	Macro mean SHAP	CN	MCI	DEM
활동상태 전환 율의 7일 단기 변동성(STV7)	v3__activity__state_transition_rate__stv7	0.0864	0.1228	0.0407	0.0959
일일 걸음 수의 일간 표준편차	v3__activity__steps__std	0.0447	0.0834	0.0461	0.0046
야간 HR-drop ratio의 일간 표 준편차	v3__sleep__paper_hr_drop_ratio__std	0.0335	0.0629	0.0361	0.0014
취침 시각 규칙 성	sleep__bedtime_regularity	0.0330	0.0603	0.0373	0.0014
야간 HR-drop ratio의 7일 rolling CV	v3__sleep__paper_hr_drop_ratio__rolling_cv7	0.0326	0.0626	0.0335	0.0017
저강도 활동시 간의 일간 표준 편차	v3__activity__low__std	0.0284	0.0550	0.0290	0.0012
시간대별 활동 프로파일 안정 성	activity__hourly_profile_stability	0.0259	0.0481	0.0263	0.0032
저강도 활동시 간의 28일 rolling range	v3__activity__low__rolling_range28	0.0234	0.0350	0.0104	0.0247
야간 HR- drop(5% 기 준) ratio의 MAD	v3__sleep__paper_hr_drop05_ratio__mad	0.0227	0.0411	0.0246	0.0025
취침 시각(정오 기준 unwrap) 의 일간 표준편 차	v3__sleep__paper_bedtime_noon_unwrapped__std	0.0208	0.0338	0.0234	0.0052
비활동시간의 일간 표준편차	v3__activity__inactive__std	0.0202	0.0385	0.0214	0.0006
활동상태 전환 율의 일간 표준 편차	v3__activity__state_transition_rate__std	0.0188	0.0259	0.0095	0.0209
수면 RMSSD 의 일간 변동계 수(CV)	v3__sleep__rmssd__cv	0.0175	0.0323	0.0185	0.0016


CN



MCI



DEM



16. Branch SHAP: DEM vs non-DEM

최종 model이 hierarchy이므로 clinical/model interpretation은 최종 class SHAP뿐 아니라 branch별로도 분리했다.

DEM branch의 positive output은:

P-like score(DEM)

이며 각 hierarchy의 temperature/bias 적용 후 score를 설명했다.

16.1 DEM branch consensus Top 15

두 hierarchy의 `mean(|SHAP|)`를 component 내부에서 정규화한 뒤 최종 DEM ensemble weight로 결합한 summary:

의미	Raw feature	Consensus importance
활동상태 전환율의 7일 rolling range 평균	v3__activity__state_transition_rate__rolling_range7	0.0952
활동상태 전환율의 7일 단기변동성 (STV7)	v3__activity__state_transition_rate__stv7	0.0741
저강도 활동 연속 지속시간의 개인 내 최대값	v3__activity__state_code_3_longest_minutes__maximum	0.0656
저강도 활동시간의 28일 rolling range	v3__activity__low__rolling_range28	0.0288
저강도 활동 최대 연속시간의 기간 내 범위	v3__activity__state_code_3_longest_minutes__range	0.0287
일별 MET 하위 10% 지표의 개인 내 최대값	v3__activity__met_p10__maximum	0.0258
비활동 비율의 개인 내 최빈값	v3__activity__inactive_fraction__mode	0.0252
MET cosinor phase-sin의 왜도	v3__activity__met_cosinor_phase_sin__skew	0.0238
MET cosinor phase-cos의 4구간 분산	v3__activity__met_cosinor_phase_cos__bin_variance4	0.0235
MET cosinor phase-cos의 5% 분위값	v3__activity__met_cosinor_phase_cos__q05	0.0230
휴식 상태 최대 연속시간의 중앙값 (V3)	v3__activity__state_code_1_longest_minutes__median	0.0228
활동상태 전환율의 일간 표준편차	v3__activity__state_transition_rate__std	0.0228
미착용 상태 최대 연속시간의 4구간 변화량	v3__activity__state_code_0_longest_minutes__bin_change4	0.0225
휴식 상태 최대 연속시간의 중앙값 (V2)	activity__state_code_1_longest_minutes__median	0.0203
주야간 MET 차이의 첨도	v3__activity__met_day_night_difference__kurtosis	0.0200

16.2 방향성: 두 DEM 모델이 같은 방향인지 확인

아래 방향은 **Validation 33명**에서 **raw feature value**와 해당 **branch SHAP 값**의 상관 부호를 비교한 것이다. 임상적 인과관계가 아니라 현재 두 **component**가 실제로 어느 방향으로 **score**를 밀었는지를 요약한다.


Feature	Hierarchy 1	Hierarchy 2	방향 일치
활동상태 전환율의 7일 rolling range 평균	값↑ → DEM score↓	값↑ → DEM score↓	일치
활동상태 전환율의 7일 단기변동성(STV7)	값↑ → DEM score↑	값↑ → DEM score↓	불일치
저강도 활동 연속 지속시간의 개인 내 최대값	값↑ → DEM score↓	값↑ → DEM score↓	일치
저강도 활동시간의 28일 rolling range	값↑ → DEM score↓	값↑ → DEM score↓	일치
저강도 활동 최대 연속시간의 기간 내 범위	값↑ → DEM score↑	값↑ → DEM score↓	불일치
휴식 상태 최대 연속시간의 중앙값(V3)	값↑ → DEM score↑	값↑ → DEM score↑	일치
휴식시간의 기간 내 범위	값↑ → DEM score↑	값↑ → DEM score↑	일치

확인 가능한 중요한 점:


- `state_transition_rate rolling_range7`은 두 DEM branch 모두에서 값이 높을수록 **DEM score**를 낮추는 방향.
- `low-intensity longest maximum`도 두 branch 모두에서 값이 높을수록 **DEM score**를 낮추는 방향.

- **low rolling_range28**도 두 branch에서 같은 감소 방향.
- **rest longest median, rest range**는 두 branch에서 값이 높을수록 **DEM score**를 높이는 방향.
- 반면 **state_transition_rate STV7**처럼 두 component의 방향이 일치하지 않는 feature도 있다. 이런 변수는 한 방향의 임상적 결론으로 요약하지 않는다.

Hierarchy 1 DEM SHAP



Hierarchy 2 DEM SHAP



17. Branch SHAP: MCI vs CN

CN/MCI branch는 DEM을 제외한 Validation 30명(CN 26 + MCI 4)을 설명한다.

두 최종 component는 서로 다른 모델이다.

- H1: LDA + SMOTE
- H2: Logistic Regression

하지만 둘 다 같은 사전정의 compact 15-feature view를 사용한다.

중요: 두 알고리즘이 독립적으로 동일한 15개 feature를 feature selection으로 찾아낸 것이 아니다.

compact view 자체가 코드에 15개 feature로 정의되어 있고 top_k='all'로 모두 사용한다.

17.1 CN/MCI consensus Top 15

의미	Raw feature	Consensus importance
취침 시각 규칙성	sleep__bedtime_regularity	0.1184
야간 HR-drop ratio의 일간 표준편차	v3__sleep__paper_hr_drop_ratio__std	0.1133
일일 걸음 수의 일간 표준편차	v3__activity__steps__std	0.1108
야간 HR-drop ratio의 7일 rolling CV	v3__sleep__paper_hr_drop_ratio__rolling_cv7	0.0859
야간 HR-drop(5% 기준) ratio의 MAD	v3__sleep__paper_hr_drop05_ratio__mad	0.0849
취침 시각(정오 기준 unwrap)의 일간 표준편차	v3__sleep__paper_bedtime_noon_unwrapped__std	0.0848
저강도 활동시간의 일간 표준편차	v3__activity__low__std	0.0788
시간대별 활동 프로파일 안정성	activity__hourly_profile_stability	0.0714
비활동시간의 일간 표준편차	v3__activity__inactive__std	0.0642
수면 RMSSD의 일간 변동계수(CV)	v3__sleep__rmssd__cv	0.0544
기상 시각의 일간 표준편차	v3__sleep__paper_wake_hour__std	0.0450
기상 시각 규칙성	sleep__wake_regularity	0.0386
총 수면시간의 7일 단기변동성(STV7)	v3__sleep__total__stv7	0.0378
휴식시간의 개인 내 평균	v3__activity__rest__mean	0.0064
수면효율의 일간 MAD	v3__sleep__efficiency__mad	0.0054

17.2 MCI 방향성의 component 간 일치

Feature	LDA branch	Logistic branch	방향 일치
일일 걸음 수의 일간 표준편차	값↑ → MCI score↑	값↑ → MCI score↑	일치
시간대별 활동 프로파일 안정성	값↑ → MCI score↑	값↑ → MCI score↑	일치
야간 HR-drop ratio의 7일 rolling CV	값↑ → MCI score↑	값↑ → MCI score↑	일치
취침 시각 규칙성	값↑ → MCI score↑	값↑ → MCI score↑	일치
야간 HR-drop ratio의 일간 표준편차	값↑ → MCI score↑	값↑ → MCI score↑	일치
취침 시각(정오 기준 unwrap)의 일간 표준편차	값↑ → MCI score↑	값↑ → MCI score↑	일치
총 수면시간의 7일 단기변동성(STV7)	값↑ → MCI score↑	값↑ → MCI score↑	일치
수면 RMSSD의 일간 변동계수(CV)	값↑ → MCI score↓(CN 방향)	값↑ → MCI score↓(CN 방향)	일치
저강도 활동시간의 일간 표준편차	값↑ → MCI score↓(CN 방향)	값↑ → MCI score↓(CN 방향)	일치
비활동시간의 일간 표준편차	값↑ → MCI score↓(CN 방향)	값↑ → MCI score↓(CN 방향)	일치
야간 HR-drop(5% 기준) ratio의 MAD	값↑ → MCI score↓(CN 방향)	값↑ → MCI score↓(CN 방향)	일치
기상 시각의 일간 표준편차	값↑ → MCI score↓(CN 방향)	값↑ → MCI score↓(CN 방향)	일치

두 모델에서 방향이 같은 주요 패턴:

값 증가가 MCI score 증가 방향

- 걸음 수 일간 SD
- 시간대별 활동 profile stability
- HR-drop ratio rolling CV7
- bedtime regularity
- HR-drop ratio std
- 취침시각 std
- sleep total STV7


값 증가가 MCI score 감소(CN 방향)

- low activity std
- inactive std
- sleep RMSSD CV
- HR-drop05 MAD
- wake-hour std


이 결과는 현재 모델과 현재 **Validation sample**의 방향이다.

예를 들어 **bedtime_regularity** ↑ → **MCI score** ↑를 곧바로 "MCI 환자는 임상적으로 더 규칙적으로 잔다"는 일반화된 사실로 바꾸어 쓰지 않는다.

Hierarchy 1 MCI/CN SHAP



Hierarchy 2 MCI/CN SHAP



18. Feature Importance에서 직접 말할 수 있는 최종 메시지

현재 결과만으로 안전하게 말할 수 있는 범위는 다음과 같다.

18.1 DEM 구분

최종 DEM branch는 **activity-only** 모델 두 개로 구성되어 있다.

중요도가 높은 feature는 주로:

- 활동 상태 전환 패턴
- 저강도 활동의 연속 지속 패턴
- 휴식 지속시간
- MET의 시간대/일주기 관련 변화
- 저강도 활동량의 rolling variability

다.

따라서 모델 수준의 표현:

DEM vs non-DEM 구분에서 단순 총 활동량뿐 아니라 활동 상태의 전환·지속·시간적 변동 구조가 중요한 예측 신호로 사용되었다.

18.2 CN vs MCI 구분

CN/MCI branch는 다음을 함께 사용한다.

- Activity variability
- Sleep timing regularity
- HR-drop variability
- RMSSD variability
- Sleep-duration short-term variability

따라서 모델 수준의 표현:

CN vs MCI 구분에서는 활동량의 일간 변동과 함께 취침/기상 리듬, 야간 심박 감소 패턴, HRV 계열의 시간적 특징이 중요한 예측 신호로 사용되었다.

18.3 전체 3-class 관점

Permutation과 final SHAP 모두에서 매우 상위에 반복된 신호:

1. 활동 state transition의 7일 변동
2. 저강도 활동의 최대 연속 지속시간
3. 걸음/low/inactive의 일간 변동
4. HR-drop variability
5. bedtime regularity

즉 최종 champion의 주요 정보는 단순한 "평균 활동량/평균 수면시간" 하나보다는 **생활 패턴의 시간적 구조와 변동성** 쪽에 많이 분포한다.

이 문장은 현재 feature 중요도 결과가 직접 뒷받침한다.
다만 이것을 임상 biomarker로 확정하려면 별도 독립 cohort 및 임상 문헌 검증이 필요하며, 그 검증은 본 실험 결과 자체에는 포함되지 않는다.

19. 실험 전체 논리 사슬

아래 표가 V2 → V3의 흐름을 가장 간단히 보여준다.

단계	핵심 질문	구현	실제 결과	다음 단계로 이어진 이유
V2 기본/ablation	어떤 representation/view/model이 나은가?	27개 사전 ablation + 5-fold subject OOF	activity 모델 등이 상대적으로 우수	다양한 모델을 Optuna/ensemble로 확대
V2 Optuna + ensemble	Training OOF에서 AUC/recall을 함께 개선 가능한가?	80 trials, diverse ensemble, offsets, 3 seeds	Dev OOF AUC 0.6047 / recall 0.5689	선택편향을 배제하기 위해 Nested 평가
V2 Nested CV	선택 과정을 모르는 사람에서 일반화되는가?	outer 5 / inner 3, nested trials 20	AUC 0.5431 / recall 0.4418	엄격 조건에서 목표 미달 확인
V2 Validation	선택을 고정한 모델이 기존 Validation에서 어떤가?	Validation을 V2 선택에 사용하지 않음	AUC 0.6136 / recall 0.4466	MCI 분리가 특히 약함
목표 변경	Nested 일반화 추정보다 subject split + No MMSE + 높은 3-class 결과에 집중	fixed original split	-	V3 설계
V3 feature 확장	평균값 이외 temporal variability에 신호가 있는가?	1,333 → 5,144 features	activity-only direct AUC 0.8854	branch-specific modeling 진행
V3 direct 3-class	한 모델로 3-class가 가능한가?	Activity CatBoost top40	AUC 0.8854 / recall 0.8974	CN hard decision 개선 필요
V3 hierarchy	DEM 경계와 CN/MCI 경계를 따로 학습하면?	DEM binary + CN/MCI binary	AUC 0.9396 / recall 0.9615	score 조정으로 ranking 개선
V3 score transform	branch score scale/bias를 조정하면?	temperature + bias 2,500 trials	AUC 0.9665	상호보완 recipe 결합
V3 soft vote	여러 hierarchy를 class별로 결합하면?	1,200 voting searches	AUC 0.9759 / recall 0.9872	최종 decision rule 확정

단계	핵심 질문	구현	실제 결과	다음 단계로 이어진 이유
Offset refinement	hard classification을 global rule로 개선 가능한가?	2개 global class offset	Accuracy 0.9697	champion freeze
Permutation + SHAP	champion이 무엇을 사용했는가?	95-feature permutation + final/branch SHAP	activity temporal structure + sleep/HR variability	임상 문헌 검증 단계로 연결 가능

20. 구현 안전장치와 재현성

20.1 Manifest

V2/V3 모두 다음을 manifest에 저장한다.

- config
- source SHA256
- package versions
- input data SHA256
- feature extraction config

같은 output directory에서 code/data/config가 달라지면 실행을 거부한다.

20.2 Candidate cache

V3는 각 candidate의:

- spec JSON
- Validation score NPZ
- selected feature
- augmentation audit

를 저장한다.

같은 candidate를 다시 요청하면 cache를 사용한다.

20.3 최종 champion 재학습 확인

V3 search가 끝난 후 final recipe에 필요한 component만 Training 전체로 다시 fit한다.

그 뒤:

```

새로 fit한 component prediction
vs
search 중 저장했던 component prediction

```

이 `np.allclose()`로 재현되지 않으면 champion claim을 저장하지 않는다.

20.4 SHAP에서도 재현 확인

SHAP 노트북은 champion score가 기존 `selection_predictions.csv`와 최대 오차 `8.33e-17`, label 100% 일치일 때만 진행했다.

20.5 Run lock

V3는 같은 `output_dir`을 두 process/kernel이 동시에 수정하지 못하도록 `.run.lock`을 사용한다.

21. 현재 결과에서 반드시 함께 보고해야 할 제한점

21.1 V3 Validation은 독립 test가 아니다

가장 중요한 제한이다.

같은 33명의 Validation label이 다음에 사용됐다.

- candidate hyperparameter 선택
- branch 조합 선택
- score temperature/bias 선택
- ensemble member 선택
- class-wise voting weight 선택
- global decision offset 선택

따라서 **AUC 0.9759**를 미사용 외부 cohort의 일반화 성능으로 표현하지 않는다.

정확한 표현:

fixed subject-disjoint selection-validation performance

21.2 탐색량이 많다

- candidate 475개
- score transform 2,500
- soft vote 1,200
- hierarchy 100
- direct recipe 20
- offset refinement 83 기록

따라서 Selection Validation의 최대값에는 선택 낙관성이 존재할 수 있다.

21.3 MCI/DEM Validation 표본이 작다

- MCI 4명
- DEM 3명

따라서 class recall은 한 명에 매우 민감하다.

21.4 score calibration이 약하다

Final log loss 1.094는 uniform 3-class log loss 1.0986과 가깝다.

따라서 score를 disease probability로 읽지 않는다.

21.5 SHAP도 같은 Selection Validation을 설명한다

SHAP은 champion의 동작을 충실히 설명하지만, 이 feature importance가 새로운 cohort에서도 동일하다는 것을 증명하지는 않는다.

21.6 상관된 engineered feature

최종 95개에는 비슷한 signal에서 파생된:

- std
- STV
- rolling range
- CV
- MAD
- range

가 함께 존재한다.

따라서 importance가 서로 분산되거나 permutation 시 상관구조가 깨질 수 있다.

이를 보완하기 위해 본 분석에서는 Permutation Importance와 SHAP을 함께 확인했고, 상위 10개 중 **7개**가 겹쳤다.

22. 최종 연구 메시지

현재 실험을 한 문단으로 요약하면 다음과 같다.

본 프로젝트는 먼저 V2에서 MMSE를 제외하고 피험자 단위 분할 및 Nested CV를 적용하여 CN/MCI/DEM 3-class 일반화 성능을 평가하였다. 그러나 Nested outer OOF에서 Macro ROC-AUC 0.5431, Macro Recall 0.4418로 목표 성능에 도달하지 못했으며 특히 MCI 분리가 어려웠다. 이후 연구 목표를 피험자 단위 독립성과 No-MMSE 조건은 유지하되 고정된 Training/Validation 환경에서 3-class 분류 성능을 최대화하고 그 모델의 feature importance를 해석하는 방향으로 수정하였다. V3에서는 V2 feature 1,333개에 calendar-day 기반 temporal variability 및 HR-drop 관련 feature를 추가하여 총 5,144개 후보를 구성하고, direct 3-class, DEM-vs-rest, CN-vs-MCI 모델 bank와 score transformation, hierarchical combination, class-wise soft voting 및 global decision offset을 순차 탐색하였다. 최종 모델은 두 hierarchical classifier의 ensemble이며 Selection Validation에서 Macro ROC-AUC 0.9759, Macro Recall 0.9872, Accuracy 0.9697을 기록하였다. Permutation Importance와 SHAP 분석에서는 DEM 구분에 활동 상태 전환 및 저장도 활동의 지속·변동 구조가, CN/MCI 구분에는 활동 변동성과 함께 취침 규칙성, 야간 HR-drop 및 RMSSD 관련 시간적 특징이 중요한 모델 신호로 확인되었다. 단, V3 Validation은 모델 선택에 재사용되었으므로 이 성능과 feature importance는 독립 외부 일반화 결과가 아니라 현재 champion의 selection-validation 성능과 동작 해석으로 한정하여 보고해야 한다.

부록 A. CN/MCI compact 15 features

최종 두 CN/MCI branch가 모두 사용하는 사전정의 feature set이다.

1. `v3_sleep_paper_hr_drop_ratio_rolling_cv7` - 야간 HR-drop ratio의 7일 rolling CV
2. `v3_activity_inactive_std` - 비활동시간의 일간 표준편차
3. `v3_activity_low_std` - 저장도 활동시간의 일간 표준편차
4. `activity_hourly_profile_stability` - 시간대별 활동 프로파일 안정성
5. `v3_sleep_paper_hr_drop_ratio_std` - 야간 HR-drop ratio의 일간 표준편차
6. `v3_activity_steps_std` - 일일 걸음 수의 일간 표준편차
7. `sleep_bedtime_regularity` - 취침 시각 규칙성
8. `v3_sleep_rmssd_cv` - 수면 RMSSD의 일간 변동계수(CV)
9. `v3_sleep_paper_bedtime_noon_unwrapped_std` - 취침 시각(정오 기준 unwrap)의 일간 표준편차
10. `v3_sleep_paper_wake_hour_std` - 기상 시각의 일간 표준편차
11. `v3_sleep_paper_hr_drop05_ratio_mad` - 야간 HR-drop(5% 기준) ratio의 MAD
12. `v3_sleep_total_stv7` - 총 수면시간의 7일 단기변동성(STV7)
13. `sleep_wake_regularity` - 기상 시각 규칙성
14. `v3_sleep_efficiency_mad` - 수면효율의 일간 MAD
15. `v3_activity_rest_mean` - 휴식시간의 개인 내 평균

부록 B. Hierarchy 1 DEM의 20개 core features

Hierarchy 1 DEM RBF ridge가 RFE로 선택한 20개다.

이 20개는 Hierarchy 2 DEM의 80개 feature 집합에도 모두 포함된다.

1. `v3_activity_met_p10_maximum` - 일별 MET 하위 10% 지표의 개인 내 최대값
2. `activity_met_p10_p90` - `activity_met_p10_p90`
3. `v3_activity_met_p10_q95` - `v3_activity_met_p10_q95`
4. `v3_activity_state_transition_rate_rolling_range7` - 활동상태 전환율의 7일 rolling range 평균
5. `v3_activity_low_rolling_range14` - `v3_activity_low_rolling_range14`
6. `v3_activity_low_rolling_range28` - 저장도 활동시간의 28일 rolling range
7. `v3_activity_state_transition_rate_rolling_range14` - `v3_activity_state_transition_rate_rolling_range14`
8. `v3_activity_met_day_night_difference_kurtosis` - 주야간 MET 차이의 첨도
9. `v3_activity_met_cosinor_phase_cos_bin_variance4` - MET cosinor phase-cos의 4구간 분산
10. `v3_activity_state_code_3_longest_minutes_rolling_range7` - 저장도 활동 최대 연속시간의 7일 rolling range
11. `activity_state_code_1_longest_minutes_median` - 휴식 상태 최대 연속시간의 중앙값(V2)
12. `v3_activity_state_code_1_longest_minutes_median` - 휴식 상태 최대 연속시간의 중앙값(V3)
13. `v3_activity_state_transition_rate_stv7` - 활동상태 전환율의 7일 단기변동성(STV7)
14. `v3_activity_met_cosinor_phase_cos_q05` - MET cosinor phase-cos의 5% 분위값
15. `v3_activity_state_code_3_longest_minutes_maximum` - 저장도 활동 연속 지속시간의 개인 내 최대값
16. `v3_activity_rest_range` - 휴식시간의 기간 내 범위
17. `activity_state_transition_rate_extra_std` - `activity_state_transition_rate_extra_std`
18. `v3_activity_state_code_3_longest_minutes_range` - 저장도 활동 최대 연속시간의 기간 내 범위
19. `v3_activity_state_transition_rate_std` - 활동상태 전환율의 일간 표준편차

20. `v3__activity__score_training_volume__lag1` - Training-volume score의 일간 lag-1 상관

부록 C. Hierarchy 2 DEM의 80개 features

▶ 80개 전체 펼치기

부록 D. 주요 산출물 위치

V2

- `results_v2/run_full/RESULTS.md`
- `results_v2/run_full/summary.json`
- `results_v2/run_full/manifest.json`
- `results_v2/run_full/development/ablation.csv`
- `results_v2/run_full/development/search_results.csv`
- `results_v2/run_full/development/selected.json`
- `results_v2/run_full/nested/outer_oof_predictions.csv`
- `results_v2/run_full/nested/outer_metrics.csv`
- `results_v2/run_full/nested/bootstrap_ci.csv`
- `results_v2/run_full/validation_predictions.csv`
- `results_v2/run_full/validation_bootstrap_ci.csv`

V3

- `results_v3/run_full/RESULTS.md`
- `results_v3/run_full/summary.json`
- `results_v3/run_full/manifest.json`
- `results_v3/run_full/candidate_selection_scores.csv`
- `results_v3/run_full/controlled_ablations.csv`
- `results_v3/run_full/recipe_selection_scores.csv`
- `results_v3/run_full/best_by_search_stage.csv`
- `results_v3/run_full/selected_recipe.json`
- `results_v3/run_full/champion_selection_only.joblib`
- `results_v3/run_full/selection_predictions.csv`

Feature importance / SHAP

- `results_v3/run_full/shap_analysis/final_ensemble_permutation_importance.csv`
 - `results_v3/run_full/shap_analysis/final_decision_shap_global.csv`
 - `results_v3/run_full/shap_analysis/branch_consensus_DEM_vs_nonDEM.csv`
 - `results_v3/run_full/shap_analysis/branch_consensus_MCI_vs_CN.csv`
 - `results_v3/run_full/shap_analysis/*_beeswarm.png`
 - `results_v3/run_full/shap_analysis/local_waterfall_*.png`
-

부록 E. 본 보고서 작성에 사용한 근거

본 보고서는 다음 업로드 자료를 대조하여 작성했다.

1. `lifelog_v2.zip`
2. `V2 run_full`
3. `lifelog_v3.zip`
4. `V3 run_full`
5. `CN_MCI_DEM_PerformanceSearch_NoMMSE_v3.ipynb`
6. `V3_SHAP_Feature_Importance(1).ipynb`
7. `shap_analysis.zip`
8. 현재 Activity / Sleep / Label CSV

9. AI-Hub 치매 고위험군 웨어러블 데이터 구축 가이드라인

10. AI-Hub 치매 고위험군 라이프로그 테크니컬 리포트

외부 논문을 새로 검색하여 임상 기전을 보충하지 않았다.

따라서 임상적 관계에 대한 문장은 **현재 모델이 사용한 feature와 SHAP 방향** 범위까지만 서술하였다.