



저작자표시-비영리-동일조건변경허락 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.
- 이차적 저작물을 작성할 수 있습니다.

다음과 같은 조건을 따라야 합니다:



저작자표시. 귀하는 원저작자를 표시하여야 합니다.



비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.



동일조건변경허락. 귀하가 이 저작물을 개작, 변형 또는 가공했을 경우에는, 이 저작물과 동일한 이용허락조건하에서만 배포할 수 있습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 [이용허락규약\(Legal Code\)](#)을 이해하기 쉽게 요약한 것입니다.

[Disclaimer](#)

석 사 학 위 논 문

웨어러블 기기 라이프로그를
활용한 치매 진단 예측 머신러닝
모델 비교

고려대학교 SW·AI융합대학원

빅데이터융합학과

임 형 준

2025년 8월

김현철 교 수 지 도
석 사 학 위 논 문

웨어러블 기기 라이프로그를
활용한 치매 진단 예측 머신러닝
모델 비교

이 논문을 공학 석사학위 논문으로 제출함

2025년 4월

고려대학교 SW·AI융합대학원

빅데이터융합학과

임 형 준 (인)



임형준의 공학 석사학위논문 심사를 완료함

2025년 5월

위원장	김현철	(인)
-----	-----	-----

위 원	서태원	(인)
-----	-----	-----

위 원	유헌창	(인)
-----	-----	-----



웨어러블 기기 라이프로그를 활용한 치매 진단 예측 머신러닝 모델 비교

임 형 준

빅 데이터 융합 학과

지도교수: 김 현 철

초록

대한민국의 급속한 고령화에 대비하여, 본 연구는 정확하고 비침습적인 치매 선별 도구를 개발하고 이를 검증하는 것을 목표로 한다. 이를 위해 다섯 가지 머신러닝 모델을 비교·평가하였다. 대상 환자로부터 웨어러블 기기를 통해 수집한 수면 및 보행 패턴 등의 시계열 데이터와 인지 검사 결과를 기반으로, LSTM, Bi-LSTM, Random Forest, XGBoost, 1D-CNN 모델들로 치매 예측 실험을 실시했다. 정확도(Accuracy), ROC-AUC, F1-score 등을 기준으로 성능을 평가한 결과, 1D-CNN이 78.8%의 정확도, 81.0%의 AUC, 0.63의 F1-score로 가장 우수한 성능을 보였다. 라이프로그 데이터와 인지 기능 검사 변수를 함께 적용한 로지스틱 회귀 분석에서는 수면 중 호흡률, 수면 중 뒤척임, 즉각 회상 능력이 유의미한 예측 변수로 나타났다. 이러한 결과는 머신러닝 기반 모델이 치매의 조기 및 지속적 위험 모니터링을 지원하고, 환자 맞춤형 중재 전략을 수립하는데 기여할 수 있음을 시사한다.

주제어: 치매예측모델, 머신러닝, 웨어러블 디바이스



Comparison of Machine Learning Models for Predicting Dementia Diagnosis Using Wearable Device Lifelog Data

by Hyungjun Lim

Department of Big Data Convergence

under the supervision of Professor Hyunchul Kim

Abstract

In response to rapid population aging in South Korea, this study aims to develop and validate an accurate, non-invasive dementia screening tool by comparing and evaluating five machine learning models. We collected wearable device lifelog time-series data—including sleep and gait patterns—and cognitive test results from target patients, then preprocessed these inputs for LSTM, bi-LSTM, Random Forest, XGBoost, and 1D-CNN classifiers. Performance was assessed by accuracy, ROC-AUC, and F1-score; the 1D-CNN outperformed the others with 78.8% accuracy, 81.0% AUC, and a 0.63 F1-score. Logistic regression applied to combined lifelog and cognitive variables identified sleep breathing rate, sleep movement rate, and immediate recall ability as significant predictors. These findings suggest that machine learning models can support early and continuous dementia risk monitoring and inform tailored intervention strategies.

Keywords : Dementia Prediction Models, Machine Learning, Wearable Devices.



목차

초록	i
Abstract	ii
목차	iii
표 목차	iv
그림 목차	v
1. 서론	1
2. 연구 배경	3
2.1 치매 현황	3
2.2 AI 기술 도입의 필요성	4
2.3 기존 연구 성과	5
2.4 웨어러블 기기 활용 치매 연구 성과	6
3. 실험 및 결과	7
3.1 데이터셋 개요	7
3.2 데이터 전처리 과정	14
3.3 학습 모델 설계 및 평가	18
3.3.1 Random Forest & XGBoost	19
3.3.2 LSTM & bi-LSTM & 1D-CNN	21
3.4 로지스틱 회귀분석 설계 및 평가	23
4. 결론 및 한계	26
참고문헌	30




표 목차

표 1. 걸음걸이 & 수면 로그 데이터셋 요약 I	8
표 2. 걸음걸이 & 수면 로그 데이터셋 요약 II	9
표 3. 걸음걸이 & 수면 로그 데이터셋 요약 III	10
표 4. 걸음걸이 & 수면 로그 데이터셋 요약 IV	11
표 5. 간이정신상태검사(K-MMSE) 데이터셋 요약 I	11
표 6. 간이정신상태검사(K-MMSE) 데이터셋 요약 II	12
표 7. 간이정신상태검사(K-MMSE) 데이터셋 요약 III	13
표 8. 간이정신상태검사(K-MMSE) 데이터셋 요약 IV	14
표 9. 전처리 후 사용된 데이터 변수 I	15
표 10. 전처리 후 사용된 데이터 변수 II	16
표 11. 전처리 후 사용된 데이터 변수 III	17
표 12. 전처리 Python 코드 일부 - 변수 평탄화(flatten)	18
표 13. 랜덤포레스트 & XGBoost 성능 비교	20
표 14. LSTM & bi-LSTM & 1D-CNN 성능 비교	22
표 15. 간이정신상태검사(K-MMSE) 단변량 로지스틱 회귀분석 평가 결과	24
표 16. 라이프로그 로지스틱 회귀분석 평가 결과(Wald 검정)	24
표 17. 머신러닝 모델 성능 비교 I	26
표 18. 머신러닝 모델 성능 비교 II	26



그림 목차

그림 1. 랜덤포레스트 & XGBoost 성능 비교	20
그림 2. LSTM & bi-LSTM & 1D-CNN 성능 비교	22
그림 3. training 데이터셋의 분포(불균형)	27



1. 서론

대한민국은 세계에서 가장 빠른 속도로 고령화가 진행되고 있으며, 65세 이상 인구 비율이 2025년까지 20%를 넘어설 것으로 예상된다. 이로 인해 치매 환자 수가 급증하여 의료비용뿐 아니라 요양·돌봄 등 사회적 비용이 2030년 약 272억 달러, 2050년 832억 달러에 달할 것으로 전망된다[1]. 특히 치매는 인지기능 저하뿐 아니라 가족 돌봄 부담과 생산성 손실을 동반하여 국가 보건·복지 시스템에 중대한 도전 과제를 제기한다[2].

그런 흐름 속에서 최근 웨어러블 기기를 이용한 라이프로그 데이터가 일상생활 속에서 환자의 건강 상태를 비침습적으로 모니터링할 수 있는 유망한 수단으로 주목받고 있다[3]. 가속도 센서와 심박수 센서 등을 통해 수집된 걸음걸이·수면 패턴·활동량 등의 정보는 전통적 임상 검사에서 얻기 어려운 연속적·실시간 특징을 제공하고 치매 발병 전후의 미세 변화를 포착할 수 있다. 특히, 시계열 데이터를 처리할 수 있는 딥러닝 기반 모델은 복잡한 패턴 인식에 강점을 지니고 있어 헬스케어 영역에서 활발히 연구되고 있다.

LSTM, bi-LSTM, 1D-CNN 등 딥러닝 기반 시계열 분석 모델은 연속적 패턴을 자동 추출하여 높은 예측 성능을 입증했으며[4] Random Forest 및 XGBoost 같은 전통적 머신러닝 기법도 다변량 센서 데이터를 효과적으로 활용해 왔다[5].

하지만 치매 예측을 위해 웨어러블 기반 라이프로그 시계열 데이터를 5가지 이상의 모델로 비교·평가한 연구는 상대적으로 부족하다. 또한, 모델의 예측 성능뿐 아니라 중요 변수를 해석하고자 하는 노력도 제한적이었다.

이에 본 연구에서는 고위험군 치매 환자의 시계열 데이터를 활용하여, Random Forest, XGBoost, LSTM, Bi-LSTM, 1D-CNN의 총 5가지 서로 다른



머신러닝 모델을 학습·비교하였다. 더 나아가, 최적 성능을 보인 1D-CNN 모델을 최종 치매 분류기로 채택, 인지기능 검사 결과와 라이프로그 변수 간의 상관관계 분석을 위해 로지스틱 회귀분석을 수행하였다.

이를 통해 치매 진단 예측에 기여하는 주요 인지 검사 문항과 수면·활동 지표를 선별함으로써, 머신러닝 모델의 예측 결과 해석을 쉽게 하고 임상적 활용성을 제고하고자 한다는 점에서 의의가 있다.



2. 연구 배경

2.1 치매 현황

대한민국은 빠른 인구 고령화로 인해 치매가 주요 공중보건 문제로 대두되고 있다. 65세 이상 인구를 대상으로 한 메타분석 연구에서는 치매 유병률이 9.2% (95% CI 8.2-10.4%)로 보고되어, 노인 열 명 중 한 명이 치매를 경험하는 것으로 추정된다[6]. 국민건강보험공단 청구자료 기반 연구에서는 2020년 기준 치매 유병률을 10.25%로 산정하여 약 83만 명의 환자가 존재하는 것으로 나타났다[6].

임상 진단 기록을 분석한 연구에 따르면, 2008년부터 2016년 사이 치매 진료율은 인구 1,000명당 31.3명에서 72.2명으로 두 배 이상 증가하였으며, 이는 의료 접근성 향상과 함께 실제 치매 환자 수가 급격히 늘어났음을 시사한다.[7] 또한, 2005-2007년 연령표준화 치매 발생률은 인구 십만 명당 273.2명이었으나, 2009-2011년에는 576.0명으로 증가하였고 이 중 약 5%가 조기 발병형 치매로 확인되었다[7].

치매가 개인과 사회에 미치는 경제적 부담도 상당하다. 국내 연구에서는 2019년 기준 치매 환자 1인당 의료비용이 평균 미화 6,957달러에 달하며, 총 건강-경제적 비용은 약 미화 420만 달러로 추정되었다[2]. 이같이 막대한 비용은 환자 개인은 물론 가족과 국가 재정에도 중대한 영향을 미치며, 효과적인 예방 및 관리 전략 마련의 중요성을 강조한다.

세계적으로도 치매 환자 수는 빠르게 증가하고 있다. GBD 2019 연구에서는 전 세계 치매 환자가 5,740만명 (95% UI 50.4-65.1)에 이르렀으며, 2050년에는 1억 5,000만명 (130.8-175.9)으로 예상하였다[8].



한국 내 치매 유형 분포의 변화도 주목할 만하다. 알츠하이머형 치매(AD) 대비 혈관성 치매(VaD)의 비율은 1990년대 약 1.96에서 2010년대 약 4.13으로 AD 환자의 비중이 크게 증가하였다[9].

이러한 상황에서 2008년 ‘치매 국가책임제’ 선포 이후 우리나라는 제5차 치매관리종합계획(2026-2030)을 통해 조기진단 확대, 예방·관리 서비스 강화, 지역사회 돌봄시스템 구축 등에 주력하고 있다[10]. 본 연구에서는 이와 같은 국내외 치매 현황 및 정책 배경을 바탕으로, 웨어러블 기기 기반 라이프로그 데이터를 활용한 치매 예측 모델 개발의 필요성을 논의하고자 한다.

2.2 AI 기술 도입의 필요성

치매 진단 및 예측에는 기존에 설문조사, 임상 검사, 영상진단 등 전통적 방법이 사용되었으나, 이러한 방법은 정기적인 병원 방문과 고비용, 제한된 시간대 모니터링 등의 제약이 있다. 반면, 웨어러블 기기를 통한 라이프로그 데이터는 일상생활에서 연속적으로 수집되는 대규모 시계열 정보로, 환자의 행동 및 생리적 변화를 실시간으로 반영할 수 있다는 장점을 가진다.

방대한 데이터의 패턴을 효율적으로 분석하기 위해서는 고차원 특징을 추출하고 비선형 관계를 모델링할 수 있는 인공지능 기술이 필수적이다. 특히, 머신러닝 기반의 자동화된 진단 시스템은 임상 위험 점수 대비 향상된 예측력을 보여주었으며 다양한 데이터 mortality(생체 신호, 활동량, 수면 패턴 등)를 종합하여 분석할 수 있다[5].

딥러닝 모델은 시계열 데이터 처리에 강점을 보이며, 1D-CNN 및 순환신경망(RNN) 계열 모델은 연속적 패턴 인식에 우수하다. 실제로 스마트 헬스케어 기반 분류 모델 연구에서는 웨어러블 센서에서 얻은 활동 및 생리 데이터를 활용하여 조기 치매 분류에 성공한 사례가 보고되었다[11]. 또한, 개인별 맞춤형 머신러닝 접근법은 개인 간 변이성을 고려해 행동 및 심리 증상을 감지하는 데 유용함이 확인되었다[12].



이처럼 AI 기술은 대규모 라이프로그 데이터의 효율적 처리 및 해석을 가능하게 하며, 치매 조기진단 및 지속적 모니터링에 새로운 가능성을 제시한다. 본 연구에서는 이러한 AI 기반 분석 기법을 적용하여 치매 예측 모델의 성능을 평가하고, 임상 활용 방안을 모색하고자 한다.

2.3 기존 연구 성과

동일한 데이터로 진행한 기존 연구[13]에서는 웨어러블 장치로 수집된 수면 및 활동 시계열 데이터를 참가자별로 변수의 평균값으로 평탄화(flattening)하여, 랜덤포레스트(Random Forest) 모델을 학습시켰다. 이를 통해 데이터 차원을 효율적으로 축소하고 ROC-AUC 0.98의 높은 성능을 보고하였으나, 과적합(overfitting)의 가능성이 있다는 점과 이 방식을 통해 시간 의존성(time dependency)과 시계열 고유의 패턴이 상실된다는 한계가 있다[5]. 실제로 시간별 변동, 주기적 패턴, 이상치 등은 평균값으로 대표하기 어려워, 입력 변수가 본래의 시계열 특성을 반영하지 못하면 랜덤포레스트를 포함한 통계적·기계학습 모델의 예측력 역시 제약을 받는다[12].

또한, 평균값 평탄화 방식은 시계열 딥러닝 모델이 포착할 수 있는 시점 간 상호작용과 순차적 특징(sequential features)을 제거하므로, 실제 임상 맥락에서 발생하는 미묘하고 복잡한 걸음걸이 및 수면 패턴의 변화를 감지하는 데 어려움이 많다[11].

본 연구에서는 이러한 단점을 보완하기 위해 시계열 데이터의 시간적 정보를 온전히 활용할 수 있는 LSTM, Bi-LSTM, 1D-CNN과 같은 딥러닝 모델을 적용하였다. 더불어, 랜덤포레스트와 XGBoost 모델도 평균값으로 동일한 평탄화된 변수로 학습해 비교하였고 이 결과, 통계적 유의성이 크게 낮아지며 시계열 딥러닝 모델 대비 예측 성능에서 열위를 보였다. 이를 통해, 시계열 데이터의 대표성을 확보하는 것이 치매 예측 모델 성능 개선에 필수적임을 확인하였다.



2.4 웨어러블 기기 활용 치매 연구 성과

비침습적 웨어러블 센서 데이터를 활용한 머신러닝 기법은 전통적 임상 위험 점수 기반 모델보다 치매 예측 정확도를 유의미하게 향상시키는 것으로 보고되고 있다[14]. 특히 랜덤 포레스트(Random Forest)와 XGBoost 모델은 심박수, 가속도계, 수면 효율 등 다변량 센서 특성을 효과적으로 학습하여 치매 분류 성능을 개선하는 데 널리 사용되고 있다[15].

1차원 합성곱신경망(1D-CNN)과 순환신경망(LSTM, bi-LSTM) 등 시계열 데이터에 특화된 딥러닝 모델은 수면 라이프로그, 활동 패턴으로부터 자동으로 특징을 추출하여 높은 예측 성능을 달성했다[16].

예를 들어, CNN-LSTM 하이브리드 구조는 가속도계 기반 활동 인식뿐 아니라 인지 저하 예측에도 효과적임이 입증되었다[16]. 통계적 특징 선택 기법(F-score)을 통해 유의미한 변수만 선별한 뒤, 이를 기반으로 다수의 머신러닝 모델을 앙상블한 하이브리드 시스템이 높은 분류 정확도를 보였다[15]. 특히 F-score로 추출한 변수에 의사결정나무, 로지스틱 회귀, 랜덤 포레스트 등을 결합한 투표(voting) 앙상블 방식은 과적합을 완화하면서도 안정적인 예측 성능을 제시했다[17].



3. 실험 및 결과

3.1 데이터셋 개요

웨어러블 헬스케어 기기 데이터를 이용한 치매 여부를 예측하는 모델 구축을 위해 AI 허브(aihub.or.kr)의 ‘치매 고위험군 웨어러블 라이프로그’ 데이터를 사용했다. ㈜에코인사이트글로벌이 주관하여 치매 조기진단 예측 및 발병의 예방과 선제적 관리를 위한 AI 기술 개발을 위하여 검증된 학습용 데이터를 구축하기 위해 제공된 이 데이터는 2020년도에 5.7만의 데이터를 모아 가공한 뒤 2025년 3월 7일에 최종 수정 배포됐으며 전문의가 직접 병리진단을 하여 익명화된 55세 이상의 정상인지군(CN), 전조증상을 보이는(MCI) 환자군 및 치매(Dem) 증상을 보이는 60~80대 174명을 대상으로 총 12,184개의 라이프로그 데이터를 수집, 정리하였다. 또한 간이정신상태검사(K-MMSE) 데이터를 통해 인지기능(기억력, 언어기능, 시공간 능력, 전두엽 기능, 주의 집중력, 정서 상태 등)의 상태를 알 수 있는 질문들과 환자들의 고위험군 해당 여부를 라벨링했다.

이 데이터는 반지 형태의 데일리 수면/활동 데이터 수집기를 통해 착용자의 수면 데이터(수면 시작/종료시간, 수면 점수, 수면 방해, 수면 효율, 램수면 시간, 수면의 깊이 등)와 활동 데이터(활동 시작/종료 시간, 운동 시간, 활동 점수, 신진대사량, 회복 시간, 움직인 거리, 칼로리 소모량 등)을 5분 단위로 수집하여 활동->수면->활동과 같이 사람의 기본적인 삶의 패턴을 24시간 동안 라이프 로그를 모니터링할 수 있게 했다.

데이터는 크게 Activity, Sleep, MMSE 3개로 나뉘었으며, email(MMSE의 경우, SAMPLE_EMAIL) 변수를 환자의 고유 ID로 간주하고 수집됐다<표 1~8>.



표 1. 걸음걸이 & 수면 로그 데이터셋 요약 I

NO	항목		타입
	영문명	한글 설명	
1	email	이메일	varchar(200)
2	date	요약 날짜	varchar(10)
3	check	착용 여부 체크	varchar(20)
4	nonwear	미착용 시간 체크	varchar(20)
5	activity_average_met	하루간 평균 MET (대사적 작업 당량)	varchar(10)
6	activity_cal_active	하루간 활동 칼로리	varchar(10)
7	activity_cal_total	하루간 총 사용 칼로리	varchar(10)
8	activity_class_5min	하루간 5분당 활동 로그	BLOB (Binary Large Object)
9	activity_daily_movement	매일 움직인 거리	varchar(10)
10	activity_day_end	활동 종료 시간	varchar(30)
11	activity_day_start	활동 시작 시간	varchar(30)
12	activity_high	고강도 활동 시간	varchar(10)
13	activity_inactive	비활동 시간	varchar(10)
14	activity_inactivity_alerts	비활동 알람 횟수	varchar(10)
15	active_low	저강도 활동 시간	varchar(10)
16	activity_medium	중강도 활동 시간	varchar(10)
17	activity_met_1min	하루간 1분 당 MET 로그	BLOB
18	activity_met_min_high	하루간 고강도 활동 MET	varchar(10)
19	activity_met_min_inactive	하루간 비활동 MET	varchar(10)
20	activity_met_min_low	하루간 저강도 활동 MET	varchar(10)



표 2. 걸음걸이 & 수면 로그 데이터셋 요약Ⅱ

NO	항목		타입
	영문명	한글 설명	
21	activity_met_min_medium	하루간 중강도 활동 MET	varchar(10)
22	activity_non_wear	미착용 시간	varchar(10)
23	activity_rest	휴식 시간	varchar(10)
24	activity_score	활동 점수	varchar(10)
25	activity_score_meet_daily_targets	활동 목표달성 점수	varchar(10)
26	activity_score_move_every_hour	매 시간 당 활동유지 점수	varchar(10)
27	activity_score_recovery_time	회복시간 점수	varchar(10)
28	activity_score_stay_active	활동 유지 점수	varchar(10)
29	activity_score_training_frequency	운동 빈도 점수	varchar(10)
30	activity_score_training_volume	운동 빈도 점수	varchar(10)
31	activity_steps	매일 걸음 수	varchar(10)
32	activity_total	활동 총 시간(분)	varchar(10)
33	sleep_awake	깨 시간	varchar(10)
34	sleep_bedtime_end	잠 종료시간	varchar(30)
35	sleep_bedtime_start	잠 시작시간	varchar(30)
36	sleep_breath_average	분단 평균 호흡 수	varchar(10)
37	sleep_deep	깊은 수면 시간	varchar(10)
38	sleep_duration	잠 시간	varchar(10)
39	sleep_efficiency	수면 효율	varchar(10)
40	sleep_hr_5min	5분 당 심박동 로그	BLOB



표 3. 걸음걸이 & 수면 로그 데이터셋 요약III

NO	항목		타입
	영문명	한글 설명	
41	sleep_hr_average	분당 평균 심박동 수	varchar(10)
42	sleep_hr_lowest	분당 낮은 심박동 수	varchar(10)
43	sleep_hypnogram_5min	수면 상태 로그	BLOB
44	sleep_is_longest	본 수면 여부	varchar(10)
45	sleep_light	가벼운 수면 시간	varchar(10)
46	sleep_midpoint_at_delta	수면 중간점 시간 델타	varchar(10)
47	sleep_midpoint_time	수면 중간점 시간	varchar(10)
48	sleep_onset_latency	수면 잠복 시간	varchar(10)
49	sleep_period_id	수면 식별 아이디	varchar(10)
50	sleep_rem	렘수면 시간	varchar(10)
51	sleep_restless	뒤척임 비율	varchar(10)
52	sleep_rmssd	평균 심박동변동	varchar(10)
53	sleep_rmssd_5min	5분 당 심박동변동 로그	BLOB
54	sleep_score	수면 종합 점수	varchar(10)
55	sleep_score_alignment	수면 시기 점수	varchar(10)
56	sleep_score_deep	깊은 수면 점수	varchar(10)
57	sleep_score_disturbances	수면 방해 점수	varchar(10)
58	sleep_score_efficiency	수면 효율 점수	varchar(10)
59	sleep_score_latency	수면 잠복 점수	varchar(10)
60	sleep_score_rem	렘수면 점수	varchar(10)



표 4. 걸음걸이 & 수면 로그 데이터셋 요약IV

NO	항목		타입
	영문명	한글 설명	
61	sleep_score_total	수면 시간 기여 점수	varchar(10)
62	sleep_temperature_delta	피부 온도 편차	varchar(10)
63	sleep_temperature_deviation	피부 온도 편차	varchar(10)
64	sleep_temperature_trend_deviation	피부 온도 경향 편차	varchar(10)
65	timezone	시간 장소 정보	varchar(10)
66	sleep_total	수면 시간	varchar(10)

표 5. 간이정신상태검사(K-MMSE) 데이터셋 요약 I

NO	항목	comment	타입
1	SAMPLE_EMAIL	연구대상자 이메일	VARCHAR(200)
2	DIAG_SEQ	차수	INT(3)
3	DIAG_NIM	진단명	VARCHAR(30)
4	MMSE_KIND	친절도	VARCHAR(10)



표 6. 간이정신상태검사(K-MMSE) 데이터셋 요약Ⅱ

NO	항목	comment	타입
5	Q01	올해가 몇 년 이지요?	정답/오답 : 2 / 1
6	Q02	지금은 어떤 계절이지요?	정답/오답 : 2 / 1
7	Q03	오늘은 며칠입니까?	정답/오답 : 2 / 1
8	Q04	오늘은 무슨 요일인가요?	정답/오답 : 2 / 1
9	Q05	오늘이 몇 월입니까?	정답/오답 : 2 / 1
10	Q06	지금 우리가 있는 이곳은 어느 나라입니까?	정답/오답 : 2 / 1
11	Q07	우리가 지금 무슨 시(도)에 있습니까?	정답/오답 : 2 / 1
12	Q08	지금 우리가 있는 여기는 어디입니까?	정답/오답 : 2 / 1
13	Q09	지금 우리가 있는 이곳은 몇 층입니까?	정답/오답 : 2 / 1
14	Q10	여기에서는 어떤 일을 하나요?	정답/오답 : 2 / 1
자, 잘 들으세요. 제가 지금부터 물건 이름 세 개를 불러드리겠습니다.			
15	Q11_1	지금 불러드린 그 물건 이름들을 잘 기억하고 계세요. 제가 조금 있다가 다시 외워보시라고 할겁니다. 비행기(1초간 멈춤)	정답/오답 : 2 / 1
16	Q11_2	연필(1초간 멈춤)	정답/오답 : 2 / 1
17	Q11_3	소나무	정답/오답 : 2 / 1



표 7. 간이정신상태검사(K-MMSE) 데이터셋 요약III

NO	항목	comment	타입
18	Q12_1	100에서 7을 빼면 얼마가 됩니까?	정답/오답 : 2 / 1
19	Q12_2	거기에서 7을 빼면 얼마가 됩니까?	정답/오답 : 2 / 1
20	Q12_3	거기에서 7을 빼면 얼마가 됩니까?	정답/오답 : 2 / 1
21	Q12_4	거기에서 7을 빼면 얼마나 됩니까?	정답/오답 : 2 / 1
22	Q12_5	거기에서 7을 빼면 얼마가 됩니까?	정답/오답 : 2 / 1
23	Q12_TOTAL	12번 질문 total 점수	정답/오답 : 2 / 1
24	Q13_1	좀 전에 제가 외우고 계시라고 했던 물건 이름 세 가지 기억하세요? 비행기	정답/오답 : 2 / 1
25	Q13_2	연필	정답/오답 : 2 / 1
26	Q13_3	소나무	정답/오답 : 2 / 1
27	Q14_1	이것이 무엇입니까?(시계)	정답/오답 : 2 / 1
28	Q14_2	이것이 무엇입니까?	정답/오답 : 2 / 1
29	Q15	이번에는 제가 하는 말을 그대로 따라서 말씀하시면 됩니다. (백문일 불여일건)	정답/오답 : 2 / 1
30	Q16_1	종이 뒤집기	정답/오답 : 2 / 1
31	Q16_2	반으로 접기	정답/오답 : 2 / 1
32	Q16_3	되돌려 주기	정답/오답 : 2 / 1



표 8. 간이정신상태검사(K-MMSE) 데이터셋 요약IV

NO	항목	comment	타입
33	Q17	이 그림과 똑같이 여기에 그려주세요. (별지의 오각형 그림)	정답/오답 : 2 / 1
34	Q18	지금 보여 드리는 이 문장을 큰 소리로 읽으시고 쓰인 대로 해보세요.	정답/오답 : 2 / 1
35	Q19	여기에 오늘 날씨(또는 기분)에 대해서 문장으로 써보세요.	정답/오답 : 2 / 1
36	TOTAL	검사 답변의 총점	INT

3.2 데이터 전처리 과정

먼저 활동 기록과 수면 기록, 인지기능검사 데이터셋에서 치매 여부를 알 수 있는 DIAG_NIM 열을 email 기준으로 병합했다. 정상군(CN), 전조증상을 보이는(MCI), 완전 치매임을 뜻하는(dem)으로 분류됐지만 대부분의 치매가 퇴행성 치매임을 감안해 전조증상 또한 치매로 가정하고 DIAG_NIM 열을 이진형 변수(완전 정상군은 0, 치매 전조증상 이상은 1)로 바꿔 구성했다.

데이터 전처리 과정에서 머신러닝 학습을 시작하기 전에 웨어러블 미착용 시간, 미착용 알람 횟수, 미착용 시간 체크 등 분석 목적에 맞지 않는 변수는 제외했다. 그리하여 총 58개의 변수가 학습에 사용됐다.<표 9~11>

최종 표본 수는 총 174명의 12,184행의 라이프로그 데이터이며 이 중 63명이 치매 환자로 분류됐다.

로지스틱 회귀분석에 사용된 인지기능 검사데이터는 활동과 수면 기록 분석과는 독립적으로 Q1 ~ Q19 질문과 DIAG_NIM(치매 여부 라벨링)만으로 구성했다.



표 9. 전처리 후 사용된 데이터 변수 I

NO	항목		값 예시
	영문명	한글 설명	
1	email	이메일	nia+003@rowan.kr
2	activity_average_met	하루간 평균 MET (대사적 작업 당량)	1.262897
3	activity_cal_active	하루간 활동 칼로리	202.5714
4	activity_cal_total	하루간 총 사용 칼로리	2208.3333
5	activity_class_5min	하루간 5분당 활동 로그	3659.73
6	activity_daily_movement	매일 움직인 거리	3659.73
7	activity_high	고강도 활동 시간	0.793651
8	active_low	저강도 활동 시간	201
9	activity_medium	중강도 활동 시간	18.33333
10	activity_met_min_high	하루간 고강도 활동 MET	5.984127
11	activity_met_min_inactive	하루간 비활동 MET	6.190476
12	activity_met_min_low	하루간 저강도 활동 MET	94.96825
13	activity_met_min_medium	하루간 중강도 활동 MET	59.19048
14	activity_rest	휴식 시간	618.0635
15	activity_score	활동 점수	58.68254
16	activity_score_meet_daily_targets	활동 목표달성 점수	18.79365
17	activity_score_move_every_hour	매 시간 당 활동유지 점수	92.49206
18	activity_score_recovery_time	회복시간 점수	99.69841
19	activity_score_stay_active	활동 유지 점수	66.26984
20	activity_score_training_frequency	운동 빈도 점수	21.68254




표 10. 전처리 후 사용된 데이터 변수Ⅱ

NO	항목		값 예시
	영문명	한글 설명	
21	activity_score_training_volume	운동 빈도 점수	53.03175
22	activity_steps	매일 걸음 수	4518.46
23	activity_inactive	비활동 시간	615.1429
24	activity_total	활동 총 시간(분)	165.5556
25	sleep_awake	깨 시간	8700
26	sleep_bedtime_end	잠 종료시간	2020-10-19T05:10:28+09:00
27	sleep_bedtime_start	잠 시작시간	2020-10-18T18:38:28+09
28	sleep_breath_average	분당 평균 호흡 수	17.875
29	sleep_deep	깊은 수면 시간	10110
30	sleep_duration	잠 시간	37920
31	sleep_efficiency	수면 효율	77
32	sleep_hr_5min	5분 당 심박동 로그	63/61/59/58/
33	sleep_hr_average	분당 평균 심박동 수	53.04
34	sleep_hr_lowest	분당 낮은 심박동 수	49
35	sleep_hypnogram_5min	수면 상태 로그	4/2/2/2/2/1/1/2/2
36	sleep_is_longest	본 수면 여부	1
37	sleep_light	가벼운 수면 시간	15330
38	sleep_midpoint_at_delta	수면 중간점 시간 델타	84928
39	sleep_midpoint_time	수면 중간점 시간	17820
40	sleep_onset_latency	수면 잠복 시간	630



표 11. 전처리 후 사용된 데이터 변수Ⅲ

NO	항목		값 예시
	영문명	한글 설명	
41	sleep_period_id	수면 식별 아이디	3
42	sleep_rem	렘수면 시간	3780
43	sleep_restless	뒤척임 비율	24
44	sleep_rmssd	평균 심박동변동	39
45	sleep_rmssd_5min	5분 당 심박동변동 로그	63/61/59/58/
46	sleep_score	수면 종합 점수	84
47	sleep_score_alignment	수면 시기 점수	87
48	sleep_score_deep	깊은 수면 점수	100
49	sleep_score_disturbances	수면 방해 점수	78
50	sleep_score_efficiency	수면 효율 점수	65
51	sleep_score_latency	수면 잠복 점수	89
52	sleep_score_rem	렘수면 점수	56
53	sleep_score_total	수면 시간 기여 점수	94
54	sleep_temperature_delta	피부 온도 편차	-0.77
55	sleep_temperature_deviation	피부 온도 편차	-0.14
56	sleep_temperature_trend_deviation	피부 온도 경향 편차	0.34
57	sleep_total	수면 시간	21510
58	DIAG_NIM	진단명(치매 여부)	0/1



데이터 전처리는 2가지로 진행했다. 본 연구에서는 동일한 입력 데이터를 두 가지 방식으로 전처리하여 시계열 유지 모델(LSTM 계열)과 평탄화(flattened) 기반 모델(Random Forest, XGBoost 등)의 성능을 비교하였다. 전자는 시간 순서를 유지한 채 정규화 후 3차원 텐서로 구성되었고, 후자는 각 환자의 시계열 데이터를 평균값 기반으로 요약하여 2차원 형태로 변환하였다<표 12>. 변수 선택에 있어서는 다중공선성을 제거하고 통계적 유의성과 임상적 중요성을 모두 고려하여 최종 분석 변수군을 구성하였다.

표 12. 전처리 Python 코드 일부 - 변수 평탄화(flatten)

```
#Train set 로드 및 전처리
train_act = pd.read_csv('train_activity.csv')
train_slp = pd.read_csv('train_sleep.csv')
train_mm = pd.read_csv('train_mmse.csv')
train_mm.rename(columns={'SAMPLE_EMAIL':'EMAIL'}, inplace=True)

#비시계열용 데이터 변수 flatten 평균으로
labels_tr = train_mm[['EMAIL','DIAG_NM']].drop_duplicates()
act_tr = train_act.groupby('EMAIL').mean(numeric_only=True).reset_index()
slp_tr = train_slp.groupby('EMAIL').mean(numeric_only=True).reset_index()

#영향력이 0인 변수 제거 (임상적으로 관계 없는 변수)
columns_to_drop = ['activity_non_wear', 'nonwear', 'activity_inactivity_alerts','check','timezone']
act_tr = act_tr.drop(columns=[col for col in columns_to_drop if col in act_tr.columns], errors='ignore')
slp_tr = slp_tr.drop(columns=[col for col in columns_to_drop if col in slp_tr.columns], errors='ignore')
```

3.3 학습 모델 설계 및 평가

본 절에서는 다섯 가지 모델을 설계·비교하여, 비시계열 트리 앙상블 모델의 한계 확인, 시계열 딥러닝 모델의 성능 우위 검증, 모델별 특성·재현성 비교를 목표로 한다. 이를 위해 동일한 전처리 데이터셋을 80:20 비율로 학습/검증용으로 분할하고, Accuracy, AUC, F1-score, Recall 네 가지 지표로 성능을 평가했다.



3.3.1 Random Forest & XGBoost

Random Forest는 다수의 결정 트리를 생성한 뒤, 각 트리의 예측 결과를 선택 또는 평균화하여 최종 예측을 수행하는 앙상블 학습 기법이다. 각 결정 트리는 입력 데이터의 부트스트랩 샘플(bootstrap sample)을 기반으로 학습되며, information gain을 기준으로 최적 분할 지점을 선택한다. 이 과정을 통해 개별 트리의 분산을 낮추고 과적합(overfitting)을 억제할 수 있다.

XGBoost는 gradient boosting을 기반으로 잔차(residual)를 순차적으로 학습하여 예측 성능을 향상시키는 트리 앙상블 기법이다. 각 부스팅 단계에서 이전 모델의 오차를 보정하기 위해 새로운 트리를 학습하며, 손실 함수에 대한 2차 미분 정보를 활용해 효율적인 최적화가 가능하다. 또한 L1·L2 정규화, 부분 샘플링, 조기 중단(early stopping) 등 다양한 기능을 지원하여 과적합을 방지하고 처리 속도를 개선한다.

본 연구에서는 하이퍼파라미터 튜닝 또한 실시하였는데 예측 성능을 극대화하기 위해 주요 하이퍼파라미터(트리 수, 최대 깊이, learning rate, subsample 등)에 대해 탐색적 튜닝을 수행하였다. 탐색 방법으로는 랜덤 탐색(Random Search)을 사용하였으며, 사전 정의된 하이퍼파라미터 공간 내에서 무작위로 조합을 선택하여 5-Fold Cross Validation을 통해 성능을 검증(5개의 검증 값 평균 채택)하였다. 그 결과, 다음의 하이퍼파라미터 조합에서 logloss 기준 최적의 예측 성능(AUC 및 F1-score 기준 향상 포함)을 달성하였다.

```
n_estimators=100, learning_rate=0.1, subsample=1.0, colsample_bytree=1.0,
reg_alpha=0, reg_lambda=1, use_label_encoder=False, eval_metric='logloss'.
```



표 13. 랜덤포레스트 & XGBoost 성능 비교

Model	Accuracy	AUC	F1-Score	Recall
Random Forest	0.6970	0.7225	0.5	0.7143
XGBoost	0.6970	0.6374	0.5	0.7143




그림 1. 랜덤포레스트 & XGBoost 성능 비교

Random Forest와 XGBoost 모델의 accuracy, F1-score, Recall 값이 두 모델 모두 동일했다. 이는 두 모델이 예측한 클래스가 매우 유사했음을 시사하고, AUC에서 랜덤포레스트가 살짝 높은 것을 보면 positive vs negative 클래스의 구분을 좀 더 잘하는 것으로 평가된다. 하지만, 평가 요소 네 가지 중 모두 0.7 초반을 넘기지 못하고 있다<표 13><그림 1>.



3.3.2 LSTM & bi-LSTM & XGBoost

LSTM은 순환신경망(RNN)의 일종으로, 장기 의존성(long-term dependency)을 학습하는 데 특화된 구조이다. 입력 시퀀스의 과거 정보가 긴 Time-step 뒤에도 손실 없이 전달되도록 내부에 cell state와 게이트(gate) 메커니즘을 도입한다. 일반 RNN이 vanishing gradient 문제를 겪는 반면, LSTM은 다음과 같은 세 가지 게이트를 통해 정보를 선택적으로 유지하거나 제거하여 안정적인 학습을 가능하게 한다. 이러한 구조 덕분에 LSTM은 시계열 데이터의 장기 패턴과 추세(trend)를 포착하는 데 강점을 보이며, 음성 인식, 자연어 처리뿐만 아니라 금융 시계열 예측 등 다양한 분야에 활용된다.

Bi-LSTM은 순방향(forward) LSTM과 역방향(backward) LSTM을 병렬로 구성하여, 과거뿐 아니라 미래 시점의 정보까지 동시에 학습할 수 있는 구조이다. 즉, 입력 시퀀스를 정방향으로 처리하는 LSTM과 역순으로 처리하는 LSTM의 출력을 연결(concatenate)하여 최종 표현을 만든다. 이 방식은 시점 간 상호작용(interaction)이 양방향으로 작용할 때 유용하며, 문장 레벨의 자연어 처리나 시계열 이상 탐지(anomaly detection) 등에서 성능 향상을 보여준다.

1D-CNN은 이미지용 CNN을 시계열에 적용한 형태로, 합성곱 계층(convolutional layer)을 통해 시간 축에서 연속된 부분(signal)의 특징(local patterns)을 추출한다. 주로 다음과 같은 계층으로 구성된다. 1) Conv1D 계층: 커널(kernel) 크기만큼 연속된 시점의 값을 곱셈·합산하여 feature map을 생성한다. 2) Pooling 계층: MaxPooling1D나 AveragePooling1D를 사용하여 특징 맵의 차원을 축소하고, 위치 불변성(translation invariance)을 일부 확보한다. 3) Fully Connected 계층: 최종적으로 추출된 특징을 평탄화(flatten)하여 분류기(decoder)에 전달한다.

1D-CNN은 짧은 기간 동안 발생하는 주기·이상치 패턴 감지에 효과적이며, 실시간 이벤트 분류, 생체 신호 분석, 금융 데이터 모델링 등에서 활용된다.



표 14. LSTM & bi-LSTM & 1D-CNN 성능 비교

Model	Accuracy	AUC	F1-Score	Recall
LSTM	0.818182	0.527473	0.25	0.1428
bi-LSTM	0.818182	0.390110	0.25	0.1428
1D-CNN	0.787879	0.810440	0.63	0.8571




그림 2. LSTM & bi-LSTM & 1D-CNN 성능 비교

LSTM과 bi-LSTM 모델의 경우 accuracy는 81.8%로 높은 편이었으나 recall과 F1-score가 매우 낮아 치매 환자를 거의 탐지하지 못했다. 특히 bi-LSTM은 AUC가 특히 낮아 판별력이 부족한 것으로 평가됐다. 반면, 1D-CNN의 경우 accuracy는 다른 두 모델에 비해 78.8%로 약간 낮으나 실질적으로 가장 신뢰할 수 있는 모델로 평가됐다<표 14><그림 2>.



3.4 로지스틱 회귀분석 설계 및 평가

웨어러블 헬스기기에서 측정 가능한 변수들과 치매 진단 여부 사이의 상관관계 분석과 통계적으로 유의한 변수들을 골라내기 위해 로지스틱 회귀분석을 실시했다.

로지스틱 회귀(Logistic Regression)는 통계학 및 머신러닝 분류 기법 중 하나로, 이진 또는 다항 범주형 결과를 예측하는 데 사용된다. 입력 변수의 선형 결합을 출력 확률을 0과 1 사이로 제한하는 시그모이드(sigmoid) 함수에 통과시켜 클래스 발생 확률을 출력하며, 이를 기반으로 최종 클래스 레이블을 결정한다.

또한, 수면과 활동 데이터의 세부 데이터끼리 다중공선성 문제가 자주 발생했다. 이를 방지하기 위해 완전 선형 종속성을 제거한 뒤 실시했다. 로지스틱 회귀분석 모델의 유효성 평가는 Likelihood Ratio Test의 p-value와 Pseudo R-squared를 사용했다. LLR p-value는 $3.359e-216$ 으로 모델 자체는 유효하게 나왔지만 Pseudo R-square 점수가 0.098로 모델에 대한 설명력이 약했다.

인지기능검사에서 로지스틱 회귀분석을 실시한 결과, 질문들끼리의 다중공선성이 자주 발생해 단변량 로지스틱 회귀분석을 실시하고 통계적 유의성을 정리했다<표 15~16>.

MMSE의 Q1~Q19 문항 중 다중공선성이 있는 변수들을 제거한 뒤, 단변량 로지스틱 회귀분석 결과 통계적으로 유의한 p-value(<0.001)를 가지며, AUC, F1-score, Accuracy 측면에서도 비교적 우수한 성능을 보인 Q13_3, Q13_2, Q003, Q12_5를 대표 변수로 선정하였다.

이들 변수는 각각 지남(가리켜 지시함)력, 기억력, 즉시 회상 등 기존에 연구된 치매 진단에서 핵심적인 인지 영역과 관련된 문항[18]으로, 단순히 수치적 유의성뿐만 아니라 선행 연구에서 명시된 해당 변수의 임상적 중요성도 함께 고려하여 선택하였다.




표 15. 간이정신상태검사(K-MMSE) 단변량 로지스틱 회귀분석 평가 결과

변수명	내용	상관계수	p-value	AUC	F1	정확도
Q13_3	좀 전에 제가 외우고 계시라고 했던 물건 이름 세 가지 기억나세요? (3번)	-1.519739	0.000007	0.67	0.580	0.70
Q13_2	좀 전에 제가 외우고 계시라고 했던 물건 이름 세 가지 기억나세요? (2번)	-1.456445	0.000015	0.66	0.569	0.69
Q003	오늘이 며칠인가요?	-3.110001	0.000047	0.64	0.452	0.73
Q12_5	100에서 7을 5번 빼면 얼마인가요?	-1.353319	0.0001	0.64	0.517	0.68

표 16. 라이프로그 로지스틱 회귀분석 평가 결과(Wald 검정)

변수명	내용	p-value
sleep_breath_average	분단 평균 호흡 수	0
sleep_hr_average	분당 평균 심박동 수	0
sleep_hr_lowest	분당 낮은 심박동 수	0.003
sleep_efficiency	수면 효율	0.756
sleep_midpoint_time	수면 중간점 시간	0.021
sleep_restless	뒤척임 비율	0
sleep_score_disturbances	수면 방해 점수	0.037
activity_cal_active	하루간 활동 칼로리	0
activity_cal_total	하루간 총 사용 칼로리	0
activity_daily_movement	매일 움직인 거리	0.001
activity_inactive	비활동 시간	0.006
activity_met_min_medium	하루간 중강도 활동 MET	0



먼저 간이정신상태검사 단변량 회귀분석 결과, 완전 선형 종속성을 없앤 상태에서 검사를 받는 당일의 날짜 및 장소 등을 얼마나 잘 기억하는가와 좀 전에 의사가 불러준 3개의 간단한 단어를 잘 기억하는가, 또 5번에 걸친 연속 산수 문제의 정답 여부가 치매 진단 여부에 통계적으로 유의한 것으로 나왔다. 특히 오늘의 날짜와 환자 본인이 있는 장소에 대한 인지 기능 검사 질문에 대한 반응이 느린 것이 73%의 정확도를 보이고 상관계수의 절댓값이 크게 나왔다.

라이프로그(수면 & 활동) 로지스틱 회귀분석 통계적 유의성 검정 결과와 상관계수를 동시에 해석하면 하루 간 중/저강도 활동 MET(특정 신체활동을 수행하는 동안 개인이 소모하는 에너지 비율의 측정값)을 많이 할수록, 하루에 사용한 칼로리가 높을수록 치매에 걸리지 않을 확률이 올라갔다.

반면에 종합적인 수면 효율 점수는 치매 판별에 도움이 되지 않은 것으로 나왔다. 잠에 드는 순간이 어려울수록 치매에 걸릴 위험이 올라갔으며 수면 시간의 중앙값이 낮을수록, 수면 중 적당한 범위 안의 분당 호흡수와 심박동 수 또한 치매 예측에 도움이 되는 것으로 나왔다.



4. 결론 및 한계

본 연구는 고위험 치매군의 웨어러블 라이프로그(수면·활동) 데이터를 활용하여, 비시계열 트리 앙상블 모델(Random Forest, XGBoost)과 시계열 딥러닝 모델(LSTM, bi-LSTM, 1D-CNN)을 설계·비교함으로써 다음과 같은 결론을 도출하였다<표 17~18>.

표 17. 머신러닝 모델 성능 비교 I

Model	Accuracy	AUC	F1-Score	Recall
1D-CNN	0.78	0.81	0.63	0.85
LSTM	0.81	0.52	0.25	0.14
bi-LSTM	0.81	0.39	0.25	0.14
Random Forest	0.69	0.72	0.5	0.71
XGBoost	0.69	0.63	0.5	0.71

표 18. 머신러닝 모델 성능 비교 II

Model	특징
1D-CNN	합성곱 필터를 통해 국소적인 지역 패턴 학습(급격한 변곡점)이 매우 빠르나, 장기 의존성 파악에는 부적합
LSTM	단방향 학습, 미래 시점의 정보 반영 미비 장기 의존성 파악에 적합함
bi-LSTM	양방향 학습, 미래 시점의 정보 반영 가능 장기 의존성 파악에 적합함
Random Forest	변수별 평균화 flatten
XGBoost	변수별 평균화 flatten



제시된 다섯 가지 모델의 성능을 비교해 보면 다음과 같은 특징이 드러난다. 1D-CNN은 78%의 정확도, 0.81의 AUC, 0.63의 F1-score, 0.85의 재현율을 기록하며 전체 지표에서 가장 균형 잡힌 성능을 보였다. 특히 AUC와 재현율이 모두 0.80 이상으로 높아, 양성(치매) 클래스 탐지에 강점을 지닌다. 이에 비해 LSTM 및 Bi-LSTM 모델은 높은 Accuracy(81%)를 보였음에도 불구하고, F1-score(0.25) 및 Recall(0.14)이 현저히 낮게 나타났다. 이는 클래스 불균형 문제와 시계열 데이터의 패딩 구조, 학습 시 정보 손실 등의 구조적 한계에 기인한 것으로 보인다.

특히 치매군이 전체의 36%에 불과한 상황에서, LSTM 계열 모델은 소수 클래스(치매)를 충분히 학습하지 못해 양성 클래스에 대한 민감도(Recall)가 낮아졌으며, 이로 인해 F1-score도 함께 하락하였다. 그래서 무조건적인 일반화는 주의가 필요하다. 데이터 수집을 늘리기 전까지 클래스 가중치 조정, focal loss 등의 불균형 보정 기법을 적용하거나, attention 기반 시계열 구조 도입을 통해 이러한 한계를 극복할 수 있을 것이다<그림 3>.




그림 3. training 데이터셋의 분포(불균형)



한계점을 종합하자면, 시계열 특성을 보존하면서 지역적·단기적 변동을 효과적으로 포착하는 1D-CNN이 본 데이터셋에서 최적의 성능을 보였으며, 단순 RNN 및 트리 기반 모델은 각각 다른 이유로 성능 제약을 드러냈다. 전체 174명의 환자 중 63명의 경증, 중증 치매환자로 분류된 적은 양의 데이터로 인한 과적합(Overfitting)과 시계열 데이터를 이용하기 위해 평탄화(flatten)하는 과정에서 선택한 평균값이 각 변수들의 특징을 잘 대표하지 못했고, 다중공선성의 문제가 빈번해 이를 예방하기 위해 전문의와의 협력을 통해 치매 예측에 정확히 유효한 변수를 더 정확하게 나눠 라이프로그 기기에서 더 많은 데이터를 확보하는 방법을 향후 연구까지 고수해야 한다.

LSTM과 bi-LSTM 두 모델의 성능에 비해 1D-CNN 모델의 성능이 비교적 안정적인 것은 웨어러블 라이프로그 시계열 데이터의 특성상 국소적 패턴(특정 주기 혹은 급격한 변곡점 등)이 반복되거나 데이터의 장기 의존성이 약할 때 일어 날 수 있다. 치매는 임상적으로 급격한 변곡점을 보이기보다 장기적으로 천천히 증상이 발현되는 질병임을 생각한다면 연구에 쓰인 데이터의 불균형성, 즉 장기 의존성이 약하다는 뜻이라고 해석된다. 1D-CNN 모델의 경우, 급격한 변곡점을 보이는 패턴 감지에는 우수한 성능을 보였으나, 장기적인 변화를 감지는 LSTM, bi-LSTM 등의 모델이 더 뛰어남을 이미 다른 연구에서 볼 수 있었다[16].

데이터에 사용된 변수 역시 각각의 필요성 판별에 높은 수준의 전문성을 요하며 activity_cal_active(하루간 활동 칼로리), activity_cal_total(하루간 총 사용 활동 칼로리)처럼 변수 간의 관계가 너무 큰 나머지 다중공선성의 가능성이 서로 복잡하게 얽혀있는 것이 많아, 적절한 변수 선정 작업이 사전에 전문의와 협의하여 조율할 필요성을 보인다. 본 연구에선 기초적인 수준에서의 사전적 도메인 기반 지식에 의해 변수를 제거하고 사후적 수학적 제거 방법인 완전 선형 종속성을 제거하는 방법만을 사용했으나, 더 전문적인 사전적 도메인 기반 선택이 선행된 뒤 완전 선형 종속성을 제거하는 것이 치매 예측이라는 연구 목적과 모델의 퍼포먼스에 문제가 생길 경우의 예방에 더 적합하다.



결론적으로 본 논문은 1인당 라이프로그 데이터의 수는 충분했으나, 그에 비해 비교적 적은 174명의 고위험군 환자들을 분석했다. 불균형이 많은 데이터를 활용하는 상황에서 머신러닝을 활용하는 과정에서 과적합으로 인한 예측 정확도의 예측에 특히 어려움이 많았다. 단기보다 장기적인 데이터 즉, 더 많은 환자 수와 칼로리를 소모하는 활동 및 수면에 관련된 라이프로그를 계속 추적 및 관찰하여 비침습적으로, 또 거동이 불편한 환자의 원격 지속적인 관찰을 통해 고위험군 환자의 치매 예측, 대면 진료 중 보다 더 객관적인 환자의 평소 생활 정보를 참고(ex. A환자의 저장도 활동 부족 및 수면 부족이 최근 몇 주 얼마나(%) 심화되었다 등)를 할 수 있다는 점에서 연구의 확장 방향과 임상 적용 가능성이 보인다.

고위험군 환자의 데이터가 쌓이기 전까지 1D-CNN을 활용하여 지역 패턴(peak, spike) 감지용 학습을 따로 하고 장기적인 데이터가 쌓였을 때, 다시 LSTM과 bi-LSTM 모델과 같은 다른 시계열성 모델을 결합하거나 수정, 적용하며 보완할 수 있는 시사점이 될 것이다.

78%의 accuracy를 보이지만 1D-CNN 모델로 웨어러블 기기를 이용한 시계열 데이터 분석으로 통계적 유의성을 확보할 수 있었다.

후속 연구에서 부족한 데이터의 보완과 더불어 다른 연구에서 제시되었던 다수의 하이브리드 모델(CNN+LSTM 모델, CNN+transformer 모델 등)을 본 연구에서 진행한 1D-CNN 모델과 함께 비교[17]한다면 외국뿐만 아니라 한국의 치매 고위험군 환자 예측 방법을 보다 정확히 개선, 검증시킬 것으로 예상된다.



참고문헌

[1] Kim, J. and Lee, H., "Family support and dementia screening participation among older adults: Evidence from a South Korea fact-finding survey on the status of older adults," *Aging Medicine*, Vol.7, No.6, 2024, pp.754-760.

[2] Shon, C. and Yoon, H., "Health-economic burden of dementia in South Korea," *BMC Geriatr*, Vol.21, 2021, pp.549.

[3] Hong, Junhee., "Prediction of Cognitive Impairment Using Sleep Lifelog Data and LSTM Model," *Mathematics*, Vol.12, No.20, 2024, pp.3208.

[4] Lee, JY. and Lee, SY., "Development of an AI-Based Predictive Algorithm for Early Diagnosis of High-Risk Dementia Groups among the Elderly: Utilizing Health Lifelog Data," *Healthcare*, Vol.12, No.18, 2024, pp.1872.

[5] Javeed, A., Dallora, A.L., Berglund, J.S., "Machine Learning for Dementia Prediction: A Systematic Review and Future Research Directions," *Journal of Medical Systems*, Vol.47, 2023, pp.17.

[6] Jang, Jae Won., "Prevalence and Incidence of Dementia in South Korea: A Nationwide Analysis of the National Health Insurance Service Senior Cohort," *Journal of clinical neurology*, Vol.17, No.2, 2021, pp.249-256.



[7] Kwon, Hyuk Sung., “Comparing the Characteristics of Patients With Newly Diagnosed Dementia Before and After 2008 in Seoul, South Korea: A Population-Based Study,” *Journal of clinical neurology*, Vol.18, No.6, 2022, pp.711-713.

[8] Nichols, Emma., “Estimation of the global prevalence of dementia in 2019 and forecasted prevalence in 2050: an analysis for the Global Burden of Disease Study 2019,” *The Lancet Public Health*, Vol.7, No.2, 2022, pp.105-125.

[9] Shin, JH., “Dementia Epidemiology Fact Sheet 2022,” *Ann Rehabil Med*, Vol.46, No.2, 2022, pp.53-59.

[10] Seong, SJ., Kim, BN., Kim, KW., “Comparative Analysis on the Policy Approaches in the National Dementia Plans of G7 Countries and Korea and Their Implementation,” *Journal of Korean Medical Science*, Vol.38, No.30, 2023, pp.227.

[11] Lim, J., “A smart healthcare-based system for classification of dementia using deep learning,” *DIGITAL HEALTH*, Vol.8, 2022.

[12] S, Baker., and W, Xiang., "Artificial Intelligence of Things for Smarter Healthcare: A Survey of Advancements, Challenges, and Opportunities," *IEEE Communications Surveys & Tutorials*, Vol.25, No.2, 2023, pp.1261-1293.

[13] Youngeun, Jo., Jongpil, Yu., Joongan, Kim., “A Study on Dementia Prediction Models and Commercial Utilization Strategies Using Machine Learning



Techniques : Based on Sleep and Activity Data from Wearable Devices,”
Information Systems Review, Vol.26, No.2, 2024, pp.137-153.

[14] Al-Hammadi, M., Fleyeh, H., Åberg, AC., Halvorsen, K., Thomas, I., “Machine Learning Approaches for Dementia Detection Through Speech and Gait Analysis: A Systematic Literature Review,” Journal of Alzheimer’s Disease, Vol.100, No.1, 2024.

[15] Sakal, C., Li, T., Li, J., “Predicting poor performance on cognitive tests among older adults using wearable device data and machine learning: a feasibility study,” npj Aging, Vol.10, No.56, 2024.

[16] Sweidan, J., El-Yacoubi, M.A., Rigaud, AS., “Explainability of CNN-based Alzheimer’s disease detection from online handwriting,” Sci Reports, Vol.14, No.22108, 2024.

[17] Javeed, A., Anderberg, P., Ghazi, AN., Noor, A., Elmståhl, S., Berglund, JS., “Breaking barriers: a statistical and machine learning-based hybrid system for predicting dementia,” Front Bioeng Biotechnol, Vol.11, 2024.

[18] Guerrero-Berroa, E., Luo, X., Schmeidler, J., Rapp, MA., Dahlman, K., Grossman, HT., Haroutunian, V., Beerli, MS., “The MMSE orientation for time domain is a strong predictor of subsequent cognitive decline in the elderly,” International Journal of Geriatr Psychiatry. Vol.24, No.12, 2009, pp.1429-1437.

