



저작자표시 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.
- 이차적 저작물을 작성할 수 있습니다.
- 이 저작물을 영리 목적으로 이용할 수 있습니다.

다음과 같은 조건을 따라야 합니다:



저작자표시. 귀하는 원저작자를 표시하여야 합니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 [이용허락규약\(Legal Code\)](#)을 이해하기 쉽게 요약한 것입니다.

[Disclaimer](#) 

碩 士 學 位 論 文
指 導 教 授 鄭 軫 馨

웨어러블 라이프로그 데이터 기반
치매 조기진단 및 예방을 위한
예측모델에 관한 연구

Research on predictive models for early diagnosis and
prevention of dementia based on wearable lifelog data

가톨릭관동대학교 일반대학원

의료공학과

최 지 예

2025年

웨어러블 라이프로그 데이터 기반
치매 조기진단 및 예방을 위한
예측모델에 관한 연구

指導教授：鄭 軫 馨

이 論文을 碩士學位論文으로 提出함.

2025年 6月

가톨릭관동대학교 일반대학원

의료공학과

최 지 예

崔詩容의 碩士學位 請求 論文을 認准함.

審 査 委 員

委員長 _____ 이 기 영 _____ 印

委 員 _____ 정 진 형 _____ 印

委 員 _____ 조 재 현 _____ 印

2025年 6月

가톨릭관동대학교 일반대학원

◀ 목 차 ▶

제 1장 서론	1
1.1 연구의 배경 및 필요성	1
1.2 선행연구	5
제 2 장 이론적 배경	7
2.1 치매의 개요	7
2.1.1 치매의 정의	7
2.1.2 치매 주요 증상 및 발병 원인	8
2.2 웨어러블 디바이스 개요	12
2.3 AI 예측 모델 개요	13
2.3.1 Random Forest	15
2.3.2 GBM(Gradient Boosting Machine)	16
2.3.3 XGBoost (Extreme Gradient Boosting)	18
2.3.4 SVM(Support Vector Machine)	19
2.3.5 LSTM(Long Short-Term Memory)	20
2.3.6 Ensemble Learning	22
2.4 예측모델 성능평가	23
2.4.1 혼동행렬을 통한 성능평가	23
2.4.2 ROC curve-AUC 성능평가	25
제 3 장 연구방법	26
3.1 연구의 목적	26
3.2 데이터 전처리 및 구성	27

3.3 데이터 분석	31
3.3.1 활동 데이터의 치매 상태별 데이터 분석	31
3.3.2 수면 데이터의 치매 상태별 데이터 분석	38
3.4 모델 설계	46
 제 4 장 연구결과 및 분석	 48
4.1 혼동행렬을 통한 성능평가 결과	49
4.1.1 Random Forest 혼동행렬 결과	49
4.1.2 GBM(Gradient Boosting Machine) 혼동행렬 결과	50
4.1.3 XGBoost(Extreme Gradient Boosting) 혼동행렬 결과 ..	51
4.1.4 SVM(Support Vector Machine) 혼동행렬 결과	52
4.1.5 LSTM(Long Short-Term Memory) 혼동행렬 결과	53
4.1.6 Ensemble Learning 혼동행렬 결과	54
4.1.7 혼동행렬 성능 종합 비교 분석	55
4.2 ROC curve-AUC 성능평가 결과	57
4.2.1 Random Forest ROC-AUC 결과	57
4.2.2 GBM(Gradient Boosting Machine) ROC-AUC 결과	58
4.2.3 XGBoost ROC-AUC 결과	59
4.2.4 SVM(Support Vector Machine) ROC-AUC 결과	60
4.2.5 LSTM(Long Short-Term Memory) ROC-AUC 결과 ..	61
4.2.6 Ensemble Learning ROC-AUC 결과	62
4.2.7 ROC curve-AUC 성능 종합 비교 분석	63
 제 5장 결론 및 고찰	 64

참 고 문 헌	66
Abstract	71
국 문 요 약	74

◀ 그림 목 차 ▶

그림 1-1. 연도별 추정치매환자수 및 유병률	1
그림 1-2. 조기 치료시 치매 진행도	2
그림 2-1. Random Forest 모식도	15
그림 2-2. XGBoost 모식도	18
그림 2-3. SVM 모식도	19
그림 2-4. 혼동행렬 구조	23
그림 3-1. 치매 상태별 활동 변수의 분포 비교 박스플롯	32
그림 3-2. 치매 상태별 수면 변수의 분포 비교 박스플롯	38
그림 3-3. 치매 상태별 활동/수면 비율의 분포 비교 박스플롯	44
그림 4-1. RandomForest 혼동행렬 결과	49
그림 4-2. Gradient Boosting Machine 혼동행렬 결과	50
그림 4-3. XGBoost 혼동행렬 결과	51
그림 4-4. SVM 혼동행렬 결과	52
그림 4-5. LSTM 혼동행렬 결과	53
그림 4-6. Ensemble Learning 혼동행렬 결과	54
그림 4-7. Random Forest ROC curve-AUC 결과	57
그림 4-8. Gradient Boosting ROC curve-AUC 결과	58
그림 4-9. XGBoost ROC curve-AUC 결과	59
그림 4-10. SVM ROC curve-AUC 결과	60
그림 4-11. LSTM ROC curve-AUC 결과	61
그림 4-12. Ensemble Learning ROC curve-AUC 결과	62

◀ 표 목 차 ▶

표 2-1. 치매의 대표적 원인 질환	11
표 3-1. 사용 활동 데이터 변수	28
표 3-2. 사용 수면 데이터 변수	29
표 3-3. 치매 상태별 활동 변수의 ANOVA 분석 결과	36
표 3-4. 치매 상태별 수면 변수의 ANOVA 분석 결과	42
표 3-5. 최종 적용 하이퍼파라미터 조합	46
표 4-1. 모델별 예측 성능평가 비교	55

제 1 장 서 론

1.1 연구의 배경 및 필요성

우리나라는 빠른 속도로 초고령화 사회로 진입하고 있으며, 이에 따라 치매 환자의 수도 증가하고 있다. 중앙치매센터의 보고서에 따르면 2018년부터 2022년까지 치매 환자 수는 지속적으로 증가하여 2022년 기준 전국 치매 상병자 수는 약 100만 명에 달하며, 이 중 65세 이상 치매 환자 수는 923,003명으로 전체 노인인구 9,010,544명의 10.2%를 차지한다고 보고되었다. 또한, 65세 이상 추정치매환자수는 2023년 약 98만 명, 2024년 약 105만 명이고, 2030년 142만 명, 2040년 226만 명에 이를 것으로 예측했다[4, 26].



그림 1-1 연도별 추정치매환자수 및 유병률 (출처: 중앙치매센터)

이러한 치매 환자의 증가는 보건의료 분야를 넘어 사회·경제적 측면에서도 심각한 문제로 부각되고 있다. 치매 환자 부양자의 치매 환자 1인당 연간 관리비용은 2022년에 약 2,220만 원으로 조사되었으며, 국가 치매 관리비용은 약 20조 8,000억 원으로 GDP의 약 1%를 차지한다[26]. 이러한 경제적 비용은 향후 인구 고령화가 지속됨에 따라 더욱 증가할 것으로 예상된다.

치매는 다양한 원인으로 인해 기억력과 인지능력, 판단력 등의 인지기능이 후천적으로 저하되어 일상생활에 지장을 주는 질병이지만, 조기진단과 개입을 통해 증상의 진행 속도를 늦출 수 있는 질환이다. 특히 뇌종양이나 심각한 우울증, 갑상선 질환, 약물 부작용, 영양 문제 등의 특정 요인에 의해 발생한 치매는 조기진단과 치료를 통해 치매 환자의 5~10%는 치료될 수 있다. 또한 치매 초기 단계에서 진행하는 약물치료는 치매의 진행을 늦추는데 도움이 되며, 당뇨나 고혈압과 같은 동반질환의 꾸준한 치료와 관리를 통해 환자의 삶의 질을 높일 수 있다. 그리고 치매 환자의 판단력이 상실되기 전에 유산상속과 같은 경제적 혹은 법적인 문제에 사전에 대처할 수 있다[25].




그림 1-2 조기 치료시 치매 진행도 (출처: 중앙치매센터)

치매 조기진단을 위해 정부에서 만 60세 이상의 노인을 대상으로 실행하고 있는 ‘치매조기진단사업’에 따르면 치매 진단은 먼저 전국 구·군 보건소 치매안심센터에서 인지 선별검사(Cognitive Impairment Screening Test, CIST)를 실행하고, Mini Mental State Examination(MMSE), Seoul Neuropsychological Screening Battery(SNSB), CERAD-K 등의 인지기능 평가검사를 통해 인지기능 상태를 평가한다. 결과에 따라 추가적인 정밀검사가 필요한 경우에는 MRI, CT, PET 등의 영상 검사나 혈액검사, 유전자 검사 등을 통해 치매 진단이 이루어진다[10].

그러나 치매 초기 증상은 미묘하고 비특이적이므로 일차 의료 현장에서 의사가 명확하게 인지하고 진단하기 어려운 경우가 많고, 환자 스스로 초기 증상을 스트레스나 노화의 자연스러운 결과로 여겨 상담을 미루거나 증상을 과소평가하는 경향이 있어 진단 시기를 놓치는 경우가 있으며[8, 34] 치매 진단과정에서 발생하는 경제적 비용이나 치매 증상과 유사한 다른 질환으로 오인하는 등의 문제로 치매 조기진단에 어려움이 있다. 특히, 치매의 기저 원인과 관계없이 65세 이전에 증상이 시작되는 치매인 초로기 치매는 2020년 기준 82,302명으로 전체 치매 환자의 9.03%를 차지하며, 비교적 젊은 나이에 증상이 발현되어 자신을 포함해 주변인들도 치매라고 인식하기 어렵고, 노인성 치매에 비해 양상이 다양하고 비전형적이며 인지기능 저하 속도도 빠르게 진행되기에 조기진단에 어려움이 있다[30].

최근 딥러닝과 머신러닝 등 인공지능 기술의 발전으로 지능형 로봇, 디지털 헬스케어 등의 다양한 분야에서 인공지능이 활용하고 있으며, 특히 의료 분야에서는 질환의 조기진단과 진단 정확도 및 효율성 향상을 위한 연구가 활발하게 진행되고 있다. 특히나 의료영상 분석, 유전체 분석, 생체신호 모니터링 등의 분야에서 AI 기술을 활용한 연구가 진행되고 있으며 헬스케어 분야에서는 인공지능을 통해 신체로부터 수집된 빅데이터를 분석함으로써 질병의 조기진단 및 예측에 활용되고 있다. 이러한 인공지능 기반 질병 예

측은 기존의 알고리즘 중심 진단 방법에 비해 정확도가 높을 뿐만 아니라 시간과 비용 측면에서 절감할 수 있다[5, 43].

본 연구에서는 웨어러블 디바이스를 통해 획득 가능한 수면 및 활동 라이프로그 데이터를 활용하여 치매 진행 단계에 따른 특성을 분석하고, 인공지능 기반 치매 단계 예측 모델을 개발하였다. 라이프로그 데이터는 MRI나 혈액 등과 같은 침습적인 방법을 통해 얻을 수 있는 데이터의 한계를 보완할 수 있는 웨어러블 디바이스를 통해 일상생활에서 비침습적이고 쉽게 측정 가능한 생체신호 데이터로, 본 연구를 통해 라이프로그 데이터를 기반으로 치매의 조기진단 가능성을 확인하고자 한다.

1.2 선행연구

라이프로그(lifelog) 데이터는 개인의 일상(life)에 대한 기록(log)하는 데이터로, 병원에서 측정할 수 있는 의료데이터뿐만 아니라 일상 데이터를 모두 포괄적으로 다루는 데이터이다. 이러한 라이프로그 데이터는 디지털 센서 혹은 웨어러블 장비로부터 수집되며 활동량, 수면 정보, 심전도, 보행 검사, 체성분 검사 등 다양한 생체신호와 건강 관련 정보들이 포함된다[6]. 최근 ICT와 AI 기술의 발달로 웨어러블 디바이스를 통해 수집된 라이프로그 데이터를 인공지능 모델과 결합하여 만성질환 예측, 건강 모니터링과 같은 다양한 분야에서 활용되고 있다. 특히 치매 조기진단 및 예측에 관한 선행연구도 활발히 진행되고 있다.

이명진 등의 연구(2024)에서는 치매 고위험군의 라이프로그 데이터를 활용하여 랜덤 포레스트 등의 알고리즘을 통해 인지기능 장애 예측 모델을 개발하였다. 후진 제거법을 통해 변수 최적화를 진행하였고, 변수 중요도 기준 상위 30개의 변수를 활용하여 정확도 79.3%의 정확도를 보였다[15].

그리고 조영은 등의 연구(2024)에서는 머신러닝 알고리즘을 활용해 치매 고위험군 웨어러블 라이프로그 데이터의 수면과 활동 데이터를 통해 치매 예측 모델을 개발하였다. 특히 랜덤 포레스트 모델이 정상군 예측에서 검증 데이터 결과 뛰어난 예측 성능을 보였으며, 변수 중요도 분석 결과, 치매 예측에 있어 총 수면시간이 가장 큰 영향을 미치고, 수면 데이터 다음으로 활동 관련 변수 중 저장도 활동 MET가 치매 예측에 영향을 미침을 확인하였다. 이를 통해 낮은 활동력은 치매 유발 가능성이 높다는 결과를 도출하였다[23].

또한, 최현철 등의 연구(2023)에서는 정상군과 인지기능 장애 환자의 라이프로그 데이터의 특성을 파악하기 위해 탐색적 데이터 분석(Exploratory Data Analysis, EDA)을 수행했다. 그 결과 인지기능 장애군이 이동 거리,

걸음 수, 활동 칼로리, 총사용 칼로리, 저강도 활동 시간, 중강도 활동 시간, 그리고 휴식 시간에서 높은 경향을 보였지만, 고강도 활동 시간, 활동 목표 달성 점수, 운동 강도 점수에서 정상군이 높은 경향을 보였다. 인지기능 장애 예측을 위해 AutoML을 통해 전체 데이터를 7:3으로 학습 및 검증 세트로 분할해 학습시켰으며, 머신러닝 모델에서 Gradient Boosting Classifier에서 0.83의 정확도를 보였으며 Voting 앙상블 모델을 통해 0.85의 정확도를 보였고, AUC는 0.9193의 성능을 보였다[29].

Collin Sakal 등의 연구(2024)에서는 미국의 2011~2014년의 국민건강영양조사(NHANES)에 참여한 2,400명 이상의 정상 노인과 경도인지장애(MCI) 노인 데이터를 활용하여 웨어러블 기기 데이터를 활용하여 CatBoost, XGBoost, Random Forest 등의 머신러닝 모델을 통해 인지기능 저하를 예측하는 연구를 진행하였다. 그 결과 DSST(처리 속도 및 기억·주의력 등)을 AUC 0.84 수준으로 높은 분류 성능을 보였고 CERAD-WL(기억)과 AFT(언어 유창성)에서 각각 AUC 0.73, 0.71의 성능으로 분류했다[44].

제 2 장 이론적 배경

2.1 치매 개요

2.1.1 치매의 정의

치매(Dementia)는 후천적 뇌 질환으로 의한 기억력, 인지능력, 판단력 등 다양한 인지기능의 저하가 발생하여 일상생활에 지장을 일으키는 상태로 노화에 따른 신경세포의 파괴와 뇌를 손상시키는 다양한 원인 질환들에 의해 유발되는 임상 증후군이다[42]. 이는 노화 과정에서 발생할 수 있는 일반적인 기억력 저하 등의 인지기능 저하 수준이 아닌 일상생활에 독립적인 생활이 불가능 정도로 저하된다.

치매는 진행 정도에 따라 초기, 중기, 말기 세 단계로 구분된다. 초기 단계에서는 환자가 기본적인 일상생활을 수행할 수 있으나, 가족이나 지인이 환자의 기억력과 주의력 저하를 인지하게 된다. 중기 단계에서는 인지기능 저하가 더욱 명확해져 독립적인 생활이 어려워지고, 외부의 지속적인 관리와 보호가 필요로 하다. 그리고 치매가 말기 단계에 이르면 인지기능 손상이 심각하여 정신행동 증상과 더불어 신경학적 증상과 신체적 합병증 등이 동반되어 일상생활 수행이 거의 불가능한 상태에 이르게 된다[24].

또한, 치매는 병리학적 원인에 따라 다양한 종류로 분류되고 대표적으로 다음과 같이 네 가지 유형이 있다. 첫 번째로 가장 흔한 형태인 알츠하이머형 치매(Alzheimer's Disease)는 퇴행성 뇌 질환으로 기억력과 판단력 등의 인지기능이 점진적으로 손상되는 질환이다. 두 번째는 혈관성 치매는 고지혈증이나 고혈압, 당뇨병 등의 뇌혈관 질환 요인에 의해 혈관이 막히면서 뇌에 산소와 포도당 공급이 차단되어 뇌세포 손상으로 인해 발생된다. 세

번째로는 루이소체 치매로, 루이소체(Lewy body) 단백질이 비정상적으로 응집되어 발병되는 치매로 파킨슨 증상과 유사한 운동장애 증상이 동반된다. 마지막으로 네 번째로는 전두측두엽 치매는 뇌의 전두엽 혹은 측두엽의 손상으로 인해 발생하며 45~64세에서 발병된다[18].

경도인지장애(Mild Cognitive Impairment, MCI)는 알츠하이머형 치매(Alzheimer's Disease, AD) 등의 퇴행성 치매 질환을 진단받기 이전 단계로 [14] 최소 1개 이상의 인지 영역에서 저하가 나타나지만, 치매 진단기준에는 포함되지 않는 정도의 일상생활 활동에 큰 지장을 주지 않는 경우에 진단된다[22]. 경도인지장애는 치매로 진행될 가능성이 높아 치매로 진행되지 않도록 관리가 중요하지만, 정상 노화에 의한 경미한 기능 감퇴와 경도인지장애와의 감별이 어렵고, 기능 장애에 대한 명확한 기준이 없어 경도인지장애의 진단에 어려움이 있다[13].

2.1.2 치매 주요 증상 및 발병 원인

치매 환자에게서 나타나는 행동심리증상(Behavioral and Psychological Symptoms of Dementia, BPSD)은 1996년 국제노인정신의학회(IPA)에 의해 정의되었으며, 치매 진행 과정에서 나타나는 지각, 사고, 정서 및 행동의 이상 증상을 의미한다. 대표적인 행동심리증상으로는 무감동, 망상, 환각, 불안, 우울, 초조, 공격성, 배회, 수면장애, 반복 행동, 사회적으로 부적절한 행동을 하는 탈억제 등이 있으며, 이러한 증상은 치매의 진행 정도 및 개인에 따라 나타나는 양상과 빈도가 다르게 나타난다. 이러한 증상은 환자뿐만 아니라 보호자와 가족에게도 신체적·정신적 부담을 증가시키고 의료비 상승 및 요양시설 입소와 같이 부정적인 결과를 초래한다[38].

행동심리증상은 크게 정신증적 증상과 이상행동으로 분류된다. 정신증적 증상은 망상, 환각, 편집증, 우울증, 불안, 반복, 착오 등이 있으며, 이상행동

의 증상으로는 공격성과 배회, 수면장애, 부적절한 식사 행동, 부적절한 성 행동 등이 있다. 이러한 증상은 치매 초기나 말기보다는 치매의 중기 단계에서 다양한 종류의 증상이 관찰된다[1].

치매 환자의 인지기능 저하 증상으로는 기억력 감퇴와 언어 능력, 시공간 파악 능력, 판단력 및 일상생활 수행 능력의 저하 등이 있으며, 정신·행동 증상으로는 성격 변화, 무감동, 우울, 불안, 이상행동 등의 성격이나 정서 혹은 행동 문제 등이 포함된다. 특히, 이러한 증상은 서로 연계되어 환자의 일상생활을 저해한다. 치매 환자의 행동심리증상은 폭력적 언어나 사실이 아닌 이야기를 지어내는 폭력 작화, 단어를 떠올리지 못하거나 말을 두서없이 이어가는 표현 이해 장애, 신체적 공격으로 타인에게 혐오감을 주는 흥분·폭력, 밤낮이 뒤바뀌거나 불면증이 동반되는 수면장애, 지속적으로 밖에 나가고자 하며 목표 없이 방향감각을 상실한 채 방황하는 배회, 특정 물품에 집착적으로 수집·숨기는 수집 행동, 의미 없이 반복하는 동작 등으로 다양하게 나타난다. 이와 함께 신경학적 증상으로 편측운동마비, 편측감각저하, 발음 이상 등이 관찰된다. 연구에 따르면 치매 환자의 약 80%가 최소 한 가지 이상의 행동심리증상을 경험하며 가장 흔한 증상으로는 무감동, 우울, 초조 및 공격성의 순으로 나타난다[3].

이러한 정신·행동 증상의 양상은 치매의 유형에 따라 차이가 존재한다. 알츠하이머형 치매는 주로 중기 단계 이후에 증상이 두드러지며 가장 흔한 정신·행동 증상으로는 불안감과 초조/공격성도 증상이 전형적으로 나타난다. 혈관성 치매의 경우, 무감동 및 무관심이 가장 특징적으로 나타나며 알츠하이머형 치매보다 초조/공격성, 불안감의 정도가 더 심한 것으로 조사되었다. 그리고 전두측두엽 치매는 전두엽 기능 저하와 관련된 성격 변화, 이상행동 또는 언어장애로 시작하여 탈억제, 반복 행동 및 보속 행동이 가장 특징적이다. 루이소체 치매는 주의력·각성 상태의 변동, 파킨슨병 양상 및 항정신병 약물의 민감도, 반복적인 졸도, 실신, 환시·망상, 수면장애 등의 증상이

나타난다. 마지막으로 알코올성 치매는 건망증, 정신운동 지연, 우원증, 보속증, 주의력 및 지남력 저하 등의 증상을 보이며, 대체로 경증으로 시작하여 점차 악화되는 경향을 보인다[12].

치매의 발병 원인은 아직 명확하게 규명되지 않았으나, 세계보건기구 WHO에 따르면 대표적인 위험 요인으로는 65세 이상의 고령이 있다. 노화는 신경세포의 손실 및 신경전달물질의 감소를 유발하여 치매 발병률을 높인다. 또한, 고혈압·고혈당·고지혈증 등 심혈관 질환은 뇌 혈류를 저하시켜 뇌세포 손상을 유발할 수 있다. 이와 더불어 과체중·비만, 흡연과 과음, 신체 활동 부족 등의 생활 습관 요인 역시 치매 발병위험 요인에 속한다. 우울증 또한 치매 발병위험을 높이는 것으로 보고되고 있다. 이외에도 치매를 일으킬 수 있는 원인은 유전적 요인이나 낮은 교육 수준은, 사회적 고립 등 매우 다양하며 주요 요인은 알츠하이머병과 혈관성 치매이며, 이외에도 루이소체 치매, 전측두엽 퇴행, 파킨슨병 등의 다른 퇴행성 뇌 질환과 뇌종양, 결핍성 질환 등 다양한 원인이 존재한다[46].

치매를 일으키는 대표적 원인 질환은 표 2-1과 같다.

표 2-1 치매의 대표적 원인 질환 (출처: 대한노인정신의학회)

분류	대표 예시
퇴행성 뇌 질환	알츠하이머치매, 전두측두 치매, 루이체병, 파킨슨병, 진행성핵상마비 등
뇌혈관 질환	뇌경색, 뇌출혈 등
결핍성 질환	베르니케뇌증, 비타민 B12 결핍증 등
대사성 질환	저산소증, 갑상선기능저하, 간성뇌병증, 요독증, 윌슨병 등
중독성 질환	알코올중독, 일산화탄소중독, 약물중독, 중금속중독 등
감염성 질환	신경매독, 크로이츠펔트야코프병, 후천성면역결핍증 등
수두증	정상압수두증 등
뇌종양	뇌수막종 등
뇌 외상	뇌좌상 등

2.2 웨어러블 디바이스 개요

웨어러블 디바이스 또는 웨어러블 기기는 사용자의 신체에 착용되어 생리적 신호나 환경 정보 등을 실시간으로 수집하는 장치로, ICT 기술의 발전과 개인 건강관리에 관한 관심 증가로 헬스케어 분야에서 건강 모니터링, 질병 예측 등 다양한 용도로 활용되고 있다. 현재 웨어러블 시장은 스마트 연동과 헬스케어 서비스 중심으로 성장하고 있으며, 이어웨어, 손목밴드, 위치류 제품이 다양한 센싱 기술과 위치정보 수집 기능을 바탕으로 시장의 주류를 형성하고 있다[7, 27].

웨어러블 디바이스는 형태와 적용 방식에 따라 크게 휴대형과 부착형, 그리고 이식/복용형으로 분류된다.

휴대형은 안경, 시계, 팔찌 형태의 스마트워치(Smart watch), 스마트밴드(Smart band), 스마트글래스(Smart glass), 반지, 신발, 의류 등으로 구성되며 착용 부담이 적고 스마트폰 등과 연동되어 높은 편의성을 제공한다.

부착형은 전자문신, 패치, 콘택트렌즈 등의 형태가 있으며 피부에 직접 부착되며 예시로 스위스 벤처기업의 센시메드(Sensimed)는 녹내장 환자의 안압을 24시간 측정하는 콘택트렌즈 형태의 비침습적 의료기기 트리거피쉬(Triggerfish) 렌즈 내부의 센서와 안테나를 통해 안압 데이터를 측정하고 블루투스를 통해 의사의 컴퓨터에 저장된다.

이식/복용형은 인간의 신체에 직접 이식하거나 복용하는 형태로, ‘소화가능 센서(Ingestible sensor)’를 통해 약물 복용 여부를 추적하거나, 무선 센서를 피부 안에 이식해 당뇨병 환자의 혈당 변화를 실시간으로 모니터링할 수 있는 기술 등이 있다[11].

본 연구에서는 반지형 웨어러블 디바이스인 ‘Oura ring’을 통해 수집된 라이프로그 데이터를 활용하여 치매 상태 예측모델을 개발하였다.

2.3 AI 예측 모델 개요

본 연구에서는 치매 단계별 라이프로그 데이터를 기반으로, 치매 단계 예측을 위한 인공지능 모델을 제시한다. 이를 위해 Random Forest, GBM(Gradient Boosting Machine), SVM(Support Vector Machine), XGBoost(Extreme Gradient Boosting), LSTM(Long Short-Term Memory), Ensemble Learning 등 머신러닝 및 딥러닝 기반 알고리즘을 적용하고, 각 모델의 예측 성능을 비교 및 분석했다.

헬스케어 분야에서는 인공지능을 활용하여 질병 진단, 조기진단, 환자 모니터링 등 다양한 영역에서 활용되고 있다. 특히 전자의무기록(EHR), 의료 영상, 유전체 정보, 뇌파 등 다양한 형태의 헬스케어 데이터를 기반으로 디지털 헬스케어 서비스의 효율성과 정확성을 향상시키는 연구가 진행되고 있으며[31], 데이터의 특성에 따라 적합한 알고리즘을 선택하는 것이 중요하다.

먼저 시계열 데이터는 시간에 따른 변화하는 연속적인 특성이 있으므로 과거의 정보와의 연관성을 반영할 수 있는 순환 신경망(RNN)과 장단기 메모리(LSTM) 모델 등이 주로 활용된다. Mallya et al.[41]은 12개월간의 전자의무기록 데이터를 기반으로 울혈성 심부전(Congestive Heart Failure, CHF) 발병 예측을 수행했으며 LSTM 모델을 학습하였으며 AUC-ROC 0.9147의 성능을 보였다. 반면, 설문조사나 건강검진 결과 등과 같은 표 형식으로 구조화된 건강 데이터의 경우, 각 변수 간의 복잡한 관계와 비선형적 패턴을 효과적으로 처리할 수 있는 XGBoost와 Random Forest와 같은 앙상블 학습 기반 알고리즘이 주로 활용된다. Yang et al.[45]은 혈액검사와 심혈관 검사 결과 데이터를 기반으로 심장병 예측을 위해 Random Forest, XGBoost, AdaBoost 알고리즘을 통해 예측 모델을 개발하였으며 XGBoost 모델이 0.984의 우수한 성능을 보였다.

이처럼 헬스케어 데이터의 특성과 분석 목적에 따라 적합한 알고리즘을 선택하여 모델을 개발하여 의료진의 의사결정을 지원하고 환자의 건강 증진에 기여할 수 있다.

2.3.1 Random Forest

Random Forest는 분류 및 회귀 분석 등에 사용되는 앙상블 학습 기반 알고리즘으로, 훈련 과정에서 생성된 다수의 결정 트리(Decision Tree)로부터 분류 결과 또는 평균 예측치를 출력함으로써 예측 결과를 도출한다. 여러 개의 의사결정트리를 만들고, 각 트리의 예측 결과를 기반으로 다수결 투표를 수행하며, 회귀 문제의 경우 각 트리의 예측값 평균을 산출하여 최종 결과를 결정하는 방법이다[21].

Random Forest는 배깅(Bagging) 기법을 통해 훈련 데이터의 샘플과 특성을 무작위로 선택하여 다수의 결정 트리를 구성하고, 예측 결과를 결합하여 도출한다는 특징을 지니고 있어 단일 모델보다 높은 정확도를 보인다. 또한, 무작위성을 도입하여 트리 간 상관성을 줄임으로써 과적합을 줄일 수 있으며 각 특성(feature)에 대한 중요도를 평가할 수 있는 장점이 있다[9, 39].

Random Forest는 다양한 분야에서 광범위하게 사용됐으며 특히 선행연구에서도 많이 활용되어 비선형 패턴의 데이터에도 우수한 예측 성능을 보이며 노이즈가 포함된 고차원 데이터에도 강인한 성능을 보임이 검증되어 선정하였다.




그림 2-1 Random Forest 모식도 (출처: 정우석 외 3인, 2021)

2.3.2 GBM (Gradient Boosting Machine) 모델

GBM(Gradient Boosting Machine)은 앙상블 알고리즘 중 하나로, 여러 개의 약한 학습기(weak learners)를 순차적으로 학습하여 예측 성능을 향상시키는 모델이다. 주로 결정 트리(decision trees)를 약한 학습기로 사용하며, 각 단계에서 이전 모델의 오차를 보완하는 방식으로 모델을 개선해 나간다.

GBM은 손실함수의 Gradient, 즉 예측값과 실제값 사이의 오차인 잔차(residual)를 기반으로 새로운 학습기를 추가해가며 성능을 개선해 나간다. 이러한 방식은 손실함수를 최소화하는 방향으로 모델을 업데이트하는 과정으로 모델이 점진적으로 개선된다. GBM은 먼저 초기 모델을 학습시킨 후, 새로운 모델에서 이전 모델의 오차를 예측하는 데 중점을 둔다. 이러한 방식으로 생성된 모델을 기존 모델에 추가하여 예측을 개선하는 과정을 여러 번 반복하여 최종 모델을 완성한다[28].

초기 모델 $F_0(x)$ 을 결정하는 수식은 다음(1)과 같으며 데이터 x 에 대해 손실함수 $L(y, F(x))$ 을 최소화하는 상수 γ 을 찾아 예측 초기값을 설정한다.

$$F_0(x) = \underset{\gamma}{\operatorname{argmin}} \sum_{i=1}^n L(y_i, \gamma) \quad (1)$$

손실함수의 Gradient를 계산하여 잔차를 구하는데 수식 (2)로 계산된다.

$$r_{im} = - \left[\frac{\partial L(y_i, F(x_i))}{\partial F(x_i)} \right]_{F(x) = F_{m-1}(x)} \quad (2)$$

수식 (2)도 구한 잔차를 학습하여 새로운 모델 $h_m(x)$ 을 만들어 학습률 γ_m 을 결정하기 위해 수식 (3)의 연산을 통해 최적화한다.

$$\gamma_m = \operatorname{argmin}_{\gamma} \sum_{i=1}^n L(y_i, F_{m-1}(x_i) + \gamma h_m(x_i)) \quad (3)$$

구해진 학습률을 사용해 수식 (4)의 연산을 통해 모델을 업데이트한다.

$$F_m(x) = F_{m-1}(x) + \gamma_m h_m(x) \quad (4)$$

이러한 방법을 M회 반복 학습 후 최종 모델은 다음과 같이 표현된다[33].

$$F_M(x) = F_0(x) + \sum_{m=1}^M \gamma_m h_m(x) \quad (5)$$

GBM은 복잡한 변수의 상호작용과 비선형 경계 학습에 강점을 가진 모델로 시계열 데이터와 같이 비정형적인 특성을 지닌 라이프로그 데이터 분석에 적합하다. 본 연구에서도 해당 결과의 일반화를 위해 GBM 모델을 채택했다. 기존 연구와 구조는 동일하나 본 연구에서 활용한 데이터 구성에 따른 하이퍼파라미터를 최적화하여 적용하였다.

2.3.3 XGBoost (Extreme Gradient Boosting) 모델

XGBoost는 기존 Gradient Boosting을 개선하여 병렬 처리, 과적합 방지, 메모리 최적화 등에서 향상된 성능을 제공하는 알고리즘이다[2]. 기존 모델의 잔차(Residual)를 기반으로 새로운 트리를 추가하여 모델을 개선하고, 각 트리는 이전 모델이 예측하지 못한 오차가 큰 데이터에 더 높은 가중치를 부여해 모델 성능을 높이고, L1 및 L2 정규화를 통해 모델 복잡도를 제어하고 과적합을 방지한다. 또한, 병렬 처리 및 트리 Boosting 최적화 단계를 통해 병렬로 학습함으로써 기존 GBM 모델보다 빠른 학습 속도를 보이며, 결측값 처리에 강력한 성능을 보인다. 다만 비교적 복잡한 구조와 높은 메모리 사용량을 요구하므로 소규모 데이터 세트에서는 과적합 또는 오버헤드가 발생할 수 있다는 단점이 있다[40].

XGBoost는 경도인지장애와 치매 간의 경계가 모호하고 일부 클래스의 데이터 수가 적기에 XGBoost를 채택했다. 선행연구에서도 XGBoost를 활용하여 민감도와 특이도에서 균형을 유지하는데 탁월한 성능을 보였고 본 연구에서는 그 모델의 강점을 본 연구에서 데이터 구성에 최적화된 모델로 적용하였다.




그림 2-2 XGBoost 모식도

2.3.4 SVM (Support Vector Machine)

SVM은 Vladimir Vapnik과 Alexey Chervonenkis에 의해 고안된 지도 학습 알고리즘으로, 데이터가 비선형이며 고차원일 경우에 적합한 기계 학습 방법론이다. 분류 문제 해결을 위해 개발된 방법론인 SVM은 커널 함수를 이용하여 기존 데이터를 특징 공간(Feature Space)으로 변환하며, 이러한 공간상에서 하나의 집단과 다른 집단을 분류하는 최적의 결정 경계면인 초평면(Hyperplane)을 구하게 된다. 초평면과 가장 가까운 데이터를 SV(Support Vector)라고 하며 초평면과 SV와의 거리를 마진이라고 부른다. 분류를 위해서는, 이 마진이 최대가 되는 최적의 초평면을 구하게 되면 이는 데이터 간의 분류가 최대 성능을 가지고 있다고 볼 수 있다[20].

SVM은 비선형적인 라이프로그 데이터를 분류하는 데 적합하며 기존 연구에서 기초 비교 모델로 자주 사용되었다. 본 연구의 데이터 세트에 SVM 모델 구조에 따른 데이터 적합성과 판별력 차이를 검증하고자 선정하였다.




그림 2-3 SVM 모식도 (출처: 위키백과)

2.3.5 LSTM(Long Short-Term Memory)

Long Short-Term Memory (LSTM)은 RNN(Recurrent Neural Network)의 한 유형으로 RNN의 시계열 데이터의 장기 의존성 문제를 해결하기 위해 고안된 딥러닝 모델이다. RNN은 시간에 따른 정보 전달 과정에서 기울기 소실 문제로 인해 장기 의존성을 학습하는 데 어려움이 있다[37]. 이러한 RNN의 장기 의존성 문제를 망각 게이트, 입력 게이트, 출력 게이트 총 3개의 게이트와 Cell state를 통해 해결한 알고리즘으로 LSTM의 연산은 다음 수식(6)~(11)을 기반으로 하며 마지막 시점에서 수행된 계산의 결과값이 예측값으로 결정된다.

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (6)$$

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (7)$$

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (8)$$

$$\bar{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C) \quad (9)$$

$$C_t = f_t \odot C_{t-1} + i_t \odot \bar{C}_t \quad (10)$$

$$h_t = o_t \odot \tanh(C_t) \quad (11)$$

Cell state는 다음 LSTM Cell로 정보를 그대로 전달하여 망각 게이트에서 이전 시점으로부터 전달받은 Cell state의 정보 중에서 잊어버릴 정보를 정하는 과정을 수행한다. 망각 게이트는 이전 시점의 은닉 상태인 h_{t-1} 과 현재 시점의 입력인 x_t 을 입력받아 활성화 함수인 시그모이드 함수(Sigmoid function)를 취해준 값을 출력으로 갖게 된다. 이로 인해 망각 게이트의 출력은 0과 1 사이의 값을 가지며 이 값이 클수록 Cell state의 정보가 오래 유지되고 이 값이 작을수록 빠르게 사라진다. 다음으로 입력 게이트는 전달받은 이전 Cell state 중 사용할 정보를 결정하는 역할을 하며 출력 게이트에서는 업데이트된 Cell state에서 내보낼 값을 결정하는 과정을 수행한다. 그리고 수식(6)에서 망각 게이트의 출력값과 이전 시점의 Cell state에 Element-wise product가 수행되어 이전 정보를 유지할지 판단하며, 입력 게이트의 출력과 Cell state에 더해질 후보 값 간의 Element-wise-product를 통해 사용할 정보가 결정된다. 이러한 두 개의 값으로 업데이트된 Cell state에 Hyperbolic Tangent 함수가 취해진 값과 출력 게이트 출력값에 Element-wise-product가 수행되어 현재 시점의 출력값이 계산되어 다음 시점으로 넘어간다. 이와 같은 계산이 시점마다 수행되어 마지막 시점에서 수행된 계산의 결과가 예측값에 해당한다[17].

LSTM은 본 연구에서 사용한 라이프로그 데이터의 시간 흐름에 따른 데이터 누적 특성을 고려하기 위하여 기존 연구의 LSTM 모델의 적용된 데이터 변수의 선택이 다르며 그 데이터에 적합한 구조로 재정렬한 후 모델의 성능을 검증하고자 선정하였다.

2.3.6 Ensemble Learning

앙상블 학습은 여러 개의 약한 학습기(weak learners)를 결합하여 하나의 강한 학습기(strong learner)를 생성하는 기법으로, 개별 모델보다 높은 예측 성능을 얻을 수 있는 방법이다. 대표적인 앙상블 학습 기법으로는 동일한 모델을 여러 번 학습시키고 모델들의 예측 결과를 평균하거나 다수결 방식으로 결합하는 방식인 배깅(Bagging) 기법과 이전 모델에서 잘못 예측한 샘플에 더 높은 가중치를 부여하여 점진적으로 모델을 개선하는 방식인 부스팅(Boosting) 기법, 그리고 서로 다른 모델의 예측 결과를 메타 학습기의 입력으로 사용하여 모델로부터 얻어낸 예측값을 학습 데이터로 삼는 스택킹(Stacking) 기법, 같은 데이터를 여러 개의 분류 모델에 독립적으로 학습시킨 후 각 모델의 예측 결과를 결합하여 최종 결과를 도출하는 보팅(Voting) 기법이 있다[16].

그 중 보팅(Voting) 기법은 하드 보팅과 소프트 보팅 기법으로 나뉜다. 먼저, 하드 보팅은 각 모델의 예측 결과를 이용하여 다수결 투표를 진행해 다수의 모델이 출력한 결과를 앙상블 모델의 최종 출력으로 결정하는 방식이다. 그리고 소프트 보팅은 각 모델이 예측한 확률과 가중치를 이용해 클래스별 최종 확률을 계산하므로 소프트 보팅은 하드 보팅에 비해 각 모델의 결과값들을 유연하게 적용할 수 있다[19].

본 연구에서 채택한 모델들을 조합하여 각 모델의 약점을 상호 보완하고 전체 예측 성능과 안정성을 향상하는 데에 중점을 두며 다양한 모델의 장점을 조합함으로써 향상된 예측 성능을 얻기 위해 다양한 모델의 예측 확률을 조합하는 soft voting 기법을 선정하였다.

2.4 예측 모델 성능평가

분류 모델의 성능평가는 일반적으로 Accuracy, Precision, Recall, F1-score, ROC-AUC 등의 지표가 있다. 본 연구에서는 다중 클래스 분류 모델이므로 Accuracy, Precision, Recall, F1-score, ROC-AUC 외에도 혼동 행렬을 분석하여 예측 성능을 검증했다.

2.4.1 혼동행렬을 통한 성능평가

혼동행렬(confusion matrix)은 분류 모델의 성능을 평가하는 도구로, 분류기의 예측 결과를 시각화한 표이다. 일반적으로 이진 분류에서 사용되지만, 다중 클래스 분류 문제에도 적용할 수 있으며 각 클래스 간의 예측 정확도와 오류 유형을 분석할 수 있다.

혼동행렬의 구성요소는 예측 성공 여부(true, false)와 상태 예측 결과의 조합으로 나타내어 실제 클래스와 모델이 예측한 클래스를 교차하여 나타낸 행렬로 행은 실제 클래스, 열은 예측된 클래스를 나타낸다.

본 연구에서는 정상, 경도인지장애, 치매 총 3개의 클래스를 분류하는 모델이므로 그림 2-4와 같은 3×3 혼동행렬이 생성된다.

predict Actual	Class A	Class B	Class C
Class A	P_{AA}	P_{AB}	P_{AC}
Class B	P_{BA}	P_{BB}	P_{BC}
Class C	P_{CA}	P_{CB}	P_{CC}

그림 2-4 혼동행렬 구조

혼동행렬을 이용하여 분류 모델의 성능을 평가하기 위하여 각 클래스에 대해 다음과 같은 수식으로 성능 지표를 계산한다. 행렬의 각 셀 P_{ij} 에는 실제 클래스 i 가 예측 클래스 j 로 분류된 샘플의 수를 의미한다.

정확도(Accuracy)는 전체 예측 중에 정확하게 예측된 비율로 전체 샘플에서 정확하게 예측된 비율로 수식 (12)와 같다.

$$Accuracy = \frac{P_{AA} + P_{BB} + P_{CC}}{Total} \quad (12)$$

정밀도(Precision)는 모델이 특정 클래스 k 로 예측한 것 중 실제로 해당 클래스로 예측한 비율로 수식 (13)과 같다.

$$Precision_k = \frac{P_{kk}}{\sum_{i=1}^K P_{ik}} \quad (13)$$

재현율(Recall)은 실제 클래스 k 에 속하는 데이터 중 모델이 이를 올바르게 예측한 비율로 수식 (14)와 같이 정의된다.

$$Recall_k = \frac{P_{kk}}{\sum_{j=1}^K C_{kj}} \quad (14)$$

F1-스코어(F1-score)는 정밀도와 재현율의 조화 평균으로, 두 지표 간의 균형을 종합적으로 평가한다. F1-score는 0에서 1 사이의 값을 가지며, 1에

가까울수록 모델의 성능이 좋음을 나타낸다. 수식 (15)와 같이 정의된다.

$$F1_k = \frac{2 \times Precision_k \times Recall_k}{Precision_k + Recall_k} \quad (15)$$

위 정의된 지표는 모델의 전반적인 성능뿐만 아니라 클래스별 예측의 정밀성과 포괄성을 평가하는 데 유용하다[35].

2.4.2 ROC Curve-AUC 성능평가

ROC-AUC는 분류 모델의 성능을 평가하는 지표로 분류 모델의 임계값 변화에 따른 민감도(TPR, True Positive Rate)와 특이도(FPR, False Positive Rate) 간의 관계를 시각화한 ROC 곡선 아래의 면적을 의미하며 이 값은 0과 1 사이의 값을 가지며, 1에 가까울수록 분류 성능이 좋음을 나타낸다[32].

이진 분류의 경우 ROC-AUC는 단일 값으로 정의되지만, 다중 클래스 분류에서는 각 클래스 간의 분류 성능을 종합적으로 평가하기 위해 별도의 기법이 요구된다. 모든 클래스 쌍에 대해 ROC-AUC를 계산하고 이를 평균화하여 다중 클래스 ROC-AUC로 모델의 성능을 평가한다. 수식 (16)과 같이 정의된다.

$$Mlti-classAUC = \frac{2}{K(K-1)} \sum_{i < j} AUC_{ij} \quad (16)$$

K 개의 클래스에 대해 모든 가능한 클래스 쌍 (i, j) 에 대해 개별적인 ROC-AUC를 산출한 후, 이 값의 평균을 내어 전체 다중 클래스 분류 모델의 종합적인 성능을 평가한다[36].

제 3 장 연구 방법

3.1 연구의 목적

본 연구는 고령화 사회 진입으로 증가하고 있는 치매 환자의 조기진단을 위하여 웨어러블 디바이스 기반 라이프로그 데이터를 활용한 인공지능 예측 모델의 개발과 라이프로그 데이터의 활용 가능성을 연구하는 것을 목적으로 한다. 기존의 침습적이고 비용 및 시간에 제약이 있는 진단 방법의 한계를 극복하고 일상생활에서 수집 가능한 비침습적인 데이터를 통해 치매의 조기 발견과 진행 단계 예측의 정확성을 높이는 모델을 제안하고자 한다. 이를 위해 본 연구에서는 한국지능정보사회진흥원이 운영하는 데이터 공유 플랫폼 ‘AI Hub’에 있는 ‘치매 고위험군 웨어러블 라이프로그’ 데이터를 활용하였으며 반지형 웨어러블 디바이스를 통해 수집된 치매 단계별 활동 및 수면 라이프로그 데이터를 분석하고, 인공지능 기반 치매 예측 모델을 개발하고자 한다.

치매 단계별 예측 모델을 위해 Random Forest, GBM(Gradient Boosting Machine), SVM(Support Vector Machine), XGBoost(Ext), LSTM(Long Short-Term Memory)과 이들을 통합한 Ensemble Learning 등 총 6가지 모델을 적용하였으며 각 모델의 성능을 비교하기 위해 혼동행렬 및 ROC curve-AUC를 통해 성능 비교·검증을 진행하였다.

본 연구를 통해 비침습적인 방식으로 일상생활에서 자연스럽게 얻을 수 있는 라이프로그 데이터 기반 AI 예측모델의 적용 가능성과 최적의 모델을 제안하는 것을 목표로 한다. 그리고 더 나아가 치매 환자의 조기 개입을 위한 데이터 기반 의사결정 지원체계 구축에 기여하고자 한다.

3.2 데이터 전처리 및 구성

본 연구에서는 과학기술정보통신부의 지원을 받아 한국지능정보사회진흥원(NIA)이 운영하는 AI 통합 플랫폼인 AI Hub에서 제공하는 ‘치매 고위험군 웨어러블 라이프로그’ 데이터를 활용하였다. 해당 데이터는 치매의 조기 진단 및 예방, 그리고 선제적 관리를 위한 AI 기반 예측모델 개발을 목적으로 구축된 공공 데이터로 전문의의 병리학적 진단을 바탕으로 치매의 진행 단계에 따라 분류된 실험 대상자의 반지형 웨어러블 디바이스 기반 라이프로그 데이터를 포함하고 있다.

총 174명의 만 55세 이상의 성인을 대상으로 수집되었으며, 정상군(Cognitive Normal, CN) 111명, 경도인지장애군(Mild Cognitive Impairment, MCI) 51명, 치매군(Dementia) 12명으로 구성되어 있다. 각 피험자는 반지형 웨어러블 디바이스를 통해 최소 35일부터 122일까지의 기간 동안 수면과 활동 중에 발생하는 생체 및 활동 데이터를 수집한 데이터이다.

본 데이터셋에는 활동량, 수면시간, 수면 효율성 등의 수치형 변수가 포함되어 연구의 일관성과 예측 모델의 타당성을 높이기 위해 본 연구에서는 수면 데이터의 종료 날짜를 기준으로 활동 데이터의 시작 날짜를 정렬하여 수면 - 활동 순으로 데이터를 병합하였다. 이를 통해 수면과 활동 간 시간 순서에 따른 인과관계를 반영한 통합 데이터셋을 구성하였다.

또한, 하루 간 활동 로그, 심박동 로그 데이터와 같은 Binary Large Object(BLOB) 형태의 로그 데이터를 제외한 정량 분석이 가능한 수치형 데이터만을 선별하여 최종 분석에 활용하였다. 또한, 본 연구에서는 변수 간 상관성이 높을 경우 모델의 과적합 가능성이 있으므로 피어슨 상관계수가 0.9 이상인 변수를 추출하고 Random Forest 기반의 변수 중요도(Feature Importance) 분석을 병행하여 상관계수가 높은 변수 중에서 중요도가 중위

수 이상으로 나타난 변수는 보존하여 최종적으로 활동 데이터 변수 21개, 수면 데이터 변수 22개의 총 43개의 변수를 사용하였다. 사용된 주요 변수는 표 3-1과 3-2와 같이 정리하였다.

표 3-1 사용 활동 데이터 변수

변수명	설명
activity_high	고강도 활동 시간
activity_steps	매일 걸음 수
activity_daily_movement	매일 움직인 거리
activity_non_wear	미착용 시간
activity_inactivity_alerts	비활동 알람 횟수
activity_score_training_frequency	운동 빈도 점수_frequency
activity_score_training_volume	운동 빈도 점수_volume
active_low	저강도 활동 시간
activity_medium	중강도 활동 시간
activity_met_min_inactive	하루 간 비활동 MET
activity_met_min_low	하루 간 저강도 활동 MET
activity_met_min_medium	하루 간 중강도 활동 MET
activity_average_met	하루 간 평균 MET
activity_cal_active	하루 간 활동 칼로리
activity_score_meet_daily_targets	활동 목표달성 점수
activity_score_stay_active	활동 유지 점수
activity_score	활동 점수
activity_total	활동 총 시간(분)
activity_score_recovery_time	회복 시간 점수
activity_rest	휴식 시간

표 3-2 사용 수면 데이터 변수

변수명	설명
sleep_light	가벼운 수면시간
sleep_deep	깊은 수면시간
sleep_score_deep	깊은 수면 점수
sleep_awake	깨 시간
sleep_restless	뒤척임 비율
sleep_rem	렘수면 시간
sleep_score_rem	렘수면 점수
sleep_hr_lowest	분당 낮은 심박동 수
sleep_hr_average	분당 평균 심박동 수
sleep_breath_average	분당 평균 호흡수
sleep_score_disturbances	수면 방해 점수
sleep_total	수면시간
sleep_score_alignment	수면 시기 점수
sleep_period_id	수면 식별 아이디
sleep_onset_latency	수면 잠복 시간
sleep_score_latency	수면 잠복 점수
sleep_score	수면 종합 점수
sleep_midpoint_time	수면 중간점 시간
sleep_midpoint_at_delta	수면 중간점 시간 델타
sleep_score_efficiency	수면 효율 점수
sleep_duration	잠 시간
sleep_temperature_deviation	피부 온도 편차

이러한 활동 및 수면 데이터에 모델의 성능을 향상시키기 위해 총 수면 시간과 총 활동량의 비율을 구한 파생 변수를 생성하였고 BLOB 형태의 원천 시계열 데이터는 평균 통계 기반의 파생 변수로 변환하여 진행하였다.

본 연구에서는 변수 선택 및 생성을 진행한 다음, 모델 학습을 위하여 수치형 데이터에 대해 정규화를 수행하였다.

본 연구에서 사용한 웨어러블 라이프로그 데이터는 변수 간 측정 단위 차이가 크기 때문에 각 변수의 값을 평균 0, 표준편차 1의 범위로 스케일링하는 StandardScaler 정규화 기법을 적용하여 변수 간 스케일 차이를 처리했다. 표준화 기법 중 가장 보편적이고 많은 연구에서 사용되는 정규화 기법이기에 선정하였다. 이로써 특정 변수의 값 범위가 학습 결과에 과도한 영향을 미치는 현상을 방지하였다. 또한, 데이터 세트의 클래스 간 분포가 정상군에 비해 경도인지장애군과 치매군의 데이터의 표본 수가 적기에 모델 학습 시 특정 클래스에 과적합하거나 소수 클래스가 과소 학습되는 문제를 방지하기 위하여 SMOTE 데이터 증강을 진행하여 클래스 불균형을 해결하였다. SMOTE는 원 데이터의 분포 특성을 유지하면서 샘플 수를 증강할 수 있다. 또한, 선행연구에서도 효과적인 불균형 처리 방식으로 많이 활용된 기법이기에 선택하였다. 치매 단계별 데이터의 학습 데이터 세트는 전체의 80%, 검증 세트로 20%의 비율로 설정하여 학습을 진행했다.


3.3 데이터 분석

본 연구에서는 치매 상태별 활동 및 수면 라이프로그 데이터의 변수별 분포를 박스플롯(Box plot)으로 데이터의 치매 상태별 데이터 분포 정도와 이상치 등을 시각화하고 이를 통해 집단 간의 차이를 도출하기 위해 각 집단의 평균값과 표준편차를 비교한 뒤 통계적으로 유의미한 차이가 있는지 검증 및 분석을 수행하였다.


3.3.1 활동 데이터의 치매 상태별 데이터 분석

치매 상태별 집단 간 활동 변수의 분포 차이를 정량적으로 파악하기 위하여 총 21개의 활동 변수 대상으로 박스플롯을 통한 시각화 및 일원 분산분석(ANOVA)을 수행하였다. 이를 통해 집단 간 평균값 차이의 통계적 유의성을 검토하고 치매 상태별 활동 변화를 분석하였다.


아래의 그림은 활동 데이터의 변수별 치매 상태에 따른 분포를 시각화한 박스플롯이다. 각 집단은 라벨링의 기준에 따라 정상군은 0, 경도인지장애군은 1, 치매군은 2로 표시하였다. 그래프에서 초록색 박스는 정상군, 주황색 경도인지장애군, 하늘색은 치매군을 나타낸다.




(a) activity_score_meet_daily_targets




(b) activity_score_training_volume




(c) activity_score




(d) activity_low




(e) activity_total




(f) activity_rest




(g) activity_average_met




(h) activity_met_min_low




(i) activity_score_training_frequency




(j) activity_cal_total




activity_steps




activity_met_min_inactive




(k) activity_cal_active




(l) activity_daily_movement




(m) activity_inactivity_alerts



(n) activity_medium



(o) activity_score_stay_active



(p) activity_met_min_medium




그림 3-1 치매 상태별 활동 변수의 분포 비교 박스플롯

박스플롯의 분석 결과, 그림 3-1의 (a) 활동 목표달성 점수 변수를 제외한 대부분의 변수에서 이상치가 다수 존재하는 것을 확인하였다. 또한, 치매 상태별 데이터 분포 정도를 확인한 결과 치매군은 대부분의 활동 변수에서 활동 수준 저하 및 목표 달성률 감소 등 수치가 다른 집단에 비해 상대적으로 저하된 양상을 보였다. 그리고 휴식 시간과 회복 시간 점수에 대해서는 다른 집단에 비해 높은 수치를 보였다. 반면, 경도인지장애군은 대부분의 데이터에서 정상군과 유사한 범위 내에서 분포를 보였으나 특정 변수에서 정상군보다 높은 활동성을 보였다.

또한, 집단 간 평균 차이가 통계적으로 유의미한지를 검증하기 위해 ANOVA 분석을 시행한 결과는 표 3-3과 같이 산출되었다.

표 3-3 치매 상태별 활동 변수의 ANOVA 분석 결과

변수	CN (mean±SD)	MCI (mean±SD)	Dem (mean±SD)	F-value	p-value
activity_score_meet_daily_targets	75.32±32.46	80.65±27.25	39.35±37.94	562.657	<0.001
activity_score_training_volume	87.08±19.97	89.91±17.74	67.71±35.54	373.36	<0.001
activity_score	82.01±13.91	84.62±12.74	69.77±18.22	367.38	<0.001
activity_low	280.97±116.72	306.02±118.58	191.81±118.61	306.957	<0.001
activity_total	334.87±133.30	365.20±138.62	233.41±155.81	303.948	<0.001
activity_rest	526.77±124.43	523.33±119.52	639.82±169.44	299.078	<0.001
activity_average_met	1.46±0.18	1.49±0.18	1.35±0.24	188.204	<0.001
activity_met_min_low	190.81±97.70	205.45±94.00	132.62±112.70	179.479	<0.001
activity_score_training_frequency	79.35±33.82	83.83±30.51	60.19±43.88	159.197	<0.001
activity_cal_total	2483.22±348.32	2560.62±318.04	2332.47±421.12	157.337	<0.001
activity_steps	10466.50±5470.57	11430.92±5961.57	7762.42±6980.72	136.288	<0.001
activity_met_min_inactive	7.70±3.37	8.14±3.59	6.08±2.68	117.994	<0.001
activity_cal_active	456.00±255.26	496.26±260.47	340.67±343.95	115.642	<0.001
activity_daily_movement	8622.98±4963.82	9294.56±5183.88	6406.60±6845.69	101.771	<0.001
activity_inactivity_alerts	0.52±0.83	0.36±0.68	0.58±0.87	55.852	<0.001
activity_medium	50.56±41.10	56.01±46.47	39.43±49.98	51.757	<0.001
activity_score_stay_active	76.99±15.50	80.08±15.41	76.66±17.26	51.24	<0.001

변수	CN (mean±SD)	MCI (mean±SD)	Dem (mean±SD)	F-value	p-value
activity_met_min_medium	161.50±141.73	178.46±153.91	128.05±166.92	41.988	<0.001
activity_score_recovery_time	85.59±29.64	84.54±31.14	92.26±22.32	21.867	<0.001
activity_high	3.34±8.03	3.18±7.23	2.17±5.58	8.346	<0.001
activity_non_wear	45.79±65.69	45.42±65.51	39.43±60.68	3.371	0.034

ANOVA 분석 결과, 모든 변수에서 세 집단 간 평균값의 차이가 통계적으로 유의미한 것으로 나타났다. F-value와 p-value를 기반으로 검정한 결과, 대부분의 변수가 p-value가 0.001 미만으로 나타났으며 이는 유의수준 0.05 보다 낮은 수치로 집단 간 차이가 통계적으로 신뢰할 수 있음을 확인할 수 있었다.


변수별 집단 간 비교에서 대부분의 활동 관련 지표에서 치매군이 다른 집단에 비해 낮은 평균값을 보이는 경향이 뚜렷하게 나타났다. 특히 활동 점수와 활동 시간, 활동 칼로리 및 MET 관련 지표에서 치매군이 가장 낮았다. 예를 들어 activity_score_meet_daily_targets 변수에서 치매군이 39.35±37.94로 정상군과 경도인지장애군에 비해 현저히 낮은 수치를 보였으며, 이를 통해 치매군이 일일 활동목표를 달성하는 데 어려움이 있음을 확인할 수 있다. 반면, 비활동 및 휴식 시간, 회복 시간과 관련된 변수에서는 치매군이 가장 높은 값을 보였다. 이러한 분석을 통해 치매군이 활동보다는 휴식 또는 비활동 상태에서 보내는 시간이 길며, 전반적인 활동 저하가 두드러짐을 보여준다.

그리고 경도인지장애군은 대부분의 변수에서 정상군과 유사한 범위 내에서 다소 높은 경향을 보였다. 이는 경도인지장애군이 활동에서는 정상군보다 활동량이 증가하는 행동 양상을 보일 수 있음을 시사한다.


3.3.2 수면 데이터의 치매 상태별 데이터 분석

치매 상태별 수면 데이터의 총 22개 변수에 대해 집단 간 분포 차이를 정량적으로 파악하기 위하여 박스플롯을 활용한 시각화와 함께 통계 및 일원 분산분석(ANOVA)을 수행하였다. 집단 간 평균값 차이의 통계적 유의성을 검토하고 치매 상태별 수면 변화를 분석하였다.


아래 그림은 수면 데이터의 변수별 치매 상태별 데이터 분포를 나타낸 박스 플롯의 그래프이다. 정상군은 0, 경도인지장애군은 1, 치매군은 2로 표시하였고, 그래프에서 초록색 박스는 정상군, 주황색은 경도인지장애군, 하늘색은 치매군을 의미한다.




(a) sleep_light




(b) sleep_restless




(c) sleep_duration




(d) sleep_midpoint_time




(e) sleep_total




(f) sleep_awake




(g) sleep_score_deep




(h) sleep_score_alignment




(i) sleep_score_disturbances




(j) sleep_onset_latency




(k) sleep_deep




(l) sleep_score_efficiency




(m) sleep_breath_average



(n) sleep_score_latency



(o) sleep_score_rem



(p) sleep_rem




그림 3-2 치매 상태별 수면 변수의 분포 비교 박스플롯

박스플롯의 분석 결과, 활동 데이터와 마찬가지로 수면 데이터에서도 그림 3-2의 (o) 램수면 점수 변수를 제외한 대부분의 변수에서 이상치가 다수 관찰되었다. 치매 상태별 수면 데이터의 분포를 살펴보면, 치매군은 전반적으로 수면시간과 수면량은 높은 경향을 보였으나, 수면 효율과 수면 질과

관련된 수면 시기 점수, 깊은 수면 점수 등의 변수에서는 치매군이 가장 낮은 값을 보였다. 이는 수면의 양은 많으나 수면의 질이 낮은 치매 환자의 수면 패턴을 반영한다. 반면, 경도인지장애군은 대부분의 데이터에서 정상군과 유사한 수준의 분포를 보였으나 수면시간이 길고 깊은 수면의 질이 상대적으로 낮은 분포를 보였다.

집단 간 평균 차이가 통계적으로 유의미한지를 검증하기 위해 ANOVA 분석을 시행한 결과는 표 3-4와 같이 산출되었다.

표 3-4 치매 상태별 수면 변수의 ANOVA 분석 결과

변수	CN (mean±SD)	MCI (mean±SD)	Dem (mean±SD)	F- value	p-value
sleep_light	14432.42±4157.32	14755.57±4292.60	18490.26±5082.18	321.474	<0.001
sleep_restless	35.32±11.19	35.90±11.99	45.66±13.12	284.648	<0.001
sleep_duration	28829.29±6638.48	28983.17±6724.96	34103.82±8369.40	217.131	<0.001
sleep_midpoint_time	14492.94±3579.93	14522.26±3531.56	17144.02±4500.70	193.417	<0.001
sleep_total	23518.52±5197.26	23322.13±5162.05	26808.09±6158.32	150.543	<0.001
sleep_awake	5310.77±3296.03	5661.04±3333.75	7295.72±4552.17	123.877	<0.001
sleep_score_deep	82.84±24.42	81.27±24.20	70.50±29.37	88.986	<0.001
sleep_score_alignment	89.84±18.74	94.01±13.67	88.71±23.21	75.82	<0.001
sleep_score_disturbances	66.41±12.39	65.38±12.56	61.01±15.29	66.854	<0.001
sleep_onset_latency	701.43±615.07	681.67±577.78	955.35±1012.57	62.094	<0.001
sleep_deep	5245.63±2592.76	5042.02±2584.54	4295.88±2472.36	50.556	<0.001

변수	CN (mean±SD)	MCI (mean±SD)	Dem (mean±SD)	F- value	p-value
sleep_score_efficiency	76.53±19.01	74.18±19.09	70.18±21.50	49.669	<0.001
sleep_breath_average	16.69±1.36	16.93±1.15	16.66±1.24	44.42	<0.001
sleep_score_latency	79.94±14.52	79.78±14.19	74.91±21.24	40.691	<0.001
sleep_score_rem	57.67±29.71	52.83±28.47	57.64±31.06	34.445	<0.001
sleep_rem	3840.47±2163.22	3524.54±2079.97	4021.96±2327.49	33.129	<0.001
sleep_midpoint_at_delta	11192.05±14475.77	10151.46±15633.97	15008.94±20966.24	32.541	<0.001
sleep_hr_lowest	55.20±6.62	54.84±6.29	53.37±7.45	28.606	<0.001
sleep_period_id	0.92±1.10	0.78±0.99	0.87±1.10	21.291	<0.001
sleep_hr_average	60.71±7.41	60.10±6.82	59.61±8.23	14.427	<0.001
sleep_temperature_deviation	-0.01±0.31	-0.00±0.31	-0.06±0.37	9.126	<0.001
sleep_score	73.76±11.60	72.83±10.80	73.32±12.86	8.28	<0.001

ANOVA 분석 결과, 모든 수면 변수에서 세 집단 간 평균값의 차이가 통계적으로 유의미한 것으로 나타났다. F-value와 p-value를 기반으로 검정한 결과, 모든 변수의 p-value가 0.001 미만으로 나타났으며 이는 유의수준 0.05보다 낮은 수치로 집단 간 차이가 통계적으로 신뢰할 수 있음을 확인할 수 있었다.

수면 변수별 집단 간 비교에서는 전반적으로 치매군이 수면의 질과 효율을 나타내는 수면 효율(sleep_score_efficiency), 수면의 질(sleep_score_deep, sleep_score_alignment 등)에서 다른 집단에 비해 낮은 값을 보였다. 반면, 수면시간과 양을 나타내는 변수(sleep_light, sleep_duration, sleep_total,

sleep_rem 등)에서는 치매군이 가장 높은 값을 보였다. 예로 sleep_rem에서 치매군이 4021.96 ± 2327.49 로 정상과 경도인지장애군보다 높은 수치를 보였다. 이는 치매군이 전반적으로 수면시간이 길지만, 실제로는 깊은 수면이나 효율적인 수면으로까지 연결되는 것에 어려움을 보임을 시사한다. 또한, 뒤척임(sleep_restless), 수면 중 깸시간(sleep_awake) 등에서도 치매군이 상대적으로 높은 수치를 보이며 수면 잠복 시간(sleep_onset_latency)도 치매군이 955.35 ± 1012.57 로 가장 길게 나타나, 수면에 드는 데 오랜 시간이 걸리고 수면 중 각성과 불안정한 수면 패턴을 보이는 전형적인 수면장애 양상을 보임을 확인할 수 있다.

한편, 경도인지장애군은 대부분의 수면 변수에서 정상군과 유사한 수준을 보였으나 일부 변수에서는 정상군보다 낮은 평균값을 보여 수면 질의 부분적 저하가 확인되었다.

활동 및 수면 데이터 변수의 집단별 분포를 확인한 결과, 이러한 데이터 분석을 통해 파생 변수를 생성한 활동/수면 비율 변수에 대한 데이터 분포는 아래 그림과 같다.




그림 3-3 치매 상태별 활동/수면 비율의 분포 비교 박스플롯

정상군과 경도인지장애군이 각각 평균 0.0152와 0.0166으로 유사한 값을 나타내었지만 치매군은 평균 0.0096으로 정상과 경도인지장애군에 비해 활동/수면 비율이 확연하게 낮은 분포를 보이는 것을 확인하였다.

이를 통해 치매군은 정상군과 경도인지장애군에 비해 활동성이 감소하고 수면 비중이 높아지는 경향을 보임을 확인할 수 있었다.

3.4 모델 설계

본 연구에서는 기존 연구에서 활용된 Random Forest, GBM, XGBoost, SVM, LSTM 등 여러 모델을 기반으로 기존 모델 구조를 재해석하고 본 연구에서 선정한 데이터 변수에 적합한 최적의 성능을 도출하기 위해 머신러닝 모델의 경우, 계산 효율성과 다양한 하이퍼파라미터 공간의 경우 탐색 효율이 뛰어난 RandomSearchCV을 통해 모델별로 랜덤 샘플링을 통해 각 모델 간 최적의 하이퍼파라미터 값을 찾아내어 그 값으로 학습을 진행하였다. 본 연구에서 적용한 하이퍼파라미터는 표 3-5와 같다.

표 3-5 최종 적용 하이퍼파라미터 조합

모델	하이퍼파라미터	값
RF	n_estimators	500
	min_samples_split	2
	min_samples_leaf	1
	max_features	sqrt
	max_depth	30
	class_weight	'balanced
GB	subsample	1.0
	n_estimators	200
	max_depth	7
	learning_rate	0.2
SVM	kernel	rbf
	gamma	auto
	class_weight	balanced
	C	50
	probability	True
XGB	subsample	0.8
	reg_lambda	2
	n_estimators	300
	max_depth	7
	learning_rate	0.2
	use_label_encoder	False
	eval_metric	mlogloss

본 연구에서 웨어러블 디바이스의 시계열 데이터의 특성 정보를 활용하기 위하여 LSTM(Long Short-Term Memory) 기반의 딥러닝 모델을 구현했다. 본 연구에서는 2개의 LSTM 은닉층으로 되어 있어 첫 번째 LSTM 은닉층은 입력 시계열로부터 저수준의 다양한 시간적 패턴을 충분히 학습할 수 있도록 unit 수를 128개로 다소 넉넉하게 설정하였다. 이는 웨어러블 데이터의 특성상 짧은 구간의 급격한 변화뿐만 아니라 장기적인 주기성 패턴이나 잠재적 이상 징후 등의 temporal feature를 동시에 포착할 필요가 있기 때문이다. 그리고 두 번째 LSTM 은닉층은 앞서 추출된 시간적 특징을 압축 및 요약하는 역할을 하며 마지막 시점의 은닉 상태만 출력해 전체 시계열 정보가 효과적으로 집약될 수 있도록 64개의 unit으로 구성했다.

그리고 Batch Normalization 계층을 각 은닉층 뒤에 삽입하여 학습 과정에서 발생할 수 있는 내부 공변량 변화 문제를 완화하고, 학습률 설정의 민감도를 낮춰 더욱 일반화된 학습이 가능해진다.

Dropout 계층은 0.3의 비율로 설정하여 각 은닉층 뒤에 배치해 과적합 현상을 방지하였다.

손실함수로는 categorical crossentropy를 선택해 본 연구의 예측 대상인 치매 상태군의 3개의 범주로 구성되어 있으므로 다중 클래스 분류에 최적화된 손실함수를 선택했다.

최적화 알고리즘으로는 Adam을 사용하였다. Adam은 복잡한 딥러닝 네트워크의 최적화 문제에서 좋은 성능을 보여주는 것으로 여러 연구에서 보고되어 있어 채택하게 되었다.

제 4 장 연구결과 및 분석

본 연구에서는 치매 상태를 예측하기 위해 6가지 Random Forest, GBM(Gradient Boosting Machine), SVM(Support Vector Machine), XGBoost, LSTM(Long Short-Term Memory), Ensemble Learning 모델을 적용하여 성능을 비교 분석했다. 각 모델의 성능은 정상군, 경도인지장애, 치매군의 3가지 클래스를 대상으로 다중 클래스 분류를 수행한 혼동행렬을 통한 정확도(Accuracy), 정밀도(Precision), 재현율(Recall), F1 스코어(F1 Score)로 평가했다. 정상은 0으로, 경도인지장애군은 1, 치매군은 2로 라벨링 하여 나타냈다.

4.1 혼동행렬을 통한 성능평가 결과

4.1.1 Random Forest 혼동행렬 결과




그림 4-1 Random Forest 혼동행렬 결과

Random Forest 모델에서 정상군은 총 1,546건 중 1,431건이 정상으로 정확하게 분류되어 recall 값은 0.93으로 나타났다. 경도인지장애군은 총 731건 중 462건이 정확히 분류되고 recall 값은 0.63으로 상대적으로 낮게 나타났다. 치매군은 총 156건 중 119건이 정확하게 분류되었으며, recall 값은 0.76으로 확인되었다. precision은 정상군은 0.83, 경도인지장애군에서 0.81, 치매군에서 최대 0.84로 나타났으며, F1-score는 각각 0.88, 0.71, 0.80으로 나타났다. 전체 Accuracy는 0.826으로 비교적 우수한 성능을 보였으나 정상과 경도인지장애군 간에는 오분류가 다소 발생함을 확인하였다.

4.1.2 GBM(Gradient Boosting Machine) 혼동행렬 결과




그림 4-2 Gradient Boosting Machine 혼동행렬 결과

Gradient Boosting 모델에서 정상군은 총 1,546건 중 1,441건이 정상으로 정확하게 분류되어 recall 값은 0.93으로 나타났다. 경도인지장애군은 총 731건 중 504건이 정확히 분류되고 recall 값은 0.69로 Random Forest 모델 대비 다소 향상된 성능을 보였지만 클래스 중 상대적으로 낮게 나타났다. 치매군은 총 156건 중 127건이 올바르게 분류되었고, recall 값은 0.81로 확인되었다. precision은 정상군에서 0.86, 경도인지장애군에서 0.83, 치매군에서 0.92로 나타나 전반적으로 우수한 양성 예측률을 보였다. F1-score 또한 각각 0.89, 0.75, 0.86으로 나타났다. 전체 Accuracy는 0.851로 Random Forest 모델 대비 개선된 결과를 보였으며, 이는 Gradient Boosting machine모델이 상대적으로 복잡한 데이터의 경계 영역에서 더 효과적으로 분류를 수행하였음을 보여준다. 다만, 정상과 경도인지장애군 간에는 여전히 오분류가 발생함을 확인하였다.

4.1.3 XGBoost(Extreme Gradient Boosting) 혼동행렬 결과




그림 4-3 XGBoost 혼동행렬 결과

XGBoost 모델에서 정상군은 총 1,546건 중 1,458건이 정상으로 정확히 분류되어 recall 값은 0.94로 나타났다. 경도인지장애군은 전체 731건 중 520건이 정확히 예측되어 recall 값은 0.71로 Random Forest와 GBM 모델 대비 소폭 개선되었으며, 치매군은 총 156건 중 127건이 올바르게 분류되어 recall 값은 0.81로 확인되었다. precision은 정상군에서 0.86, 경도인지장애군에서 0.86, 치매군에서 0.93으로 모든 클래스에서 고르게 높은 예측 정확도를 보였다. F1-score는 정상군 0.90, 0.78, 0.87로 나타났다. 전체 Accuracy는 0.865로 정상군과 경도인지장애군 간 오분류 비율이 이전 모델에 비해 향상되었음을 확인하였다. 모델 대비 개선된 결과를 보였으며, 이는 XGBoost 모델이 복잡한 데이터 경계에서 분류 성능을 효과적으로 개선했음을 의미한다.

4.1.4 SVM(Support Vector Machine) 혼동행렬 결과




그림 4-4 SVM 혼동행렬 결과

SVM 모델은 정상군에서 총 1,546건 중 1,381건이 정상으로 정확하게 분류되어 recall 값은 0.89로 확인되었다. 경도인지장애군은 전체 731건 중 559건이 정확히 예측되어 recall 값은 0.76으로 Random Forest와 GBM 모델보다 높은 성능을 나타냈다. 치매군은 총 156건 중 121건이 올바르게 분류되어 recall 값은 0.78로 확인되었다. precision은 정상군에서 0.88, 경도인지장애군에서 0.77, 치매군에서 0.89로 비교적 높은 수준을 유지하였다. F1-score는 정상군 0.89, 0.77, 0.83으로 나타났다. 전체 Accuracy는 0.847로 혼동행렬 분석 결과, 정상군과 경도인지장애군 간 일부 오분류가 발생하였으나, SVM 모델은 경계가 명확하지 않은 데이터에서도 비교적 안정적인 분류 성능을 보였다. 이는 SVM의 고차원 공간에서의 분류 결정 경계 설정 능력이 데이터 복잡성을 효과적으로 처리할 수 있음을 의미한다.

4.1.5 LSTM(Long Short-Term Memory) 혼동행렬 결과




그림 4-5 LSTM 혼동행렬 결과

LSTM 모델에서 정상군 총 1,546건 중 1,396건이 정상으로 정확히 분류되어 recall 값은 0.90으로 확인되었으며, 경도인지장애군은 전체 731건 중 525건이 올바르게 예측되어 recall 값은 0.73으로 SVM과 XGBoost에 비해 소폭 낮은 성능으로 평가되었다. 치매군은 총 156건 중 117건이 정확하게 분류되어 recall 값은 0.80으로 나타났다. precision은 정상군에서 0.87, 경도인지장애군에서 0.77, 치매군에서 0.86으로 비교적 고른 성능을 보였다. F1-score는 정상군 0.88, 경도인지장애군 0.75, 치매 0.83으로 나타났다. 전체 Accuracy는 0.839로 정상군과 경도 인지장애군 간 일부 오분류가 지속적으로 발생하고 있으나, LSTM 모델이 장기 의존성을 갖는 라이프로그 데이터의 특성에 적합하며 데이터의 시퀀스 특성을 효과적으로 반영하여 안정적인 분류 성능을 보였음을 의미한다.

4.1.6 Ensemble Learning 혼동행렬 결과




그림 4-6 Ensemble Learning 혼동행렬 결과

Ensemble 모델은 정상군의 경우, 전체 1,546건 중 1,478건이 정확히 정상으로 분류되어 recall 값이 0.96으로 나타났으며, 이는 다른 분류군에 비해 매우 높은 성능을 보였다. 정상군에서의 precision도 0.87로, 예측의 정확도 높음을 알 수 있다. 그리고 경도인지장애군에서는 전체 731건 중 527건이 올바르게 예측되어 recall은 0.72로 다소 낮은 수치를 보였으나, precision은 0.88로 좋은 성능을 보였다. 치매군은 전체 156건 중 126건이 정확하게 분류되어 recall 0.81, precision 0.95로 매우 높은 성능을 보였다. F1-score 또한 세 집단 모두에서 고르게 높은 값을 기록하였다. 정상군 0.91, 경도인지장애군 0.79, 치매군 0.87로, precision과 recall의 균형 측면에서도 모델의 성능이 균일하게 유지됨을 알 수 있다. 전체 Accuracy는 0.875로, 가장 높은 값을 기록하였다. 이는 Ensemble 모델이 단일 분류기가 갖는 한계를 다수 모델의 예측 결과를 집합적으로 활용함으로써 상호 보완하고 분류 경계의 안정성을 높였음을 확인하였다.

4.1.7 혼동행렬 성능 종합 비교 분석

표 4-1 모델별 예측 성능평가 비교

model	precision			recall			F1-score			Accuracy
	0	1	2	0	1	2	0	1	2	
RF	0.83	0.81	0.84	0.93	0.63	0.76	0.88	0.71	0.80	0.826
GBM	0.86	0.83	0.92	0.93	0.69	0.81	0.89	0.75	0.86	0.851
SVM	0.88	0.77	0.89	0.89	0.76	0.78	0.89	0.77	0.83	0.847
XGBoost	0.86	0.86	0.93	0.94	0.71	0.81	0.90	0.78	0.87	0.865
LSTM	0.87	0.77	0.86	0.90	0.73	0.80	0.88	0.75	0.83	0.839
Ensemble	0.87	0.88	0.95	0.96	0.72	0.81	0.91	0.79	0.87	0.875

본 연구에서 적용한 6가지의 모델 중 Voting 기반 Ensemble 모델이 Accuracy 0.875로 가장 높은 정확도를 보였으며, 전반적인 성능평가 지표에서도 가장 우수한 성능을 보였다. 특히 치매군 예측에서 precision 0.95, recall 0.81, F1-score 0.87로 높은 민감도와 예측 균형을 확인하였고, 정상군에서도 recall 0.96, F1-score 0.91로 우수한 성능을 보였다. 이는 Ensemble 모델이 개별 모델의 약점을 상호 보완하여 분류의 안정성과 정확도를 동시에 극대화할 수 있음을 확인하였다.

Ensemble 모델에 이어 XGBoost 모델이 Accuracy가 0.865로 두 번째로 높은 성능을 보였고, GBM 0.851, SVM 0.847, LSTM 0.839, Random Forest 0.826의 순으로 높은 정확도를 보였다. 특히 XGBoost는 모든 클래스에서 고른 Precision과 Recall 값을 보였고, 전반적으로 모든 모델이 0.80 이상의 성능을 보여 치매 상태 진단의 실제 적용 가능성을 제시하였다.

반면, 모든 모델에서 경도인지장애군에서는 일부 오분류가 지속해서 발생

하는 경향이 나타났다. 향후 연구에서는 BLOB 형 시계열 데이터 등 원천 데이터의 시계열 패턴을 모델에 직접 반영하는 방법을 도입하고 특정 지역에 편중되지 않은 다양한 인구 집단의 데이터를 수집하여 예측 정확도를 향상할 필요가 있다.

4.2 ROC curve-AUC 성능평가 결과

4.2.1 Random Forest ROC-AUC 결과




그림 4-7 Random Forest ROC curve-AUC 결과

Random Forest 모델의 ROC 곡선에서 모든 클래스의 TPR이 FPR 0.0~0.2 구간에서 0.8 이상의 값을 유지하였고, 특히 치매군은 FPR 0.2 미만에서도 TPR이 0.9 이상으로 높은 민감도를 유지하며 정확하게 분류함을 확인할 수 있었다. AUC는 정상군은 0.91, 경도인지장애군은 0.90, 치매군은 0.97로 모든 클래스에서 AUC의 값이 0.9 이상의 결과를 보였다. 특히 치매군에서 AUC가 0.97로 가장 높게 나타나 Random Forest 모델이 치매군을 효과적으로 구분하는 데 강점을 보였음을 확인할 수 있었다.

4.2.2 GBM(Gradient Boosting Machine) ROC-AUC 결과




그림 4-8 Gradient Boosting ROC curve-AUC 결과

GBM 모델의 ROC 곡선에서 모든 클래스가 FPR이 0.0에서 0.2 범위에서 TPR의 수치가 0.8 이상의 높은 값을 유지하는 것을 확인할 수 있었으며 AUC 값을 살펴보면 정상군은 0.93, 경도인지장애군은 0.93, 치매군은 0.98로 모든 클래스에서 AUC의 값이 0.9 이상의 높은 값을 보였으며 특히 치매군에서 AUC가 0.98로 가장 높게 나타나 GBM 모델이 치매군의 데이터에 대해 가장 효과적인 성능을 보였다. 이는 GBM이 Random Forest 모델과 같이 트리 기반으로 오차를 단계적으로 보정하여 예측 정확도를 극대화했음을 확인할 수 있었다.

4.2.3 XGBoost(Extreme Gradient Boosting) ROC-AUC 결과




그림 4-9 XGBoost ROC curve-AUC 결과

XGBoost 모델의 ROC 곡선에서도 모든 클래스가 FPR이 0.0에서 0.2 범위에서 TPR의 수치가 0.8 이상의 높은 값을 유지하는 것을 확인할 수 있었으며 AUC 값을 살펴보면 정상군은 0.94, 경도인지장애군은 0.94, 치매군은 0.98로 Random Forest 모델과 GBM 모델에 비해 정상군과 경도인지장애군의 AUC 값이 소폭 향상되었으며 치매군에서 AUC가 0.98로 가장 높게 나타나 XGBoost 모델이 GBM 모델과 마찬가지로 트리 기반 앙상블 구조를 활용하면서 Gradient Boosting 과정을 최적화하여 학습 오차를 효과적으로 보정하여 예측 성능을 향상함을 확인할 수 있었다.

4.2.4 SVM(Support Vector Machine) ROC-AUC 결과




그림 4-10 SVM ROC curve-AUC 결과

SVM 모델의 ROC 곡선을 살펴보면, 모든 클래스가 FPR이 0.0에서 0.2 범위에서 TPR의 수치가 0.8 이상의 높은 값을 유지하는 것을 확인할 수 있었다. AUC 값은 정상군 0.91, 경도인지장애군 0.92, 치매군 0.97로 모든 클래스에서 AUC의 값이 0.9 이상의 우수한 성능을 보였으며 특히 치매군에서 가장 높은 AUC 값을 보였다. 그러나 선형 기반 SVM은 복잡한 비선형 특성을 완전히 반영하지 못해 일부 집단에서 ROC 곡선의 완만한 구간이 나타났으며 이전의 모델에 비해 낮은 성능을 보였으나 SVM 모델이 비선형 경계를 효과적으로 학습함으로써 데이터 분포 특성에 적합한 판별력을 확보했음을 확인하였다.

4.2.5 LSTM(Long Short-Term Memory) ROC-AUC 결과




그림 4-11 LSTM ROC curve-AUC 결과

LSTM 모델의 ROC 곡선 역시 모든 클래스가 FPR이 0.0에서 0.2 범위에서 TPR의 수치가 0.8 이상으로 빠르게 상승함을 확인할 수 있었다. AUC 값은 정상군 0.92, 경도인지장애군 0.91, 치매군 0.98로 모든 클래스에서 AUC의 값이 0.9 이상으로 우수한 판별 성능을 보였으며 특히 치매군에서 가장 높은 AUC 값이 산출되었다. 이를 통해 LSTM 모델이 시계열 데이터의 장기 의존성과 시간적 패턴을 효과적으로 학습했음을 확인했다. 그러나, 경도인지장애군에서 일부 구간에서 ROC 곡선이 다소 완만하게 나타나 완벽하게 판별하지는 못하는 한계가 관찰된다.

4.2.6 Ensemble Learning ROC-AUC 결과




그림 4-12 Ensemble Learning ROC curve-AUC 결과

Ensemble 모델의 ROC 곡선을 살펴보면 모든 클래스에서 FPR이 0.0에서 0.2 구간에서 TPR이 0.9 이상으로 빠르게 도달하는 이상적인 분포를 보였다. AUC 값 역시 정상군 0.95, 경도인지장애군 0.95, 치매군 0.98로 모든 클래스에서 AUC의 값이 0.95 이상으로 본 연구에서 적용한 모델 중 가장 뛰어난 판별 성능을 보였다. 특히 Ensemble 모델이 개별 분류 모델의 예측을 집합적으로 결합함으로써 약점을 상호 보완하고 전반적인 예측 정확도를 안정적으로 향상시켰으며, Ensemble 모델이 데이터의 복잡한 패턴과 치매 단계에서 매우 우수한 예측 신뢰도와 판별력을 보였음을 알 수 있다.

4.2.7 ROC curve-AUC 성능 종합 비교 분석

본 연구에서 적용한 6가지 모델의 ROC curve - AUC 분석 결과, 모든 모델이 다중 클래스 분류에서 AUC 0.90 이상의 높은 분류 성능을 나타냈으며, 특히 치매군에서 0.97에서 0.98로 가장 우수한 성능을 보였다. 특히 Ensemble Learning 모델이 정상군과 경도인지장애군의 AUC 0.95와 치매군 0.98의 성능으로 가장 우수한 성능을 확인하였다. 그다음으로 XGBoost, GBM, LSTM, SVM, Random Forest 모델 순으로 성능이 높은 것을 확인하였다.

LSTM 모델은 시계열 데이터의 시간적 특성을 효과적으로 학습하여 높은 예측 성능을 나타냈지만, 경도인지장애군에서 미세한 성능 저하가 나타났음을 확인하였다. Random Forest 모델은 전체적으로 AUC 0.90 이상의 양호한 성능을 보였으나 단일 트리의 예측 결과를 집계하는 구조로 인해 복잡한 데이터 분포나 비선형적 관계를 충분히 반영하지 못해 트리 기반 및 딥러닝 모델에 비해 성능이 상대적으로 낮았다. 이러한 결과를 통해 Ensemble 모델이 라이프로그 데이터를 통해 치매 상태 분류 및 치매 조기진단에 적합한 모델임을 확인했고 추후 연구를 통해 BLOB형 원천 시계열 데이터의 직접 활용 및 추가적인 특성 변수의 탐색과 다양한 데이터 증강 등의 라이프로그 데이터에 적합한 방법을 도입해 성능을 향상시킬 필요가 있다.

제 5 장 결론 및 고찰

치매는 전 세계적으로 고령 인구의 증가에 따라 국가 차원으로 적극적인 대응이 요구되는 질환으로, 현재까지 확실한 치료제가 존재하지 않는다. 그러나 조기에 발견하여 약물치료 등의 적절한 처치를 시행하면 진행 정도를 지연시킬 수 있다. 이에 본 연구에서는 AI Hub의 ‘치매 고위험군 웨어러블 라이프로그’ 데이터를 활용하여 국내 55세 이상 고령자의 정상군(CN), 경도 인지장애군(MCI), 치매군(Dem)의 치매 상태별 활동 및 수면 라이프로그 데이터를 통합 분석하고, Random Forest, GBM, XGBoost, SVM, LSTM, 그리고 Voting 기반의 Ensemble 모델 등 총 6가지 치매 상태별 예측 모델을 개발하여 딥러닝 및 머신러닝 알고리즘 간의 성능을 비교·분석하였다.

연구 결과, Voting 기반 Ensemble 모델이 모든 평가 지표에서 가장 우수한 성능을 보였으며, 특히 ROC-AUC가 세 집단 모두 0.95 이상을 산출하여 가장 높은 판별력을 나타냈다. 이어서 XGBoost와 GBM 모델도 전반적으로 높은 성능을 보였다. LSTM 모델은 시계열 특성을 잘 반영하였으나, 소수 클래스인 경도인지장애군에서 다소 낮은 성능을 보였고, SVM 및 Random Forest 모델은 비교적 단순한 분류 경계 설정으로 인해 비선형적인 패턴을 충분히 반영하지 못한 한계를 보였다.

본 연구는 웨어러블 기기를 통해 수집된 데이터를 통한 치매 조기진단 가능성을 제시했다는 점에서 의의를 지닌다. 기존의 치매 바이오마커는 뇌 MRI나 혈액검사 등과 같이 침습적인 방식으로 데이터를 수집해야 했던 반면, 본 연구는 웨어러블 디바이스를 통해 비침습적이고 쉽게 수집 가능한 생체신호 데이터를 기반으로 치매 상태를 예측함으로써 치매 조기진단의 접근성을 높이고, 더 나아가 디지털 헬스케어 시스템과 예방 중심의 치매 관

리 체계를 구축에 기여할 수 있을 것으로 기대된다. 그리고 치매 환자 및 가족의 삶의 질 향상과 사회적 돌봄 비용 절감 등 다방면에서 과급효과를 미칠 수 있을 것으로 기대된다.

하지만 본 연구에서는 다음과 같은 한계점이 있다. 첫째, 데이터의 실험군 별 데이터 불균형과 피실험자 간의 측정 기간이 상이함으로 인해 학습에 활용된 데이터 양이 제한되었고, 이로 인해 모델의 과적합 가능성이 존재한다. 둘째, 원천 시계열 데이터 BLOB 형태의 데이터를 모델에 직접 반영하지 못하고 평균 통계 기반의 파생 변수로 변환하여 학습했다는 점에서 시계열의 패턴을 충분히 반영하는 데 한계가 있었다.

따라서, 향후 연구에서는 다기관 또는 직접 데이터를 확보하여 데이터의 다양성을 확대하고, 원천 시계열 데이터를 직접 활용할 수 있는 모델의 구조를 개발함으로써 실시간 예측이 가능한 모델로 발전시킬 필요가 있다. 또한, 실제 임상 환경에서의 적용 가능성에 대한 임상적 검증함으로써 웨어러블 기기와 연동 가능한 경량화 모델을 설계하고, 예측 결과를 즉각적으로 환자에게 전달할 수 있는 시스템으로의 확장하는 후속 연구가 필요하다.

참 고 문 헌

- [1] 김영희. "치매의 정신행동증상(BPSD)을 나타내는 환자를 조호하는 배우자의 적응과정: 근거이론을 중심으로." 국내박사학위논문 차의과학대학교 일반대학원, 2022. 경기도
- [2] 김용현. (2024). WiFi 신호강도 기반의 실내 측위를 위한 머신러닝 회귀 알고리즘의 비교 분석. 한국측량학회지, 42(5), 483-490. 10.7848/ksgpc.2024.42.5.483
- [3] 김중용. "3D 푸드펜을 활용한 시니어의 치매예측에 관한 연구." 국내박사학위논문 동국대학교 일반대학원, 2023. 서울
- [4] 김지현, 김영운, 이협건. (2024). 웹 기반 화상채팅 및 AI 분석을 통한 치매 조기 진단 및 예방 서비스 구현. 한국정보처리학회 학술대회논문집, 31(2), 795-798.
- [5] 김지희, 이진원. (2024). 라이프로그 데이터를 활용한 LSTM 모델 기반의 치매 예측. 한국정보기술학회논문지, 22(9), 123-132. 10.14801/jkiit.2024.22.9.123
- [6] 박인규. "뇌 영상과 라이프로그 데이터를 이용한 머신러닝 기반 경도인지장애 예측 진단 모델." 국내박사학위논문 한림대학교 일반대학원, 2024. 강원특별자치도
- [7] 박홍원. (2014). 스마트웨어 : 전자섬유(E-textile) 기술개발 동향. 패션정보와 기술, 11(0), 11-19.
- [8] 박효진. "일차의료에서 치매 진단을 위한 인지 선별 검사." Korean Journal of Family Practice 14.3 (2024): 116-120.
- [9] 방찬우, 김봉현. "사물인터넷 환경에서 랜덤포레스트를 이용한 실시간 낙상 사고 예측." 한국사물인터넷학회 논문지 10.4 (2024): 27-33.
- [10] 보건복지부 노인건강과. (2024). 치매조기검진사업. 보건복지부

<https://www.mohw.go.kr/menu.es?mid=a10712010100>

- [11] 양진숙, 김주연. (2014). 뉴미디어 시대의 웨어러블 디바이스 사례분석 연구. 한국디자인문화학회지, 20(2), 354-364.
- [12] 오병훈. "치매의 행동 • 정신 증상 진단 및 관리." 대한의사협회지 52.11 (2009): 1048-1054.
- [13] 오웅석, 이해영(2016). 경도인지장애. 대한신경과학회지 34.3 (2016): 167-175.
- [14] 은홍범. "경도인지장애 환자의 일상생활능력, 인지능력 및 우울증 개선을 위한 운동중재의 효과." 국내박사학위논문 상명대학교 일반대학원, 2023. 서울
- [15] 이명진, 이종언, 이한준. (2024). 라이프로그 데이터를 활용한 랜덤포레스트 및 SHAP 기반 인지기능 장애 예측 모델. 한국정보기술학회논문지, 22(1), 1-8. 10.14801/jkiit.2024.22.1.1
- [16] 이수은, 김한준. (2020). 다중 스택킹을 가진 새로운 앙상블 학습 기법. 한국전자거래학회지, 25(3), 1-13.
- [17] 이양규. "LSTM을 활용한 드론의 모터 진동 이상 탐지 연구." 국내박사학위논문 한신대학교 정보통신학과, 2021. 경기도
- [18] 임지미. (2024). 치매. 약학정보원
https://www.health.kr/Menu.PharmReview/View.asp?PharmReview_IDX=8738
- [19] 전병욱, 강지수, 정경용. (2021). 도로교통 이머징 리스크 탐지를 위한 AutoML과 CNN 기반 소프트 보팅 앙상블 분류 모델. 융합정보논문지, 11(7), 14-20.
- [20] 정연수, 이창준. (2022). 주성분 분석과 서포트 벡터 머신을 이용한 폴리스티렌 중합 반응기 이상 진단 모델 개발. 화학공학, 60(2), 223-228.
- [21] 정우석, 김성은, 김영도. (2021). 랜덤포레스트를 이용한 낙동강 본류의

- 납조류 발생 영향인자 분석. 한국습지학회지, 23(1), 27-34.
- [22] 정재훈. (2023). 국내 경도인지장애 환자에 적용한 이중과제 프로그램이 인지기능에 미치는 효과: 체계적 문헌 고찰 및 메타분석. 산업융합연구, 21(12), 101-111.
- [23] 조영은, 우종필, 김중안(2024). 머신러닝 기법을 활용한 치매 예측 모델과 상업적 활용 전략: 웨어러블 기기의 수면 및 활동 데이터를 기반으로. 경영정보학연구, 26(2), 137-153.
- [24] 중앙치매센터(2023). 2023 나에게 힘이 되는 치매가이드북. 중앙치매센터 https://iksan.nid.or.kr/community/pds_view.aspx?page=&BID=251
- [25] 중앙치매센터(2024). 2024 나에게 힘이 되는 치매가이드북. 중앙치매센터 https://ansim.nid.or.kr/community/pds_view.aspx?page=&BID=285
- [26] 중앙치매센터(2024). 대한민국 치매현황 2023. 중앙치매센터 https://ansim.nid.or.kr/community/pds_view.aspx?page=&BID=284
- [27] 최성환. (2022). 플렉서블 디스플레이 및 웨어러블 디바이스 기술 개발 동향. 전기의세계, 71(11), 45-48.
- [28] 최현오. "스마트팜 장비 건전성 관리를 위한 인공지능 기반 이상 탐지 기술 연구." 국내박사학위논문 국립순천대학교대학원, 2025. 전라남도
- [29] 최현철, 윤치호, 이새봄. (2023). AutoML과 라이프로그를 활용한 인지 기능 장애 예측모형. 한국컴퓨터정보학회논문지, 28(11), 53-63.
- [30] 허선영. (2023). 초로기(初老期) 치매 환자 현황 및 중복 대응 방안. 중복연구원.
- [31] Esteva Andre, Robicquet Alexandre, Ramsundar Bharath, Kuleshov Volodymyr, DePristo Mark, Chou Katherine, Cui Claire, Corrado Greg, Thrun Sebastian, Dean Jeff. "A guide to deep learning in healthcare" Nature medicine : 24-29.
- [32] Fawcett, T. (2006). An Introduction to ROC Analysis. Pattern

- Recognition Letters, 27(8), 861 - 874.
<https://www.sciencedirect.com/science/article/pii/S016786550500303X>
- [33] Friedman, J. H. (2001). Greedy Function Approximation: A Gradient Boosting Machine. *Annals of Statistics*, 29(5), 1189 - 1232.
- [34] Giezendanner S, Monsch AU, Kressig RW, Mueller Y, Streit S, Essig S, et al(2019). General practitioners' attitudes towards early diagnosis of dementia: a cross-sectional survey. *BMC Fam Pract* 2019; 20: 65.
- [35] Grandini, M., Bagli, E., & Visani, G. (2020). Metrics for Multi-class Classification: An Overview. *arXiv preprint arXiv:2008.05756*. Retrieved from <https://arxiv.org/pdf/2008.05756>
- [36] Hand, D. J., & Till, R. J. (2001). A Simple Generalisation of the Area Under the ROC Curve for Multiple Class Classification Problems. *Machine Learning*, 45(2), 171 - 186.
<https://link.springer.com/article/10.1023/A%3A1010920819831>
- [37] Hochreiter, S., & Schmidhuber, J. (1997). Long Short-Term Memory. *Neural Computation*, 9(8), 1735 - 1780.
- [38] International Psychogeriatric Association. (2015). *The IPA Complete Guides to Behavioral and Psychological Symptoms of Dementia (BPSD) - Specialists Guide*.
- [39] J. Hong and S.J. Jeon, "Prediction of safety grade of bridges using the classification models of decision tree and random forest," *KSCE Journal of Civil and Environmental Engineering Research*, Vol.43, No.3, pp.397-411, 2023.
- [40] Khan, Kaffayatullah & Ahmad, Waqas & Amin, Muhammad & Ahmad, Ayaz & Nazar, Sohaib & Alabdullah, Anas. (2022).

- Compressive Strength Estimation of Steel-Fiber-Reinforced Concrete and Raw Material Interactions Using Advanced Algorithms. *Polymers*. 14. 10.3390/polym14153065.
- [41] Mallya, S., Overhage, M., Srivastava, N., Arai, T., & Erdman, C. (2019). Effectiveness of LSTMs in Predicting Congestive Heart Failure Onset. *arXiv preprint arXiv:1902.02443*. <https://arxiv.org/abs/1902.02443>
- [42] Mayeux R, Ottman R, Tang MX, Noboa-Bauza L, Marder K, Gurland B, et al. Genetic susceptibility and head injury as risk factors for Alzheimer's disease among community-dwelling elderly persons and their firstdegree relatives. *Ann Neurol* 1993;33:494-501
- [43] Mirbabaie, M., Stieglitz, S., & Frick, N. R. J.(2021). Artificial intelligence in disease diagnostics: A critical review and classification on the current state of research guiding future direction. *Health and Technology*, 11, 693 - 731. <https://doi.org/10.1007/s12553-021-00555-5>
- [44] Rykov, Y.G., Patterson, M.D., Gangwar, B.A. et al. Predicting cognitive scores from wearable-based digital physiological features using machine learning: data from a clinical trial in mild cognitive impairment. *BMC Med* 22, 36 (2024). <https://doi.org/10.1186/s12916-024-03252-y>
- [45] World Health Organization. (2025 March 31). Dementia. <https://www.who.int/news-room/fact-sheets/detail/dementia>
- [46] Yang, Y., et al. (2025). Optimized Ensemble Learning Approach with Explainable AI for Heart Disease Prediction. *Information*, 15(7), 394. <https://doi.org/10.3390/info15070394>

Abstract

Research on predictive models for early early diagnosis and prevention of dementia based on wearable lifelog data

Choi, Ji-ye

Department of Medical Engineering

Graduate School, Catholic Kwandong University

Supervised by Professor Jeong, Jin-Hyung

Due to the rapid increase in the elderly population, dementia has emerged as a representative degenerative disease that places a burden on both individuals and society. In this study, we developed an AI-based prediction model that predicts and classifies dementia status (normal, mild cognitive impairment, dementia) using the “Dementia High-Risk Group Wearable Lifelog” data provided by the AI Hub operated by the Korea Intelligent Information Society Promotion Agency, and compared and analyzed the performance of various algorithms. The data used in this study consists of activity and sleep

data collected from 174 elderly individuals aged 65 and older via ring-shaped wearables, with each participant providing at least 35 days of data on calories, MET, sleep heart rate, and movement. In the data preprocessing stage, significant variables were selected through correlation analysis and ANOVA, and SMOTE was applied to correct class imbalance. Subsequently, six machine learning and deep learning models, including Random Forest, GBM (Gradient Boosting Machine), XGBoost (Extreme Gradient Boosting), SVM (Support Vector Machine), LSTM (Long Short-Term Memory), and Soft Voting-based Ensemble models. The analysis results showed that all models performed above 0.80, with the XGBoost model demonstrating the highest performance among the individual models, achieving an accuracy of 0.86 and an AUC of 0.94 on the ROC curve for the normal and mild cognitive impairment groups, and 0.98 for dementia. It also demonstrated that it could effectively classify dementia status based on high sensitivity and specificity by effectively reducing learning errors even with highly nonlinear wearable-based lifelog data. In addition, the Ensemble Learning model applied the Soft Voting method, which combines the prediction probabilities of other models, and demonstrated stable and high accuracy of 0.875 and AUC of 0.95 for normal and mild cognitive impairment and 0.98 for dementia, making it the most promising prediction tool. These results suggest that machine learning models are suitable for dementia prediction using complex and highly nonlinear wearable-based lifelog data, demonstrating the feasibility of implementing a lifelog data-based early dementia diagnosis system. This study is significant in that it proves the practical potential of prediction models trained based on non-invasive and continuous biosignal monitoring for use in various fields, such as customized prevention, screening of high-risk groups for dementia, and early intervention.

Future research should consider the diversity of data collection periods and experimental groups, and apply real-time data processing and adaptive models to enhance the accuracy and reliability of the model. This is expected to increase the feasibility of realizing a digital healthcare platform capable of early diagnosis and preventive intervention for dementia.

국 문 요 약

웨어러블 라이프로그 데이터 기반 치매 조기진단 및 예방을 위한 예측모델에 관한 연구

최 지 예

가톨릭관동대학교 일반대학원

의료공학과

지 도 교 수 정 진 형

고령 인구의 급증으로 인해 치매는 개인과 사회 모두에게 부담을 야기하는 대표적인 퇴행성 질환으로 부상하고 있다. 이에 본 연구에서는 한국지능정보사회진흥원에서 운영하는 AI Hub에서 제공하는 ‘치매 고위험군 웨어러블 라이프로그’ 데이터를 활용하여 치매 상태별(정상, 경도인지장애, 치매)을 예측 분류하는 인공지능 기반 예측 모델을 개발하고 다양한 알고리즘 간 성능을 비교 및 분석을 진행하였다.

본 연구에서 사용한 데이터는 총 174명의 55세 이상의 고령자로부터 반지형 웨어러블을 통해 수집된 활동 및 수면 데이터로 각 실험자당 최소 35일 이상의 칼로리, MET, 수면 심박수, 뒤척임 등의 데이터가 포함되어 있다. 데이터 전처리 단계에서는 상관관계 분석 및 ANOVA를 통해 유의한 변수를 선별하고, SMOTE를 적용하여 클래스 불균형을 보정하였다. 이후 Random Forest, GBM(Gradient Boosting Machine), XGBoost(Extreme Gradient Boosting), SVM(Support Vector Machine), LSTM(Long Short-Term Memory), 그리고 Soft Voting 기반의 Ensemble 모델 등 총 6가지 머신러닝 및 딥러닝 모델을 적용하였다.

분석 결과, 모델 모두 0.80 이상의 성능을 보였으며, 개별 모델 중 XGBoost 모델이 정확도 0.86과 ROC curve-AUC에서 정상과 경도인지장애군에서 AUC 0.94, 치매 0.98의 수준으로 가장 뛰어난 성능을 보여주었으며, 비선형성이 강한 웨어러블 기반 라이프로그 데이터에서도 학습 오차를 효과적으로 줄여가며 학습해 높은 민감도와 특이도를 바탕으로 치매 상태를 효과적으로 분류할 수 있음을 입증하였다. 또한, Ensemble Learning 모델은 다른 모델의 예측 확률을 조합하는 Soft Voting 방식을 적용하여 전반적으로 안정적이고 높은 정확도 0.875와 AUC 정상, 경도인지장애 0.95와 치매 0.98의 성능을 보여주어 가장 유망한 예측 도구로 평가되었다. 이러한 결과는 머신러닝 모델이 복잡하고 비선형성이 큰 웨어러블 기반 라이프로그 데이터를 활용한 치매 예측에 적합하다는 점을 시사하며, 라이프로그 데이터 기반 치매 조기진단 시스템의 구현 가능성을 보여준다. 본 연구에서는 비침습적이고 지속적인 생체신호 모니터링을 기반으로 학습된 예측 모델이 맞춤형 예방, 치매 고위험군 선별, 조기 개입 등 다양한 분야에서 활용될 수 있는 실질적인 가능성을 입증하는 데 의의가 있다.

향후 연구에서는 데이터 수집 기간 및 실험자 집단의 다양성을 고려하고 실시간 데이터 처리 및 적응형 모델을 적용하여 모델의 정확도와 신뢰성을 강화할 필요가 있다. 이를 통해 치매 조기진단 및 예방적 개입이 가능한 디지털 헬스케어 플랫폼의 실현 가능성을 높일 수 있을 것으로 기대된다.